

Previsão da vida útil remanescente de estruturas de concreto armado sujeitas à corrosão induzida por carbonatação por meio de emuladores estocásticos

Forecasting the Remaining Useful Life of Reinforced Concrete Structures Subjected to Carbonation-Induced Corrosion Using Stochastic Emulators

Victor Hugo Moreira do Couto Souza

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

Wanderlei Malaquias Pereira Junior (Autor correspondente)

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

University of Minnesota, Minneapolis, MN 55455, Estados Unidos

wanderlei.malaquias.pereira.jr@gmail.com

Marcos Luiz Henrique

Núcleo Interdisciplinar de Ciências Exatas e da Natureza (NICEN/CAA)

Universidade Federal de Pernambuco (UFPE), Caruaru, 55014-900, Pernambuco, Brasil

marcos.henrique@ufpe.br

Renata Maria Pensin

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

Ketson dos Santos

CEGE — Department of Civil, Environmental, and Geo-Engineering, University of Minnesota,
Minneapolis, MN 55455, Estados Unidos

Resumo

A corrosão induzida por carbonatação é um dos principais mecanismos de degradação de estruturas de concreto armado, e a previsão acurada da vida útil remanescente (*Remaining Useful Life* — RUL) é essencial para a gestão de infraestruturas informada por risco. Este trabalho propõe um emulador estocástico dependente do tempo que aproxima a distribuição condicional completa da função de estado limite $g(\mathbf{X}, t)$ por meio da Distribuição Lambda Generalizada, cujos parâmetros são representados por Expansão em Caos Polinomial das variáveis de entrada e interpolados continuamente no tempo por um modelo de aprendizado de máquina. O arcabouço integra o modelo de avanço da frente de carbonatação, a perda de seção e de aderência das armaduras e a verificação do estado limite, fornecendo, a custo computacional desprezível, a probabilidade de falha, a distribuição do tempo até a falha, a RUL probabilística e métricas de risco de cauda (VaR e CVaR). O método é verificado em um problema de referência com solução de Monte Carlo direta como *ground truth* e aplicado à previsão da RUL de elementos de concreto armado sob

carbonatação. Os resultados indicam excelente concordância distribucional (erro relativo inferior a **[FALTA: número]**% até o percentil 99) e ganho de eficiência computacional de **[FALTA: número]** ordens de grandeza em relação à simulação direta, viabilizando análises de RUL e de cenários de manutenção em tempo quase real.

Palavras-chave: vida útil remanescente; carbonatação; emulador estocástico; distribuição lambda generalizada; confiabilidade dependente do tempo; concreto armado.

Keywords: remaining useful life; carbonation; stochastic emulator; generalized lambda distribution; time-dependent reliability; reinforced concrete.

Nomenclatura

Modelos físicos — carbonatação e corrosão

$y(t)$	Profundidade da frente de carbonatação no instante t (mm)
k	Coefficiente de carbonatação ($\text{mm}/\sqrt{\text{ano}}$)
CO_2	Concentração volumétrica de CO_2 no ambiente (%)
ad	Teor de adição pozolânica em relação à massa de cimento (%)
k_c, k_{fc}, k_{ad}	Coefficientes do modelo de carbonatação: cimento, resistência e adições
k_{CO_2}, k_{UR}, k_{ce}	Coefficientes do modelo de carbonatação: CO_2 , umidade e exposição
c_{nom}	Cobrimento nominal da armadura (mm)
t_{ini}	Instante de iniciação da corrosão (anos)
t_{corr}	Período de propagação, $t_{\text{corr}} = t - t_{\text{ini}}$ (anos)
f_c	Resistência a compressão do concreto (MPa)
UR	Umidade relativa do ar (%)
i_{corr}	Densidade de corrente de corrosão ($\mu\text{A}/\text{cm}^2$)
$d_{s0}, d_s(t)$	Diâmetro inicial e residual das barras (mm)
$A_s(t)$	Área efetiva de armadura no instante t (mm^2)
C_f	Coefficiente redutor de aderência aço-concreto

Resistência e estado limite

$M_{Rd,0}$	Momento resistente da seção íntegra ($\text{kN}\cdot\text{m}$)
$M_{Rd,\text{cor}}(t)$	Momento resistente degradado no instante t ($\text{kN}\cdot\text{m}$)
M_S	Momento solicitante característico total ($\text{kN}\cdot\text{m}$)
$g(\mathbf{X}, t)$	Função de estado limite (margem de segurança)
$\mathbf{X}$	Vetor de variáveis aleatórias de entrada
$T(\mathbf{x})$	Tempo até a falha (anos)

Emulador estocástico

$\mathcal{M}_S$	Simulador estocástico
-----------------	-----------------------

$Q(u)$	Função quantílica da Distribuição Lambda Generalizada
$\boldsymbol{\lambda} = \{\lambda_1, \dots, \lambda_4\}$	Parâmetros da GLD (localização, escala, forma)
Ψ_α	Polinômios ortonormais multivariados da PCE
$a_{i,\alpha}$	Coefficientes da PCE
$\mathcal{M}_{ML}$	Regressor de aprendizado de máquina (camada temporal)
M, N, N_t	Número de pontos do DoE, réplicas e passos de tempo

Confiabilidade, RUL e risco

$p_f(t)$	Probabilidade de falha dependente do tempo	
$\beta(t)$	Índice de confiabilidade generalizado	
$R(t)$	Função de confiabilidade (probabilidade de sobrevivência)	
$RUL(t_{\text{insp}})$	Vida útil remanescente condicionada	a inspeção
VaR_α	<i>Value-at-Risk</i> ao nível α	
$CVaR_\alpha$	<i>Conditional Value-at-Risk</i> ao nível α	

Siglas

RUL	<i>Remaining Useful Life</i> (vida útil remanescente)
GLD	Distribuição Lambda Generalizada
GLaM	<i>Generalized Lambda Model</i>
PCE	Expansão em Caos Polinomial
ML	Aprendizado de Máquina (<i>Machine Learning</i>)
RNA	Rede Neural Artificial
MoM	Método dos Momentos
LHS	Amostragem por Hipercubo Latino
KS / AD	Testes de Kolmogorov–Smirnov / Anderson–Darling

1. Introdução

As estruturas de concreto armado constituem a espinha dorsal dos sistemas de infraestrutura crítica; entretanto, sua durabilidade a longo prazo é fortemente afetada por mecanismos de degradação, dentre os quais se destaca a corrosão das armaduras induzida pela carbonatação. A carbonatação reduz a alcalinidade do concreto, viabilizando o início da corrosão e a perda progressiva de capacidade resistente, o que pode comprometer a segurança, a funcionalidade e o desempenho ao longo do ciclo de vida (**tuutti1982; possan2010**). À medida que as redes de infraestrutura envelhecem e os recursos de manutenção se tornam cada vez mais restritos, a capacidade de prever com acurácia a vida útil remanescente (*Remaining Useful Life* – RUL) de estruturas de concreto armado tornou-se um desafio central da engenharia estrutural e da gestão de ativos informada por risco (**ellingwood2005; frangopol2011; si2011**).

As abordagens tradicionais de previsão de vida útil apoiam-se em modelos físicos de profundidade de carbonatação e em formulações determinísticas de estado limite. Embora

tais modelos forneçam valiosa compreensão mecanicista, eles frequentemente não capturam os efeitos combinados da variabilidade dos materiais, da incerteza ambiental, da deterioração estocástica e do erro epistêmico de modelo (**possan2010; melchers2018**). Os avanços recentes em modelagem probabilística de durabilidade têm, portanto, enfatizado a integração entre quantificação de incertezas, processos estocásticos de deterioração e calibração orientada por dados (**jcass2001; fib2006**).

Em paralelo, técnicas de aprendizado de máquina (*Machine Learning* – ML) e de metamodelagem têm recebido crescente atenção para a previsão da profundidade de carbonatação, da degradação estrutural e do desempenho ao longo do ciclo de vida de sistemas de concreto armado. Em trabalho anterior deste grupo, modelos de ML foram treinados para reproduzir a profundidade de carbonatação prevista por um modelo paramétrico de referência, evidenciando a forte não linearidade do fenômeno e a superioridade dos regressores não lineares sobre formulações de regressão convencionais (**couto2025**). Contudo, modelos puramente orientados por dados costumam apresentar capacidade limitada de extrapolação, baixa interpretabilidade e sensibilidade à escassez de dados de treinamento, o que restringe sua aplicação direta em avaliações de confiabilidade de sistemas críticos.

No contexto da quantificação de incertezas, metamodelos consolidados como os Processos Gaussianos (GP) (**rasmussen2006**) e as Expansões em Caos Polinomial (PCE) (**xiu2002; blatman2011**) são padrão para simuladores *determinísticos*, nos quais uma única avaliação caracteriza a resposta. Esses metamodelos, entretanto, não podem ser aplicados diretamente a *simuladores estocásticos*, nos quais a resposta para um mesmo vetor de entrada é uma variável aleatória cuja distribuição precisa ser caracterizada. Essa é exatamente a natureza do problema de degradação por carbonatação: para uma mesma configuração de projeto, variáveis latentes de material e de ambiente produzem uma distribuição de margens de segurança, e não um valor único. Para esse cenário, foram propostos recentemente os emuladores estocásticos, com destaque para os modelos *Generalized Lambda Models* (GLaM), nos quais a distribuição condicional da resposta é aproximada pela Distribuição Lambda Generalizada (GLD) e seus quatro parâmetros são representados por PCE das variáveis de entrada (**ZhuSudret2020; ZhuSudret2021**).

Apesar desses avanços, identifica-se uma lacuna na literatura: os trabalhos existentes sobre confiabilidade dependente do tempo de estruturas sujeitas à carbonatação concentram-se em emular momentos estatísticos, o índice de confiabilidade $\beta(t)$ ou a profundidade média de carbonatação, e o arcabouço GLaM original é formulado para um instante fixo, sem tratamento contínuo da variável tempo. Nenhuma abordagem disponível fornece, de forma simultânea, (i) a distribuição condicional *completa* da função de estado limite $g(t)$, (ii) a interpolação contínua dessa distribuição entre instantes simulados e (iii) a tradução direta dessa informação em uma distribuição probabilística de RUL apta a subsidiar decisões de manutenção.

Para preencher essa lacuna, o presente estudo propõe um emulador estocástico dependente do tempo no qual a resposta do simulador é modelada por uma GLD cujos

parâmetros λ são funções das variáveis de entrada, representadas por PCE, e a evolução temporal desses parâmetros é aprendida por um modelo de ML que recebe o tempo como variável de entrada contínua. Uma vez treinado, o emulador fornece instantaneamente a função densidade de probabilidade da margem de segurança $g(\mathbf{X}, t)$ em qualquer instante t do horizonte de análise, da qual se derivam a probabilidade de falha, a distribuição do tempo até a falha, a RUL probabilística e métricas de risco de cauda (VaR e CVaR). A metodologia é aplicada à previsão da vida útil remanescente de elementos de concreto armado sujeitos à corrosão induzida por carbonatação, integrando o modelo de avanço da frente de carbonatação de **possan2010**<empty citation>, a perda de seção e de aderência das armaduras (**val1997**; **azad2010**; **peng2016**) e a verificação do estado limite último de flexão segundo a **nbr6118**<empty citation>. Para verificar o arcabouço metodológico, adota-se uma versão adaptada de um problema de referência de confiabilidade, seguindo a estratégia geral de validação proposta por **pires2024**<empty citation>.

As principais contribuições deste trabalho são: (i) a extensão do arcabouço GLaM para o domínio temporal, por meio de uma camada de aprendizado de máquina que interpola continuamente os parâmetros da GLD entre os instantes simulados; (ii) a integração da deterioração por carbonatação em um arcabouço probabilístico de previsão de RUL que opera sobre a distribuição completa da função de estado limite, e não apenas sobre seus momentos; e (iii) a demonstração de ganhos de eficiência computacional de ordens de grandeza em relação à abordagem convencional de Monte Carlo, viabilizando análises de RUL em tempo quase real, inclusive em cenários com intervenções de manutenção. Os resultados visam a contribuir para a avaliação de ciclo de vida baseada em confiabilidade de infraestruturas de concreto armado e para o suporte a decisões de manutenção informadas por risco.

O restante do artigo está organizado da seguinte forma. A Seção 2 reúne a fundamentação sobre vida útil de estruturas de concreto armado: os mecanismos de degradação, a fenomenologia da carbonatação, os modelos de previsão da profundidade carbonatada e o conceito de vida útil remanescente com suas métricas de risco. A Seção 3 apresenta o núcleo metodológico do emulador — o simulador estocástico, a Distribuição Lambda Generalizada, seu acoplamento com a Expansão em Caos Polinomial e a camada de aprendizado de máquina que o torna contínuo no tempo. A Seção 4 detalha a metodologia propriamente dita: a função de estado limite de despassivação, a parametrização adotada, os cenários de exposição, o procedimento de construção do emulador e a obtenção da RUL a partir da distribuição emulada. A Seção 5 apresenta os exemplos numéricos, iniciando pela verificação em um problema de referência e avançando para a previsão de RUL de elementos de concreto armado sob carbonatação. A Seção 6 resume as conclusões.

2. Vida útil de estruturas de concreto armado

2.1 Degradação, vida útil e o modelo de Tuutti

Estruturas de concreto armado em serviço estão permanentemente expostas a agentes físicos e químicos que reduzem progressivamente seu desempenho. A durabilidade não é, portanto, uma propriedade intrínseca do material, mas a resposta de uma estrutura específica, em um ambiente específico, ao longo de um período determinado (fib2006). Essa dependência conjunta de material, ambiente e tempo é o que torna a previsão de vida útil um problema naturalmente probabilístico.

Entre os mecanismos de deterioração do concreto armado destacam-se a corrosão de armaduras induzida por íons cloreto, característica de ambientes marinhos e de estruturas sujeitas a sais de degelo; a corrosão induzida por carbonatação, predominante em ambientes urbanos e atmosféricos; o ataque por sulfatos; a reação álcali-agregado; a lixiviação da matriz cimentícia; e os ciclos de gelo-degelo. Dentre todos, a corrosão das armaduras é reconhecida como a principal causa de deterioração precoce de estruturas de concreto armado (tuutti1982; melchers2018).

Os dois mecanismos de corrosão mais relevantes diferem quanto à natureza do ataque, conforme detalhado na Seção 2.2: os cloretos rompem a camada passiva de forma localizada, enquanto a carbonatação a destrói de maneira generalizada. A carbonatação é o mecanismo dominante em ambientes urbanos atmosféricos afastados da orla marítima, condição que descreve grande parte do parque construído brasileiro no interior do país e que justifica o recorte adotado neste trabalho.

No que se refere à vida útil, é usual distinguir a *vida útil de projeto*, período para o qual a estrutura é concebida e que fundamenta a escolha do cobrimento e da classe de agressividade ambiental (nbr6118); a *vida útil de serviço*, efetivamente observada em campo; e a *vida útil remanescente*, isto é, o período que resta, a partir de um instante de inspeção, até que um estado limite pertinente seja atingido. É esta última que interessa à gestão de ativos existentes e que constitui o objeto deste trabalho.

O arcabouço conceitual consagrado para descrever a evolução da corrosão é o modelo de tuutti1982, que decompõe a vida útil em duas fases sucessivas:

$$t_{\text{total}} = t_{\text{ini}} + t_{\text{prop}}, \quad (1)$$

em que t_{ini} é o período de *iniciação*, durante o qual a frente agressiva avança pelo cobrimento sem que haja perda de capacidade estrutural, e t_{prop} é o período de *propagação*, iniciado com a despassivação da armadura, no qual ocorrem a perda de seção do aço, a fissuração por expansão dos produtos de corrosão e o eventual destacamento do cobrimento.


Este trabalho concentra-se na **fase de iniciação**. O estado limite considerado é, portanto, a *despassivação* da armadura — o instante em que a frente carbonatada alcança o

nível do aço — e não a ruína estrutural. Trata-se de um estado limite de serviço de durabilidade, para o qual as recomendações do **fib2006** indicam índices de confiabilidade alvo da ordem de $\beta_{\text{alvo}} \approx 1,3$, substancialmente inferiores aos adotados para estados limites últimos, justamente porque sua violação não implica colapso, mas o encerramento do período protegido e o início da janela em que a intervenção de manutenção passa a ser pertinente. Essa distinção é mantida explicitamente ao longo de todo o texto: as distribuições de vida útil remanescente aqui obtidas referem-se ao tempo até a despassivação.

2.2 Carbonatação: fenomenologia

A corrosão desencadeada pela carbonatação difere substancialmente de outros mecanismos agressivos por sua natureza química global, governada pela redução progressiva da alcalinidade da matriz cimentícia. Enquanto agentes como os íons cloreto perfuram a camada passiva de forma localizada (corrosão por *pites*), a carbonatação avança como uma frente ácida que reduz o pH do concreto a níveis inferiores a 9, promovendo a despassivação generalizada de toda a superfície da armadura afetada. Essa perda de proteção em larga escala resulta em corrosão uniforme, caracterizada pela formação volumosa de óxidos expansivos ao longo da barra, o que gera tensões de tração no concreto e culmina em fissuração intensa e destacamento do cobrimento, mesmo antes da perda crítica de seção transversal do aço (**tuutti1982**).

O processo inicia-se com a difusão do dióxido de carbono atmosférico (CO_2) através da rede de poros do concreto. O CO_2 reage com a umidade dos poros e com os produtos de hidratação do cimento, predominantemente o hidróxido de cálcio ($\text{Ca}(\text{OH})_2$), levando à formação de carbonato de cálcio (CaCO_3), conforme a Equação (2):



Em condições normais, o concreto mantém um ambiente altamente alcalino (pH entre 12,6 e 13,5), que sustenta uma película passiva estável de óxidos sobre a superfície do aço, conferindo proteção efetiva contra a corrosão. O avanço progressivo da frente de carbonatação, contudo, reduz o pH a valores inferiores a 9, despassivando a armadura e tornando o aço suscetível à corrosão generalizada na presença de oxigênio e umidade. O processo de corrosão é tipicamente dividido em duas fases: *iniciação*, durante a qual a armadura permanece passivada enquanto a frente avança em direção a ela, e *propagação*, na qual a película protetora é destruída e a corrosão ativa se desenvolve (**tuutti1982**).

A velocidade e a profundidade da carbonatação são influenciadas por diversos fatores ambientais e de material, tais como: a concentração de CO_2 (níveis mais elevados aceleram a reação); a umidade relativa do ar (a carbonatação é mais intensa em faixas intermediárias, tipicamente 50%–70%); a qualidade do concreto (relação água/cimento, tipo de cimento e porosidade determinam a facilidade de ingresso do CO_2); e a espessura

do cobrimento, que atua como barreira física (possan2010; possan2016co2).




Figura 1: Diferenças entre os mecanismos de corrosão localizada (cloretos) e generalizada (carbonatação).

2.3 Exposição ambiental: concentração atmosférica de CO₂

Como descrito na subseção anterior, o CO₂ atmosférico é o agente que desencadeia a carbonatação, e sua concentração governa diretamente o fluxo difusivo para o interior do concreto. Diferentemente das demais condições ambientais, trata-se de uma grandeza que não é estacionária ao longo da vida útil de uma estrutura: a concentração de fundo cresceu de forma sustentada ao longo do século XX e sua trajetória futura depende do cenário de emissões considerado. Uma previsão de vida útil em horizonte secular precisa, portanto, tratar o CO₂ como uma condição de exposição variável no tempo, e não como uma constante. Para representar sua evolução, empregam-se as concentrações médias globais anuais do CMIP6, publicadas por meinshausen2017<empty citation> para o período histórico e por meinshausen2020<empty citation> para os cenários SSP (*Shared Socioeconomic Pathways*). A grandeza utilizada é a concentração de CO₂ no ar, em partes por milhão (ppm), e não a taxa de emissão, o consumo de carbono ou uma concentração de CO₂ equivalente.

A série implementada abrange 1900–2100. Até 2014, adota-se um histórico comum aos cenários. A partir de 2015, utilizam-se as trajetórias anuais publicadas para SSP1-2.6, SSP2-4.5 e SSP5-8.5. Os dados foram extraídos das colunas referentes a CO₂, unidade ppm e região global (*World*) do suplemento de meinshausen2020<empty citation>; o mesmo suplemento disponibiliza a série histórica de meinshausen2017<empty citation>. As séries são utilizadas sem ajuste de regressão ou correção posterior. As abas SSP incorporam observações em 2015–2016, conforme a descrição da base, e as trajetórias subsequentes são mantidas na versão publicada em 2020. Assim, os valores de cenário em anos já transcorridos não são apresentados como medições atualizadas.

Os três cenários representam, respectivamente, trajetórias de emissões baixas, intermediárias e muito altas. Sua seleção permite examinar condições ambientais contras-

tantes sem atribuir probabilidades de ocorrência. O SSP2-4.5 é a referência de comparação adotada por padrão; essa escolha não implica classificá-lo como o futuro mais provável. Na nomenclatura SSP x - y , o primeiro índice identifica a trajetória socioeconômica e o segundo indica o nível aproximado de forçamento radiativo em 2100, em W/m² (ipcc2021scenarios). Os resultados de durabilidade devem, portanto, ser interpretados como condicionais ao cenário de exposição escolhido.




Figura 2: Concentração atmosférica média global anual de CO₂ entre 1980 e 2100: histórico comum até 2014 e trajetórias SSP1-2.6, SSP2-4.5 e SSP5-8.5 a partir de 2015. A linha vertical indica a transição entre as séries. As linhas unem os valores anuais publicados e não representam bandas de confiança. Elaboração própria com dados de meinshausen2017; meinshausen2020<empty citation>.

A Figura 2 evidencia a divergência entre as trajetórias. No SSP1-2.6, a concentração atinge aproximadamente 474 ppm em 2063 e posteriormente diminui; no SSP2-4.5, o crescimento desacelera; no SSP5-8.5, o aumento é mais acentuado. A Tabela 1 apresenta valores selecionados para os horizontes de interesse. Esses valores descrevem o CO₂ atmosférico; uma eventual redução da concentração não significa reversão da carbonatação já ocorrida.

Tabela 1: Concentrações médias globais anuais de CO₂ nos cenários adotados (ppm), extraídas do suplemento de meinshausen2020<empty citation>.

Cenário	2050	2080	2100
SSP1-2.6	469,3	467,4	445,6
SSP2-4.5	506,9	585,1	602,8
SSP5-8.5	562,8	864,4	1135,2

2.4 Modelos de previsão da profundidade de carbonatação

A despassivação por carbonatação ocorre quando a frente carbonatada avança pelo concreto de cobrimento e atinge o nível da armadura, ou seja, quando $y(t) \geq c_{\text{nom}}$, sendo c_{nom} o cobrimento nominal. Para prever o avanço dessa frente ao longo do tempo, existem diversos modelos matemáticos na literatura, que variam desde formulações empíricas simples até abordagens analíticas e mecanísticas mais complexas.

Na sua forma mais geral e clássica, frequentemente utilizada em análises de confiabilidade, o avanço da frente de carbonatação reduz-se à lei da difusão baseada na raiz do tempo:

$$y(t) = k \sqrt{t}, \quad (3)$$

na qual t é o tempo de exposição e k (mm/ $\sqrt{\text{ano}}$) é o coeficiente de carbonatação. Em modelos simplificados como este, o coeficiente k condensa todo o efeito conjunto do material e do ambiente de exposição, podendo ser obtido, por exemplo, por regressão de perfis medidos como $k = y/\sqrt{t}$. A contrapartida dessa simplicidade é que k não permite discriminar a contribuição individual de cada fator de projeto ou de ambiente, o que o torna pouco útil quando o objetivo é justamente propagar incertezas de material e de exposição, como neste trabalho.

Formulação adotada. Para contornar essa limitação, adotou-se o modelo semiempírico de [possan2010](#); [possan2016co2](#) <empty citation>, calibrado a partir de resultados de ensaios naturais e acelerados de concretos brasileiros. O modelo explicita a influência da resistência à compressão, do tipo de cimento, do teor de adições pozolânicas, da concentração atmosférica de CO_2 , da umidade relativa e da proteção à chuva, conforme a Equação (4):

$$y(t) = k_c \cdot \left(\frac{20}{f_c}\right)^{k_{fc}} \cdot \left(\frac{t}{20}\right)^{\frac{1}{2}} \cdot \exp \left[\frac{k_{ad} \cdot ad^{\frac{3}{2}}}{40 + f_c} + \frac{k_{CO_2} \cdot CO_2^{\frac{1}{2}}}{60 + f_c} - \frac{k_{UR} \cdot (UR - 0,58)^2}{100 + f_c} \right] \cdot k_{ce} \quad (4)$$

em que $y(t)$ é a profundidade de carbonatação (mm) na idade t (anos), f_c é a resistência à compressão do concreto (MPa), ad é o teor de adição pozolânica em relação à massa de cimento (%), CO_2 é a concentração volumétrica de dióxido de carbono no ambiente (%) e UR é a umidade relativa média do ar, expressa como fração decimal. Os seis coeficientes de calibração são: k_c , associado ao tipo de cimento; k_{fc} , à resistência à compressão; k_{ad} , às adições pozolânicas; k_{CO_2} , à concentração de CO_2 ; k_{UR} , à umidade relativa; e k_{ce} , à condição de exposição da estrutura quanto à proteção à chuva. Os cinco primeiros dependem do tipo de cimento e o último da condição de exposição, com os valores reunidos na Tabela 2.

Tabela 2: Coeficientes do modelo de carbonatação em função (a) do tipo de cimento e (b) da condição de exposição da estrutura (**possan2010**, **possan2010**).

(a) Tipo de cimento					
Tipo de cimento	Características do concreto			Condições ambientais	
	Cimento k_c	f_c k_{fc}	Adição k_{ad}	CO ₂ k_{CO_2}	UR k_{UR}
CP I	19,80	1,70	0,24	18,00	1300
CP II E	22,48	1,50	0,32	15,50	1300
CP II F	21,68	1,50	0,24	18,00	1100
CP II Z	23,66	1,50	0,32	15,50	1300
CP III	30,50	1,70	0,32	15,50	1300
CP IV	33,27	1,70	0,32	15,50	1000
CP V-ARI	19,80	1,70	0,24	18,00	1300
(b) Condição de exposição					
Proteção à chuva					k_{ce}
Ambiente interno, protegido da chuva					1,30
Ambiente externo, protegido da chuva					1,00
Ambiente externo, desprotegido da chuva					0,65

Leitura física dos termos. A estrutura multiplicativa da Equação (4) admite interpretação direta, o que facilita tanto a verificação do modelo quanto a leitura posterior dos índices de sensibilidade:

- **Termo de resistência**, $(20/f_c)^{k_{fc}}$. Normaliza a resposta em relação a um concreto de referência de 20 MPa. Resistências mais elevadas decorrem de relações água/cimento menores, que produzem matriz mais densa e menor difusividade efetiva do CO₂, reduzindo a profundidade carbonatada. O expoente k_{fc} , entre 1,50 e 1,70, mede a intensidade dessa redução.
- **Termo temporal**, $(t/20)^{1/2}$. Preserva a lei da raiz do tempo da Equação (3), ancorada em uma idade de referência de 20 anos.
- **Termo de adições**, $+k_{ad}ad^{3/2}/(40+f_c)$. O sinal positivo indica aprofundamento da frente: as adições pozolânicas consomem hidróxido de cálcio na reação pozolânica e reduzem a reserva alcalina disponível para fixar o CO₂. Esse efeito é contrário ao do refinamento da estrutura de poros que as mesmas adições promovem, o qual já é capturado indiretamente pela resistência f_c .
- **Termo de CO₂**, $+k_{CO_2}\sqrt{CO_2}/(60+f_c)$. Representa o gradiente de concentração que governa o fluxo difusivo do gás para o interior do concreto; quanto maior a concentração ambiente, mais rápida a penetração.
- **Termo de umidade**, $-k_{UR}(UR-0,58)^2/(100+f_c)$. É uma parábola com vértice em $UR = 0,58$, ou seja, a expressão matemática do comportamento em sino característico

da carbonatação: em concreto seco falta água nos poros para dissolver o CO_2 e viabilizar a reação de carbonatação; em concreto saturado, os poros preenchidos reduzem o coeficiente de difusão do CO_2 em várias ordens de grandeza. A taxa máxima ocorre, portanto, em umidades intermediárias, em torno de 58%.

- **Fator de exposição, k_{ce} .** Os ciclos de molhagem saturam a rede de poros e retardam o avanço da frente, razão pela qual o ambiente externo desprotegido da chuva ($k_{ce} = 0,65$) carbonata menos que o ambiente interno protegido ($k_{ce} = 1,30$).

Cabe observar que os três termos do expoente são atenuados por denominadores crescentes com f_c ($40+f_c$, $60+f_c$ e $100+f_c$), de modo que concretos mais resistentes são menos sensíveis tanto às adições quanto às condições ambientais — comportamento coerente com a menor conectividade da rede porosa.

Uma consequência útil da normalização adotada é que, para $t = 20$ anos, $f_c = 20$ MPa, $ad = 0$, $UR = 0,58$ e concentração de CO_2 desprezível, a Equação (4) reduz-se a $y = k_c \cdot k_{ce}$. O coeficiente k_c é, portanto, diretamente interpretável como a profundidade de carbonatação, em milímetros, de um concreto de 20 MPa aos 20 anos na condição de referência, o que torna a Tabela 2 imediatamente legível: um CP IV ($k_c = 33,27$) carbonata cerca de 68% mais que um CP V-ARI ($k_c = 19,80$) nas mesmas condições, refletindo a menor reserva alcalina dos cimentos com elevado teor de adições.

Domínio de validade. O modelo foi calibrado para concretos convencionais brasileiros a partir de ensaios naturais e acelerados, e sua aplicação deve respeitar a faixa de variáveis empregada nessa calibração. As análises deste trabalho são conduzidas dentro do envelope $f_c \in [20; 50]$ MPa, $UR \in [30; 90]\%$ e $t \leq 100$ anos, com a concentração de CO_2 dada pelas trajetórias da Seção 2.3. **[FALTA: confirmar o limite superior de f_c contra a fonte primária: a descrição do modelo em possan2010<empty citation> menciona a faixa de 20 a 40 MPa, enquanto as simulações deste trabalho alcançam 50 MPa — se a faixa de calibração for mesmo 20–40 MPa, ou se reduz o envelope, ou se declara e justifica explicitamente a extrapolação]**

2.5 Vida útil remanescente

Definido o mecanismo de degradação e o modelo que descreve o avanço da frente carbonatada, resta estabelecer a grandeza de interesse para a gestão da estrutura. Para cada realização $\mathbf{x}$ das variáveis de entrada, o tempo até o esgotamento da vida útil é o primeiro instante em que a margem de segurança atinge um limiar de intervenção g_{lim} :

$$T(\mathbf{x}; g_{\text{lim}}) = \inf \{ t \geq 0 : g(\mathbf{x}, t) \leq g_{\text{lim}} \}. \quad (5)$$

O caso $g_{\text{lim}} = 0$ recupera o tempo até a violação do estado limite propriamente dita. Adotar $g_{\text{lim}} > 0$, contudo, é o que corresponde à prática de gestão: não se aguarda que a frente carbonatada alcance a armadura para então intervir, mas antecipa-se a intervenção

enquanto ainda resta uma margem de cobrimento não atacado. O limiar é, portanto, uma *variável de decisão* do gestor, e não uma propriedade da estrutura — elevá-lo significa intervir mais cedo e com mais folga; reduzi-lo a zero significa operar o ativo até o limite. Manter g_{lim} explícito na formulação permite que uma mesma análise produza uma família de distribuições de vida remanescente, uma por política, que é precisamente a entrada de um problema de otimização de manutenção.

Dado um instante de inspeção t_{insp} no qual se constata que a estrutura ainda não violou o estado limite, a *vida útil remanescente* (*Remaining Useful Life* — RUL) é a variável aleatória condicionada

$$\text{RUL}(t_{\text{insp}}; g_{\text{lim}}) = (T - t_{\text{insp}} \mid T > t_{\text{insp}}). \quad (6)$$

A RUL é a grandeza central da literatura de prognóstico e gestão da saúde de sistemas (**si2011**) e da gestão de infraestruturas informada por risco (**frangopol2011; vannoortwijk2009**). Sua natureza é intrinsecamente probabilística: como as propriedades do material, a geometria executada e as condições de exposição são incertas, T é uma variável aleatória e a RUL é uma distribuição, não um número.

Essa distinção é mais do que formal. A prática corrente reporta a vida útil residual por um valor único — tipicamente a média ou o valor obtido com parâmetros nominais —, mas nenhuma decisão de manutenção é tomada sobre a média. Decide-se sobre quantis inferiores: o gestor precisa saber qual é a vida remanescente que será superada com alta confiança, e não qual é a vida remanescente típica. Duas estruturas com a mesma $\mathbb{E}[\text{RUL}]$ podem exigir intervenções em momentos muito distintos se as dispersões, e sobretudo as caudas inferiores, forem diferentes.

Por essa razão, além da distribuição completa, empregam-se métricas de risco de cauda consagradas em análise de decisão sob incerteza (**rockafellar2000**). O *Value-at-Risk* ao nível α é o quantil inferior da distribuição de RUL,

$$\text{VaR}_\alpha = \inf \{ r : F_{\text{RUL}}(r) \geq \alpha \}, \quad (7)$$

e representa a vida remanescente que será superada com confiança $(1 - \alpha)$. O *Conditional Value-at-Risk* é o valor esperado da RUL condicionado aos cenários abaixo desse limiar,

$$\text{CVaR}_\alpha = \mathbb{E} [\text{RUL} \mid \text{RUL} \leq \text{VaR}_\alpha], \quad (8)$$

contabilizando explicitamente a severidade da cauda e fornecendo uma medida mais conservadora que o próprio VaR.

Complementarmente, a confiabilidade dependente do tempo é descrita pela probabilidade de falha instantânea $p_f(t) = \mathbb{P}[g(\mathbf{X}, t) \leq 0]$ e pelo índice de confiabilidade generalizado $\beta(t) = -\Phi^{-1}[p_f(t)]$, em que Φ é a função de distribuição normal padrão (**melchers2018**). Para processos de degradação monotônica, como o avanço da frente de carbonatação, a função de confiabilidade satisfaz $R(t) \approx 1 - p_f(t)$, uma vez que as

trajetórias que cruzam o limiar não retornam ao domínio seguro (**ellingwood2005**).

Cabe observar, por fim, que a maior parte dos trabalhos de confiabilidade dependente do tempo aplicados à carbonatação reporta a evolução de $\beta(t)$ ou da profundidade média carbonatada. A distribuição de T — e, por consequência, a de RUL e suas métricas de cauda — raramente é obtida de forma direta, pois exigiria caracterizar a distribuição *completa* de g em cada instante do horizonte de análise. É precisamente essa lacuna que o emulador estocástico apresentado na Seção 3 se propõe a preencher.

3. Emuladores estocásticos e aprendizado de máquina

O elevado custo computacional de modelos de alta fidelidade frequentemente inviabiliza simulações diretas de Monte Carlo, exigindo o uso de metamodelos, também chamados de emuladores. Embora Processos Gaussianos (GP) (**rasmussen2006**) e Expansões em Caos Polinomial (PCE) (**xiu2002**) sejam padrão para sistemas determinísticos, eles não podem ser aplicados diretamente a simuladores estocásticos, nos quais uma única avaliação é insuficiente para caracterizar a distribuição da resposta.

3.1 Simuladores estocásticos

Matematicamente, um simulador estocástico $\mathcal{M}_S$ pode ser visto como um mapeamento que incorpora variáveis determinísticas e aleatoriedade intrínseca. Para um dado vetor de parâmetros de entrada $\mathbf{x}$ no domínio $\mathcal{D}_X$, a resposta não é um valor determinístico único, mas uma variável aleatória $Y_{\mathbf{x}}$. Essa relação é formalmente expressa como:

$$\mathcal{M}_S : \mathcal{D}_X \times \Omega \rightarrow \mathbb{R}, \quad (\mathbf{x}, \omega) \mapsto \mathcal{M}_S(\mathbf{x}, \omega), \quad (9)$$

em que $\mathbf{x}$ representa o conjunto de parâmetros de entrada controlados (e.g., geometria, propriedades dos materiais) e ω denota um evento aleatório do espaço de probabilidade Ω . Essa variável latente ω introduz a estocasticidade no sistema. Consequentemente, para uma entrada fixa $\mathbf{x}$, o simulador produz uma distribuição de resultados possíveis, e não uma solução única. No problema em estudo, $\mathcal{M}_S(\mathbf{x}, \omega) = g(\mathbf{x}, t; \omega)$ é a função de estado limite definida na Equação (19), e as variáveis latentes correspondem às incertezas de modelo e às flutuações não explicitamente parametrizadas.

3.2 Distribuição Lambda Generalizada

No contexto da avaliação de durabilidade do concreto armado, o processo de carbonatação é influenciado por diversas fontes de incerteza, que vão da heterogeneidade do material às flutuações ambientais. Para capturar esses comportamentos probabilísticos complexos sem o custo computacional de simulações exaustivas, este estudo emprega a Distribuição Lambda Generalizada (GLD) como núcleo do emulador estocástico. A GLD é uma família

de distribuições de quatro parâmetros, altamente flexível, projetada para aproximar uma ampla gama de distribuições paramétricas (**KarianDudewicz2000**; **ZhuSudret2021**).

A GLD é definida por sua *função quantílica* $Q(u)$, que é a inversa da função de distribuição acumulada (CDF), i.e., $Q(u) = F^{-1}(u)$. Essa abordagem é particularmente vantajosa para a emulação estocástica, pois facilita o método de amostragem por transformada inversa. Neste estudo, considera-se a família Freimer–Kolliya–Mudholkar–Lin (FKML) (**Freimer1988**), definida como:

$$Q(u) = \lambda_1 + \frac{1}{\lambda_2} \left(\frac{u^{\lambda_3} - 1}{\lambda_3} - \frac{(1-u)^{\lambda_4} - 1}{\lambda_4} \right) \quad (10)$$

em que $u \in [0, 1]$ representa a probabilidade acumulada. A distribuição é governada por quatro parâmetros: λ_1 é o parâmetro de *locação*, λ_2 é o parâmetro de *escala* (com a exigência $\lambda_2 > 0$) e λ_3, λ_4 são os parâmetros de *forma*.

3.3 Estimação de parâmetros via método dos momentos

Para calibrar o emulador GLD, os quatro parâmetros $\boldsymbol{\lambda} = \{\lambda_1, \dots, \lambda_4\}$ devem ser estimados a partir de um conjunto de avaliações do modelo (**karian2010handbook**; **corlu2016**). Neste estudo, emprega-se o *Método dos Momentos* (MoM) (**lakhany2000**), que consiste em igualar os momentos teóricos da GLD aos momentos empíricos calculados do conjunto amostral $\mathcal{Y} = \{y^{(1)}, \dots, y^{(N)}\}$. Os quatro primeiros momentos centrais — média μ , variância σ^2 , assimetria δ e curtose κ — relacionam-se analiticamente aos parâmetros λ da seguinte forma:

$$\mu = \lambda_1 - \frac{1}{\lambda_2} \left(\frac{1}{\lambda_3 + 1} - \frac{1}{\lambda_4 + 1} \right) \quad (11)$$

$$\sigma^2 = \frac{v_2 - v_1^2}{\lambda_2^2} \quad (12)$$

$$\delta = \frac{v_3 - 3v_1v_2 + 2v_1^3}{(v_2 - v_1^2)^{3/2}} \quad (13)$$

$$\kappa = \frac{v_4 - 4v_1v_3 + 6v_1^2v_2 - 3v_1^4}{(v_2 - v_1^2)^2} \quad (14)$$

Nessas expressões, v_k denota uma função não linear que depende apenas de λ_3 e λ_4 , dada pela Equação (15), em que $B(\cdot, \cdot)$ representa a função Beta:

$$v_k = \sum_{j=0}^k \frac{(-1)^j}{\lambda_3^{k-j} \lambda_4^j} \binom{k}{j} B(\lambda_3(k-j) + 1, \lambda_4j + 1) \quad (15)$$

A calibração dos parâmetros da GLD é formulada como um problema inverso, cujo objetivo é minimizar a discrepância entre os momentos analíticos (Equações 11–14) e os momentos empíricos derivados do simulador estocástico. Para resolver esse sistema não linear, emprega-se o algoritmo de otimização Broyden–Fletcher–Goldfarb–Shanno (BFGS)

(**nocedal2006**), um método quase-Newton particularmente adequado a esse tipo de estimação devido ao tratamento eficiente de gradientes e às boas propriedades de convergência em espaços multidimensionais. O procedimento numérico foi implementado no PyGLAM, biblioteca Python desenvolvida pelos autores especificamente para a emulação de simuladores estocásticos com Distribuições Lambda Generalizadas.

Cabe registrar que o arcabouço GLaM original (**ZhuSudret2021**) emprega máxima verossimilhança condicional combinada a mínimos quadrados generalizados para a estimação dos parâmetros, dispensando réplicas no plano de experimentos. A opção pelo MoM com réplicas adotada neste trabalho justifica-se (i) pela robustez e simplicidade de implementação, (ii) pelo baixo custo de cada avaliação dos modelos mecânicos aqui considerados, que torna as réplicas viáveis, e (iii) pelo controle direto da qualidade do ajuste local em cada ponto do plano de experimentos, requisito importante para a camada temporal descrita na Seção 4.2.

A acurácia desse ajuste — que condiciona a de todo o arcabouço, por ser ele que converte cada conjunto de réplicas do simulador em um vetor $\boldsymbol{\lambda}$ — é verificada de forma isolada na Seção 5.1, por meio do ajuste a distribuições de referência com solução analítica conhecida.

3.4 Acoplamento com a Expansão em Caos Polinomial

Seguindo a metodologia proposta por **ZhuSudret2021** e desenvolvimentos posteriores em metamodelagem estocástica, a GLD é acoplada à Expansão em Caos Polinomial (PCE) para a construção de um emulador global. Nesse arcabouço, a resposta estocástica do simulador para qualquer entrada $\mathbf{X}$ é modelada por uma GLD cujos parâmetros $\boldsymbol{\lambda}$ são, eles próprios, funções das variáveis de entrada.

Dado um conjunto de parâmetros de entrada $\mathbf{X}$ governado por uma função densidade de probabilidade conjunta $f_{\mathbf{X}}(\mathbf{x})$, cada componente do vetor de parâmetros λ_i é aproximada por uma PCE truncada:

$$\lambda_i(\mathbf{X}) \approx \sum_{\boldsymbol{\alpha} \in \mathcal{A}} a_{i,\boldsymbol{\alpha}} \Psi_{\boldsymbol{\alpha}}(\mathbf{X}), \quad i = \{1, 2, 3, 4\} \quad (16)$$

em que $\Psi_{\boldsymbol{\alpha}}(\mathbf{X})$ são polinômios ortonormais multivariados específicos das distribuições de entrada (**xiu2002**), $a_{i,\boldsymbol{\alpha}}$ são os coeficientes a determinar e $\mathcal{A}$ é o conjunto de multi-índices que define o esquema de truncamento (e.g., base de grau total) (**blatman2011**). Uma vez estimados os coeficientes, o emulador PCE–GLD fornece instantaneamente a distribuição de probabilidade completa (via parâmetros $\boldsymbol{\lambda}$) para qualquer nova entrada $\mathbf{X}^*$, sem exigir novas execuções do simulador estocástico original. O procedimento concreto de construção do emulador — plano de experimentos, réplicas estocásticas e extensão temporal — é detalhado na Seção 4.2.

3.5 Aprendizado de máquina como camada temporal

O emulador PCE–GLD descrito nas subseções anteriores fornece, para cada ponto do plano de experimentos e para cada instante simulado, um vetor de parâmetros λ que caracteriza a distribuição condicional da margem de segurança. Para que esse emulador opere de forma *contínua* no tempo — e não apenas nos instantes efetivamente simulados —, é necessária uma camada de regressão capaz de aprender o mapeamento entre as variáveis de entrada, o tempo e os parâmetros da distribuição. Esta subseção apresenta os fundamentos de aprendizado de máquina empregados nessa camada, com ênfase nas redes neurais artificiais.

3.5.1 Regressão supervisionada de múltiplas saídas

$$\mathbf{w}^* = \arg \min_{\mathbf{w}} \frac{1}{K} \sum_{k=1}^K \mathcal{L}(\lambda^{(k)}, \mathcal{M}_{ML}(\mathbf{z}^{(k)}; \mathbf{w})) + \Omega(\mathbf{w}), \quad (17)$$

em que $\Omega(\mathbf{w})$ é um termo de regularização que penaliza a complexidade do modelo e mitiga o sobreajuste. Diferentemente da regressão determinística usual, aqui a variável-alvo não é a resposta física em si, mas os *parâmetros de uma distribuição de probabilidade*; a acurácia da camada de ML traduz-se, portanto, diretamente na qualidade da distribuição emulada e, conseqüentemente, na estimativa de probabilidade de falha e de RUL.

Diversos regressores são candidatos naturais a essa tarefa, entre eles as florestas aleatórias (*Random Forests*), a regressão por vetores de suporte (*Support Vector Regression* — SVR) e as redes neurais artificiais (RNA). A escolha do regressor empregado na camada temporal não é assumida a priori: candidatos são treinados e comparados sobre os próprios parâmetros da GLD, com o desempenho reportado na Seção 5.3. **[FALTA: incluir referências canônicas de ML e reconhecimento de padrões, ex.: Hastie et al. (2009); Bishop (2006); Goodfellow et al. (2016), e acrescentá-las ao references.bib]**

3.5.2 Redes neurais artificiais

Inspiradas na biologia do cérebro humano, as redes neurais funcionam através de unidades básicas de processamento conhecidas como neurônios artificiais. Assim como os dendritos e sinapses biológicas recebem e modulam sinais elétricos, o modelo computacional recebe dados numéricos de entrada e aplica "pesos" matemáticos para determinar a importância relativa de cada variável. O verdadeiro poder dessa tecnologia reside em sua capacidade inata de generalização; após processar milhares de exemplos, a rede ajusta seus parâmetros e adquire a habilidade de prever respostas estruturais para cenários físicos inéditos com notável resiliência.

Para realizar esse mapeamento complexo, a arquitetura padrão organiza os neurônios em camadas hierárquicas, movimentando a informação unidirecionalmente da camada de entrada até a previsão final na camada de saída. A estrutura básica de uma rede neural

é composta por um grande número de nós interconectados distribuídos nessas camadas, que se diferenciam fundamentalmente em três tipos: a camada de entrada (que capta as variáveis iniciais do projeto), as camadas ocultas (que realizam o processamento denso e a extração de padrões profundos) e a camada de saída (que emite a resposta final do modelo). O mecanismo de funcionamento da rede neural baseia-se na propagação contínua do sinal numérico através dessas conexões. O processamento matemático ocorre em duas etapas essenciais dentro de cada nó: primeiro, o neurônio realiza uma soma linear das entradas ponderadas pelos pesos, adicionando um valor de viés. Em seguida, o resultado passa por uma função de ativação não linear (como o ReLU), o que permite ao modelo emancipar-se das regressões simples e simular comportamentos não lineares de materiais, como a plasticidade do aço ou a fissuração do concreto. Adicionalmente, os tipos de camadas de saída dependem diretamente da aplicação estrutural desejada: em problemas de regressão a camada de saída opera geralmente com ativações lineares.




Figura 3: Diagrama de funcionamento de uma rede neural

O "conhecimento" da rede neural é construído durante um processo chamado de treinamento supervisionado. No início, como os pesos internos são aleatórios, as previsões do modelo são bastante imprecisas, gerando a necessidade de medir a divergência em relação ao resultado real por meio de uma função de perda. O algoritmo então utiliza um método de retropropagação para avaliar as falhas e ajustar iterativamente os pesos de cada conexão. Com a exposição contínua aos dados de treino, o erro matemático diminui progressivamente e a rede converge para um estado de estabilidade, atingindo a precisão necessária para o uso na engenharia em tempo real.

As redes neurais artificiais são aproximadores universais de funções, capazes de representar mapeamentos não lineares arbitrariamente complexos desde que dotadas de capacidade suficiente. Uma rede do tipo perceptron de múltiplas camadas (*Multilayer Perceptron* — MLP) organiza-se em uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio de uma camada ℓ computa uma combinação afim das ativações da camada anterior, seguida da aplicação de uma função de ativação não linear $\phi(\cdot)$:

$$\mathbf{a}^{(\ell)} = \phi\left(\mathbf{W}^{(\ell)}\mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right), \quad \mathbf{a}^{(0)} = \mathbf{z}, \quad (18)$$

em que $\mathbf{W}^{(\ell)}$ e $\mathbf{b}^{(\ell)}$ são, respectivamente, a matriz de pesos e o vetor de vieses da camada

ℓ , agrupados no conjunto de parâmetros $\mathbf{w} = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_\ell$. Funções de ativação usuais nas camadas ocultas incluem a unidade linear retificada (ReLU), $\phi(s) = \max(0, s)$, e a tangente hiperbólica, $\phi(s) = \tanh(s)$; a camada de saída, no caso de regressão, emprega tipicamente ativação linear. A saída da rede, $\mathbf{a}^{(L)}$, fornece a estimativa dos parâmetros $\hat{\lambda}$.

O treinamento consiste na minimização da perda da Equação (17), tipicamente o erro quadrático médio, por meio de *retropropagação* do gradiente combinada a um otimizador de gradiente estocástico (e.g., Adam). Para evitar o sobreajuste, empregam-se estratégias de regularização como parada antecipada (*early stopping*), penalização ℓ_2 dos pesos e, quando pertinente, *dropout*. A partição dos dados em subconjuntos de treinamento, validação e teste, aliada a validação cruzada, sustenta a estimativa honesta do erro de generalização.

Uma particularidade do presente problema é a necessidade de garantir a validade estatística da distribuição emulada: o parâmetro de escala da GLD deve satisfazer $\lambda_2 > 0$. Essa restrição é incorporada à saída da rede por meio de **[FALTA: descrever o mecanismo efetivamente adotado: predição de $\log \lambda_2$ com posterior exponenciação, ativação *softplus* na saída correspondente, ou truncamento]**, assegurando que toda predição corresponda a uma GLD bem definida. Além disso, parâmetros que exibam baixa sensibilidade às entradas podem ser fixados em seu valor médio, reduzindo a dimensionalidade da saída e melhorando a robustez do ajuste, conforme a análise exploratória apresentada na Seção 5.2.

No arcabouço proposto, a RNA recebe como entrada o vetor $\mathbf{z} = (\mathbf{x}, t)$ e prediz os parâmetros $\hat{\lambda}(\mathbf{x}, t)$ da GLD em qualquer instante do horizonte de análise, atuando como interpolador contínuo entre os anos efetivamente simulados. A arquitetura específica adotada — número de camadas ocultas, número de neurônios por camada, função de ativação, otimizador e hiperparâmetros — e a biblioteca de implementação são reportadas na Seção 5.2. **[FALTA: especificar a arquitetura final (ex.: 2–3 camadas ocultas, n neurônios, ativação ReLU/tanh, otimizador Adam, taxa de aprendizado, *early stopping*) e a biblioteca (ex.: `scikit-learn`/`TensorFlow`)]**

4. Metodologia

Esta seção reúne os modelos físicos que definem o simulador estocástico, a formulação da função de estado limite dependente do tempo, o procedimento de construção do emulador (incluindo a camada temporal de aprendizado de máquina) e a ponte entre a distribuição emulada e as grandezas de gestão de ativos (probabilidade de falha, tempo até a falha, RUL e métricas de risco).

4.1 Simulador estocástico

A fundamentação sobre o mecanismo de degradação e o modelo de previsão da profundidade carbonatada foi apresentada na Seção 2. Esta subseção define como esse modelo é organizado em um simulador estocástico: qual é a função de estado limite, como as variáveis são separadas entre entradas controladas e fontes latentes de aleatoriedade, e quais parametrizações foram adotadas.

4.1.1 Função de estado limite de despassivação

Conforme estabelecido na Seção 2.1, o estado limite adotado é a despassivação da armadura, atingida quando a frente carbonatada alcança o nível do aço. A margem de segurança no instante t é, portanto, a distância remanescente entre a face da armadura e a frente de carbonatação:

$$g(\mathbf{X}, t) = c(\mathbf{X}) - y(\mathbf{X}, t), \quad (19)$$

em que c é o cobrimento efetivo da armadura (mm) e y é a profundidade de carbonatação (mm) dada pela Equação (4). A interpretação física é direta:

$$\begin{cases} g(\mathbf{X}, t) > 0, & \text{armadura passivada (período de iniciação),} \\ g(\mathbf{X}, t) \leq 0, & \text{despassivação (fim do período de iniciação).} \end{cases} \quad (20)$$

Trata-se de um estado limite de serviço de durabilidade: sua violação não corresponde à ruína da peça, mas ao encerramento da fase protegida e ao início da janela em que a corrosão pode se desenvolver. Consequentemente, as distribuições de vida útil remanescente obtidas neste trabalho, no sentido das Equações (5) e (6), referem-se ao tempo até a despassivação.

Variáveis de projeto e variáveis latentes. A estrutura da Equação (19) admite a separação exigida por um simulador estocástico (Seção 3.1). O vetor $\mathbf{X} = \{f_c, UR, c_{\text{nom}}\}$ reúne as *variáveis de projeto*, que caracterizam a peça e o ambiente e distinguem um elemento de outro. Sobre elas atua um conjunto de *variáveis latentes* ω , multiplicativas, que representam a dispersão interna ao próprio elemento — heterogeneidade do material ao longo da peça, variabilidade executiva do posicionamento da armadura, flutuação das condições ambientais e erro do modelo de carbonatação:

$$f_c^* = f_c \omega_{f_c}, \quad UR^* = UR \omega_{UR}, \quad c = c_{\text{nom}} \omega_c. \quad (21)$$

Essa separação é o que confere ao problema a estrutura de simulador estocástico: para um mesmo vetor de projeto $\mathbf{x}$ e um mesmo instante t , a resposta g não é um valor único, mas uma *variável aleatória* cuja distribuição condicional precisa ser caracterizada. É precisamente essa distribuição condicional que o emulador da Seção 4.2 aproxima. **[FALTA:**

fixar e justificar os coeficientes de variação de ω_{fc} , ω_{UR} e ω_c com base em referências de variabilidade executiva (cobrimento) e no erro de modelo da Equação (4); declarar em Limitações que a correlação espacial ao longo da peça não é representada]

Determinada a trajetória de g para cada realização, a repetição do procedimento para todos os instantes e todas as amostras permitiria, em princípio, obter as curvas de confiabilidade e a distribuição do tempo até a despassivação por simulação direta de Monte Carlo. O custo dessa estratégia quando se deseja varrer projetos, cenários de exposição e instantes de inspeção é justamente o que motiva o emulador proposto.

4.1.2 Parametrização adotada

Neste estudo adotou-se cimento CP II F e ambiente externo protegido da chuva ($k_{ce} = 1,00$), o que fixa os coeficientes $k_c = 21,68$, $k_{fc} = 1,50$, $k_{ad} = 0,24$, $k_{CO_2} = 18,00$, $k_{UR} = 1100$ e $k_{ce} = 1,00$ da Tabela 2. O teor de adição foi mantido em $ad = 10\%$.

[FALTA: justificar o valor de ad de forma independente — teor típico de adição para o cimento adotado, ou referência de prática brasileira — e decidir se ele permanece fixo ou entra como variável do problema; note que $ad = 0$ reduz a profundidade carbonatada em torno de 1,6 mm nas condições analisadas]

Registra-se que, no modelo original, ad refere-se a adições pozolânicas em relação à massa de cimento, ao passo que o CP II F é um cimento com filer calcário; a interpretação desse parâmetro para o cimento adotado deve, portanto, ser explicitada.

Por fim, ressalta-se que a Equação (4) é avaliada neste trabalho em sua forma fechada, e não por meio de um metamodelo de aprendizado de máquina ajustado a ela. Essa opção garante que o emulador estocástico proposto na Seção 4.2 seja construído e validado contra o próprio modelo mecanístico de referência, sem a interposição de uma aproximação intermediária.

4.1.3 Trajetória de CO_2 e idade da estrutura

As trajetórias de concentração atmosférica adotadas foram apresentadas na Seção 2.3. Descreve-se aqui como elas são associadas à idade da estrutura e convertidas na entrada do modelo de carbonatação.

Para associar a exposição ambiental à idade da estrutura, distingue-se o ano-calendário a do tempo de exposição t :

$$a = a_0 + t, \quad 0 \leq t \leq T, \quad a_0 + T \leq 2100, \quad (22)$$

em que a_0 é o ano de início da exposição, tomado como o ano de construção, e T é o horizonte de análise. Dessa forma, 100 anos correspondem a 1980–2080 para uma construção de 1980 e a 2000–2100 para uma construção de 2000. O horizonte de análise não é uma vida útil previamente assegurada; o atendimento ao critério de desempenho é

avaliado ao longo desse intervalo.

Denotando por $C_s(a)$ a concentração em ppm para o cenário s , a entrada utilizada na Equação (4), expressa em porcentagem, é

$$CO_{2,s}(t) [\%] = \frac{C_s(a_0 + t)}{10^4}. \quad (23)$$

Para anos inteiros, empregam-se diretamente os valores tabulados; para anos fracionários, realiza-se interpolação linear entre os dois anos adjacentes. Não se admite extrapolação fora de 1900–2100. O limite de disponibilidade da série ambiental não amplia o domínio de validade do modelo de carbonatação.

Adota-se a média global como uma hipótese de concentração atmosférica de fundo. Não são representadas diferenças locais associadas a tráfego, ventilação ou ocupação. Além disso, variar apenas o CO_2 , mantendo as demais hipóteses ambientais, caracteriza uma análise de sensibilidade à concentração atmosférica, e não uma simulação conjunta de todos os efeitos das mudanças climáticas. As incertezas dos materiais e da exposição consideradas no simulador são avaliadas condicionalmente a cada trajetória de CO_2 ; a dispersão entre cenários não é tratada como intervalo probabilístico.

Perfis paramétricos de referência. As Figuras 4A e 4B ilustram a resposta da Equação (4) para uma estrutura construída em 2000 e analisada até 2100, sob SSP2-4.5, cimento CP II F, exposição externa protegida e $ad = 10\%$. Na primeira figura varia-se f_c com $UR = 65\%$; na segunda varia-se UR com $f_c = 30$ MPa. A linha em 30 mm corresponde ao cobrimento escolhido para essa ilustração, sem pretensão de representar todas as classes de exposição.

Nesses perfis, a expressão de carbonatação é avaliada com a idade e a concentração correspondentes a cada ano, aplicando-se o máximo acumulado para impedir a redução da profundidade. Essa é uma aproximação temporal da aplicação do modelo, não uma integração explícita do histórico de difusão e reação. A interpretação dos resultados está sujeita a essa limitação; a adoção de cenários publicados de CO_2 não constitui, por si só, validação dessa aproximação.


4.2 Construção do emulador dependente do tempo

Definidos o simulador estocástico (Seção 4.1.1) e o núcleo estatístico do emulador (Seção 3), descreve-se aqui o procedimento concreto de construção do emulador PCE–GLD e sua extensão ao domínio temporal.


4.2.1 Plano de experimentos e ajuste local

O treinamento do emulador PCE–GLD segue os passos:

1. **Plano de experimentos:** um conjunto de M pontos amostrais $\{\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(M)}\}$ é gerado por Amostragem por Hipercubo Latino (LHS) (mckay1979).



(A) Variação de f_c com $UR = 65\%$.



(B) Variação de UR com $f_c = 30$ MPa.

Figura 4: Perfis paramétricos de carbonatação para 100 anos de exposição (2000–2100), sob SSP2-4.5. O eixo horizontal representa a idade da estrutura. Perfis calculados pela Equação (4) com as hipóteses indicadas no texto.

2. **Avaliações estocásticas:** para cada ponto $\mathbf{x}^{(j)}$, o simulador estocástico original é executado N vezes, gerando um conjunto amostral local da resposta, $\mathcal{Y}^{(j)}$.
3. **Ajuste local da GLD:** o método dos momentos, implementado no PyGLAM com o otimizador BFGS, é utilizado para estimar os parâmetros locais ótimos $\hat{\boldsymbol{\lambda}}^{(j)}$ para cada $\mathcal{Y}^{(j)}$.
4. **Estimação dos coeficientes da PCE:** a partir dos pares $\{\mathbf{x}^{(j)}, \hat{\boldsymbol{\lambda}}^{(j)}\}_{j=1}^M$, os coeficientes $a_{i,\alpha}$ da Equação (16) são calculados para cada λ_i .

4.2.2 Emulação dependente do tempo

O processo de carbonatação é inerentemente dependente do tempo, exigindo que a evolução da distribuição da margem de segurança seja capturada ao longo de toda a vida em serviço da estrutura. Para tanto, o arcabouço PCE–GLD é estendido para incluir o tempo t como variável de entrada contínua. Nesse esquema de emulação temporal, os parâmetros $\boldsymbol{\lambda}$ da GLD são avaliados em passos de tempo discretos, e um metamodelo de aprendizado de máquina (Seção 3.5) é subsequentemente treinado para mapear o espaço conjunto de variáveis físicas $\mathbf{X}$ e tempo t nos parâmetros da distribuição.

A base de treinamento do emulador temporal é construída avaliando-se o simulador estocástico em N_t passos de tempo discretos $\{t_1, t_2, \dots, t_{N_t}\}$ (e.g., 0, 10, 20, 50 e 80 anos). Para cada passo t_m , um conjunto de M amostras do vetor de entrada $\mathbf{X}^{(j)}$ é avaliado, produzindo os parâmetros locais correspondentes $\hat{\boldsymbol{\lambda}}^{(j,m)}$ via PyGLAM. A base de dados resultante $\mathcal{D}$ é definida como:

$$\mathcal{D} = \left\{ \left(\mathbf{x}^{(j)}, t_m \right), \hat{\boldsymbol{\lambda}}^{(j,m)} \right\} \quad \text{para } j = 1, \dots, M \text{ e } m = 1, \dots, N_t \quad (24)$$

Para prever os parâmetros da GLD em um instante arbitrário t^* , emprega-se o modelo de ML de múltiplas saídas descrito na Seção 3.5.2, que aprende o mapeamento não linear

$f : (\mathbf{X}, t) \rightarrow \mathbb{R}^4$:

$$\hat{\lambda}(\mathbf{X}, t) \approx \mathcal{M}_{ML}(\mathbf{X}, t; \mathbf{w}). \quad (25)$$

Ao incluir o passo de tempo como entrada explícita, o emulador interpola os valores de $\{\lambda_1, \dots, \lambda_4\}$ entre os anos simulados, fornecendo uma evolução contínua da distribuição da margem de segurança ao longo de todo o período de análise. Duas salvaguardas são adotadas: (i) a restrição de validade $\lambda_2 > 0$ é imposta na saída do regressor (Seção 3.5.2); e (ii) parâmetros que exibam baixa sensibilidade às entradas podem ser excluídos do treinamento e representados por seu valor médio, decisão tomada caso a caso a partir de análise exploratória (ver Seção 5.2).

4.2.3 Métricas de validação do emulador

A similaridade estatística entre os dados de referência (*ground truth*, obtidos por simulação direta) e as amostras geradas pelo emulador é avaliada por um conjunto complementar de métricas, todas aplicadas em pontos e instantes *não utilizados no treinamento*:

Testes de aderência. O teste de Kolmogorov–Smirnov (KS) (**massey1951**) quantifica a máxima distância entre as funções de distribuição acumuladas empíricas, sendo sensível a discrepâncias globais; o teste de Anderson–Darling (AD) (**anderson1952**; **scholz1987**) pondera fortemente as caudas, sendo adequado para detectar desvios nas regiões extremas, justamente as mais relevantes para confiabilidade.

Comparação de quantis. Erros relativos nos quantis $\{0,001; 0,01; 0,5; 0,99; 0,999\}$ localizam a origem de eventuais discrepâncias e quantificam diretamente a qualidade da aproximação na cauda inferior, região que governa a probabilidade de falha.

Divergência de Kullback–Leibler. Para duas densidades $p(x)$ (referência) e $q(x)$ (emulador), a entropia relativa (**kullback1951**; **cover2006**)

$$D(p \parallel q) = \int p(x) \log \frac{p(x)}{q(x)} dx \quad (26)$$

é não negativa e anula-se se, e somente se, $p = q$. Embora não seja simétrica nem satisfaça a desigualdade triangular, é frequentemente útil interpretá-la como uma medida de “distância” entre distribuições, fornecendo um escalar global de qualidade do emulador.

4.3 Da distribuição emulada à vida útil remanescente

As grandezas de interesse para a gestão de ativos — probabilidade de falha dependente do tempo, distribuição do tempo até a despassivação, vida útil remanescente e métricas de risco — foram definidas na Seção 2.5. Esta subseção descreve como cada uma delas é obtida a partir da distribuição condicional emulada, e não por simulação direta.

4.3.1 Probabilidade de falha por inversão da função quantílica

Dado que o emulador fornece, para qualquer instante t , os parâmetros $\hat{\lambda}(\mathbf{X}, t)$ da GLD que aproxima a distribuição de g , a probabilidade de falha instantânea é obtida diretamente da função quantílica, sem necessidade de amostragem:

$$p_f(t) = \mathbb{P}[g(\mathbf{X}, t) \leq 0] = F_{g(t)}(0) = Q_t^{-1}(0), \quad (27)$$

em que $F_{g(t)}$ é a CDF da margem de segurança no instante t e Q_t a correspondente função quantílica emulada. Como a GLD é definida por sua função quantílica (Equação (10)) e não admite CDF em forma fechada, a inversão é realizada numericamente por bisseção em $u \in [0, 1]$, procurando-se u^* tal que $Q(u^*; \hat{\lambda}) = 0$; o valor u^* é a própria probabilidade de falha. Cada avaliação custa algumas dezenas de iterações escalares, contra as milhares de execuções do simulador que a estimativa equivalente por Monte Carlo exigiria. O índice de confiabilidade generalizado associado é $\beta(t) = -\Phi^{-1}[p_f(t)]$, conforme a Seção 2.5.

Cabe registrar que a hipótese de monotonicidade é satisfeita de forma estrita no problema aqui tratado: a profundidade carbonatada $y(\mathbf{X}, t)$ é não decrescente em t — condição imposta explicitamente pelo máximo acumulado descrito na Seção 4.1.3 — e o cobrimento não varia no tempo, de modo que g é não crescente e uma trajetória que cruza o zero não retorna ao domínio seguro. Não há, portanto, problema de primeira passagem não monotônico, e a identidade $R(t) = 1 - p_f(t)$ vale exatamente, dispensando correções por taxa de ultrapassagem. Essa é uma vantagem do estado limite de despassivação frente a estados limites últimos com ações variáveis flutuantes, em que tal correção seria necessária.

4.3.2 Distribuição de RUL e métricas de risco

A distribuição do tempo até a despassivação, definida pela Equação (5), é obtida de forma eficiente a partir do emulador. Para cada realização $\mathbf{x}$ amostrada das variáveis de projeto, a camada temporal (Seção 4.2.2) fornece $\hat{\lambda}(\mathbf{x}, t)$ em qualquer instante do horizonte, do que resulta uma trajetória contínua da distribuição de g . O instante $T(\mathbf{x})$ é então localizado pela raiz da Equação (5) sobre essa trajetória, sem qualquer nova execução do modelo de carbonatação.

Fixado o instante de inspeção t_{insp} , a amostra de tempos até a despassivação é condicionada à sobrevivência e transformada na distribuição de RUL pela Equação (6), da qual se extraem o valor esperado, a mediana e os quantis inferiores. As métricas de cauda VaR_α e CVaR_α (Equações (12) e (8)) são calculadas sobre essa mesma amostra, adotando-se $\alpha = 5\%$. Todo o procedimento é pós-processamento do emulador: varrer instantes de inspeção, classes de concreto ou cenários de exposição exige apenas reavaliações da GLD interpolada.

4.3.3 Modelagem de intervenções de manutenção

O emulador proposto habilita a avaliação rápida de cenários de manutenção, uma vez que cada cenário exige apenas reavaliações da GLD interpolada, e não novas execuções do simulador original. Considera-se uma intervenção no instante t_{man} — por exemplo, a remoção do concreto carbonatado, limpeza das armaduras e recomposição do cobrimento com argamassa de reparo realcalinizante — cujo efeito sobre a função de estado limite é modelado por dois mecanismos (frangopol2011; vannoortwijk2009):

1. **Recuperação da margem de segurança:** o momento resistente é restaurado a uma fração $\rho \in (0, 1]$ de seu valor íntegro, $M_{Rd,cor}(t_{\text{man}}^+) = \rho \cdot M_{Rd,0}$, em que ρ reflete a eficácia do reparo ($\rho = 1$ corresponde à recuperação total; valores típicos [FALTA: indicar faixa adotada e justificar com referência]);
2. **Reinício do relógio de iniciação:** a recomposição do cobrimento realcaliniza a vizinhança da armadura, de modo que um novo período de iniciação se desenvolve no material de reparo, $t_{\text{ini}}^{\text{nov}} = t_{\text{man}} + \Delta t_{\text{ini}}$, com Δt_{ini} governado pelo coeficiente de carbonatação do material de reparo k_{rep} [FALTA: definir distribuição de k_{rep} ; na ausência de dados, adotar $k_{\text{rep}} = k$ como hipótese conservadora].

A trajetória resultante da margem de segurança assume o típico formato “dente de serra” das estruturas mantidas, e a Equação (5) é avaliada sobre a trajetória composta. A comparação entre as distribuições de RUL com e sem intervenção quantifica o *ganho probabilístico de vida útil* proporcionado pela manutenção:

$$\Delta \text{RUL} = \text{RUL}_{\text{com man.}}(t_{\text{insp}}) - \text{RUL}_{\text{sem man.}}(t_{\text{insp}}). \quad (28)$$

Adicionalmente, o emulador permite determinar de forma praticamente instantânea o *instante normativo de intervenção*, definido como o primeiro tempo em que a probabilidade de falha atinge um alvo de norma,

$$t_{\text{man}}^* = \inf \{ t : \beta(t) \leq \beta_{\text{alvo}} \}, \quad (29)$$

adotando-se, por exemplo, $\beta_{\text{alvo}} = 1,5$ para estados limites de serviço/durabilidade, em consonância com as recomendações do fib2006<empty citation> e do jcss2001<empty citation>. Ressalta-se que este trabalho emprega a política de limiar da Equação (29) como demonstração da utilidade do emulador para decisões de manutenção; a otimização completa de custo de ciclo de vida, envolvendo custos de inspeção, reparo e falha, constitui extensão natural e é apontada como trabalho futuro.

5. Resultados e discussão

Os exemplos a seguir formam uma escada de evidência: o Exemplo 1 verifica o arcabouço metodológico em um problema de referência de baixo custo, no qual a solução de Monte

Carlo direta serve de *ground truth*; o Exemplo 2 aplica o emulador ao problema-alvo — a previsão da RUL probabilística de uma viga de concreto armado sob corrosão induzida por carbonatação; e o Exemplo 3 estende a análise a um cenário com intervenção de manutenção, demonstrando o uso do emulador no suporte à decisão.

5.1 Verificação da biblioteca PyGLAM

A biblioteca *PyGLAM*, desenvolvida pelos autores em linguagem Python, implementa o ajuste, a amostragem e a avaliação da Distribuição Lambda Generalizada na parametrização FKML (Freimer1988). Por ser o núcleo estatístico de todo o arcabouço — é ela que converte cada conjunto de réplicas do simulador em um vetor $\mathbf{\lambda}$ —, sua acurácia condiciona a de todos os resultados subsequentes. Esta subseção verifica essa acurácia de forma isolada, antes que o emulador seja exercitado nos Exemplos 5.2 e 5.3.

5.1.1 Procedimento

Quatro distribuições-alvo foram escolhidas por exercitarem geometrias distintas: a **Normal** (simétrica, suporte ilimitado), a de **Gumbel** (assimétrica à direita, cauda exponencial), a **Uniforme** (suporte compacto, sem moda) e a **Lognormal** (assimétrica à direita, cauda mais pesada). Para cada alvo, amostras de tamanho $N \in \{50; 200; 1.000; 5.000\}$ foram geradas e ajustadas pelo método dos momentos com 15 reinícios de otimização. Cada célula (distribuição, N) foi repetida 20 vezes com amostras independentes, e os valores reportados são as médias dessas repetições — precaução necessária porque, em $N = 50$, um ajuste isolado é dominado por ruído amostral.

As métricas são calculadas contra a distribuição-alvo *analítica*, e não contra a amostra, de modo a medir a qualidade da aproximação da família GLD e não o ajuste ao ruído. A estatística de Kolmogorov–Smirnov é tomada como $\sup_x |F_{\text{GLD}}(x) - F_{\text{alvo}}(x)|$, os erros de quantil são normalizados pela amplitude $P_5 - P_{95}$ do alvo, e a divergência de Kullback–Leibler (Equação (26)) é avaliada na direção $D(q||p)$, da GLD ajustada em relação ao alvo. Essa escolha de direção não é arbitrária: com $\lambda_3, \lambda_4 > 0$ a GLD-FKML possui suporte *compacto*, ao passo que Normal, Gumbel e Lognormal não, de modo que $D(p||q)$ diverge por construção.

5.1.2 Resultados

A Figura 5 apresenta os ajustes para $N = 1.000$ e a Tabela 3 consolida as métricas.

A leitura quantitativa desses resultados é dada pela taxa com que a distância KS decai com o tamanho amostral, obtida por regressão linear em escala logarítmica. O erro de um ajuste por momentos decompõe-se em duas parcelas: uma *amostral*, decorrente da estimação dos quatro primeiros momentos a partir de uma amostra finita, que decai com a taxa teórica $N^{-1/2}$; e outra *estrutural*, decorrente de a família GLD não conter




Figura 5: Ajuste da GLD, pelo método dos momentos implementado no PyGLAM, a quatro distribuições-alvo ($N = 1.000$). O histograma corresponde à amostra e a linha contínua à densidade da GLD ajustada.

Tabela 3: Métricas de qualidade do ajuste da GLD às distribuições-alvo, em média sobre 20 repetições independentes por célula. Erros de quantil normalizados pela amplitude P_5 – P_{95} .

Distribuição	N	KS	$D(q p)$	Wasserstein	P_5 (%)	P_{50} (%)	P_{95} (%)
Normal	50	0,0659	0,0488	0,0877	5,55	3,37	7,18
	200	0,0366	0,0108	0,0512	3,59	2,04	2,27
	1.000	0,0158	0,0021	0,0228	1,43	0,74	1,34
	5.000	0,0059	0,0003	0,0129	0,46	0,28	0,53
Gumbel	50	0,0818	0,1047	0,1333	5,01	3,88	9,92
	200	0,0476	0,0623	0,0947	2,46	1,57	4,94
	1.000	0,0460	0,0941	0,0883	1,50	1,14	4,84
	5.000	0,0436	0,0963	0,0823	1,23	0,93	3,24
Uniforme	50	0,0720	0,0341	0,0208	3,48	5,73	2,92
	200	0,0324	0,0006	0,0099	1,16	2,41	1,39
	1.000	0,0175	0,0026	0,0051	0,82	1,12	0,65
	5.000	0,0066	0,0013	0,0029	0,21	0,48	0,21
Lognormal	50	0,0940	0,1238	0,0543	4,07	4,17	13,73
	200	0,0738	0,1584	0,0423	2,74	2,56	6,36
	1.000	0,0303	0,0481	0,0191	1,14	0,85	2,53
	5.000	0,0149	0,0149	0,0117	0,57	0,37	1,10

exatamente a distribuição-alvo, que independe de N . A inclinação medida discrimina as duas.

Para a Normal e a Uniforme obtiveram-se inclinações de $-0,52$ e $-0,50$, com $R^2 = 0,99$ em ambos os casos — estatisticamente indistinguíveis da taxa teórica $-1/2$. O erro observado é, portanto, integralmente de natureza amostral, sem parcela estrutural detectável: a GLD representa essas duas distribuições com a precisão que os dados permitirem. Em termos absolutos, em $N = 5.000$ a distância KS cai a $0,0059$ e $0,0066$, respectivamente, com erros de quantil abaixo de $0,55\%$ em toda a faixa P_5 – P_{95} . A Lognormal apresenta inclinação de $-0,42$, ligeiramente inferior, o que sinaliza uma pequena parcela não amostral, mas ainda converge de forma sustentada, alcançando $1,10\%$ no P_{95} . Esses três casos confirmam a capacidade da GLD de representar simultaneamente distribuições simétricas, assimétricas e de suporte compacto com um único conjunto de quatro parâmetros.

5.1.3 O limite estrutural da família GLD

O comportamento da distribuição de Gumbel merece destaque, e a Figura 6 o evidencia. Enquanto as demais distribuições decaem com inclinações entre $-0,42$ e $-0,52$, a curva da Gumbel estabiliza em torno de $KS \approx 0,044$ a partir de $N = 200$: sua inclinação medida é de apenas $-0,12$, e o baixo coeficiente de determinação da regressão ($R^2 = 0,68$) confirma que o decaimento sequer segue uma lei de potência. Trata-se, portanto, de um patamar *estrutural*, e não amostral: aumentar a amostra não reduz a discrepância porque a família GLD, com os parâmetros de forma ajustados, não representa exatamente a cauda exponencial da Gumbel.




Figura 6: Convergência da distância de Kolmogorov–Smirnov entre a GLD ajustada e a distribuição-alvo, em função do tamanho amostral. Eixos em escala logarítmica; cada ponto é a média de 20 repetições independentes.

A mesma leitura explica o comportamento do teste clássico de aderência. Nas 20 repetições, o teste KS de duas amostras não rejeitou a hipótese nula em nenhum caso para a Normal e para a Uniforme, em qualquer tamanho amostral. Para a Gumbel e a Lognormal, contudo, a taxa de rejeição a 5% cresceu de 0% em $N = 50$ para 30% em

$N = 5.000$. O aparente paradoxo — ajustes que melhoram enquanto o teste rejeita mais — é apenas o ganho de potência do teste: com amostras maiores, ele passa a detectar uma discrepância residual que permanece pequena em magnitude. **No Exemplo 5.2, a comparação das distribuições é apresentada por métricas de distância e erros de quantis, sem uma decisão de teste de hipótese.**

A origem desse limite é geométrica. Com $\lambda_3, \lambda_4 > 0$, a GLD-FKML tem suporte compacto, de modo que uma distribuição-alvo de suporte ilimitado é necessariamente aproximada por uma de caudas truncadas. Para a Gumbel ajustada em $N = 5.000$, por exemplo, obteve-se $\lambda_3 = 1,67$ e $\lambda_4 = 2,25$, com suporte $[-1,86; 34,42]$; já a Lognormal produziu $\lambda_4 = -0,04$, valor negativo que mantém a cauda direita ilimitada e explica sua convergência mais favorável. Essa constatação é relevante para a interpretação dos resultados de confiabilidade: a aproximação da GLD é excelente no corpo da distribuição e nos quantis usualmente empregados em decisões de manutenção, mas a acurácia na cauda extrema deve ser verificada caso a caso, e não presumida.

5.2 Exemplo 1: verificação em problema de referência

O problema de referência permite avaliar a representação da distribuição de resposta antes da aplicação ao concreto armado. Adota-se uma adaptação do exemplo de **pires2024** na qual a margem de segurança depende da resistência R , da solicitação S e das incertezas de modelo Z_1 e Z_2 :

$$g(R, S, t) = k_{\text{fator}}(t) \frac{R}{Z_1} - SZ_2. \quad (30)$$

A redução da resistência segue a expressão

$$k_{\text{fator}}(t) = \begin{cases} 1 + (k_{\text{final}} - 1) \frac{t}{T_f}, & 0 \leq t < T_f, \\ k_{\text{final}}, & t \geq T_f, \end{cases} \quad t \text{ em anos}, \quad (31)$$

com $k_{\text{final}} = 0,5$ e $T_f = 100$ anos, de modo que a capacidade cai linearmente até metade do valor íntegro ao final do horizonte. Essa magnitude é compatível com uma deterioração severa, ainda que a lei de decaimento permaneça idealizada. A retenção do valor terminal para $t \geq T_f$ é uma salvaguarda: sem ela, a extrapolação linear cruzaria zero em $t = T_f/(1 - k_{\text{final}})$ e inverteria o sinal da resistência, produzindo distribuições de resposta degeneradas, sem interpretação física e não representáveis por uma GLD válida. As variáveis de entrada estão descritas na Tabela 4. Esse exemplo representa uma perda idealizada de capacidade e serve à verificação do método. Sua lei de degradação não descreve os mecanismos de carbonatação ou corrosão do concreto armado.

Tabela 4: Variáveis do problema de referência.

Variável	Símbolo	Distribuição	Média	Desvio padrão
Resistência	R	Normal	5,00	0,80
Solicitação	S	Normal	2,00	0,60
Incerteza de modelo da resistência	Z_1	Lognormal	1,00	0,028
Incerteza de modelo da solicitação	Z_2	Lognormal	1,00	0,096

5.2.1 Configuração das simulações, representação da GLD e ganho computacional

A configuração atual utiliza 2.000 pontos de projeto para treinamento e 500 para validação, com 2.500 realizações de g geradas para cada par (R, S) a partir das variáveis latentes. Os quatro parâmetros da GLD são ajustados às amostras pelo PyGLAM, e os metamodelos PCE são construídos separadamente em cada uma das 5 idades igualmente espaçadas entre 0 e 100 anos. A qualidade desse ajuste, por parâmetro, é discutida na Seção 5.2.2, junto com o desempenho da camada temporal de aprendizado de máquina.

O ganho computacional foi avaliado pela razão entre o tempo do procedimento de referência e o tempo de predição do emulador PCE para o mesmo conjunto de 2.000 pontos de projeto, em cada uma das cinco idades:

$$S_{\text{comp}}(t) = \frac{T_{\text{ref}}(t)}{T_{\text{PCE}}(t)}. \quad (32)$$

O tempo T_{ref} soma a geração das amostras latentes, a avaliação do modelo numérico, a organização dos dados e o ajuste local da GLD. O tempo T_{PCE} corresponde à predição dos parâmetros para o lote de entradas, com o metamodelo já treinado e carregado. Portanto, a razão mede o ganho na obtenção dos parâmetros da distribuição em relação ao procedimento completo de referência, e não uma comparação com o tempo isolado de avaliação da função g .

Tabela 5: Tempos por lote de pontos de projeto e ganho computacional nas cinco idades avaliadas.

Tempo (anos)	Referência (s)	Emulador PCE (s)	Ganho (vezes)
0,00	936,209381	0,002231	419.549
25,00	954,884701	0,001499	637.069
50,00	905,878127	0,001637	553.220
75,00	870,398033	0,001492	583.323
100,00	798,989566	0,001436	556.504
Mediana	905,878127	0,001499	556.504

A última linha apresenta a mediana de cada coluna, estatística menos sensível ao valor mais baixo registrado em $t = 0$. A mediana do ganho é a mediana das cinco razões registradas, calculada antes do arredondamento; não é a razão entre os tempos medianos.

O procedimento de referência demandou, na mediana, 905,88 s por idade, enquanto

a predição pela PCE levou aproximadamente 1,50 ms. A mediana dos ganhos foi de $5,57 \times 10^5$ vezes, com valores entre $4,20 \times 10^5$ e $6,37 \times 10^5$.

Esses resultados mostram a redução do custo de consulta após a construção da PCE, o que favorece a avaliação repetida de cenários. O treinamento da PCE e o pós-processamento para amostragem, confiabilidade ou RUL não estão incluídos no tempo de predição. Além disso, o registro disponível contém uma cronometragem de predição por idade, sem repetições para estimar sua variabilidade. O ganho obtido caracteriza esse ensaio e não deve ser transferido diretamente para o modelo de durabilidade do concreto.

5.2.2 Camada temporal de aprendizado de máquina

A camada temporal utiliza as entradas (R, S, t) para prever os parâmetros λ_1 e λ_2 de forma contínua no tempo, dispensando o uso de uma PCE independente para cada instante. Os parâmetros de forma λ_3 e λ_4 não são preditos por essa camada, nem pela PCE nas comparações apresentadas neste trabalho: como mostra a Tabela 6, esses dois parâmetros controlam principalmente as caudas da GLD, variam pouco entre pontos de projeto e ao longo do tempo, e a PCE não os representa com precisão. Adotam-se, portanto, seus valores médios no conjunto de treinamento, $\lambda_3 = 0,142157$ e $\lambda_4 = 0,131525$, em toda comparação de distribuições apresentada neste trabalho.

Tabela 6: Erro quadrático médio (MSE) e coeficiente de determinação R^2 dos quatro parâmetros da GLD no conjunto de validação da PCE, por idade.

Tempo (anos)	MSE				R^2			
	λ_1	λ_2	λ_3	λ_4	λ_1	λ_2	λ_3	λ_4
0,00	0,000032	0,036096	0,000452	0,000413	0,999969	0,979504	0,002202	0,100693
25,00	0,000032	0,051272	0,000454	0,000469	0,999965	0,976717	0,065788	0,002610
50,00	0,000026	0,049197	0,000438	0,000383	0,999967	0,984233	0,015658	0,079338
75,00	0,000025	0,056486	0,000400	0,000399	0,999962	0,986619	-0,001781	0,060296
100,00	0,000022	0,063286	0,000419	0,000420	0,999960	0,989090	-0,018763	-0,008939

A predição de λ_1 tem R^2 acima de 0,9999 em todas as idades, com MSE da ordem de 10^{-5} , cerca de três ordens de grandeza menor que o de λ_2 . Para λ_2 , o R^2 fica entre 0,977 e 0,989, com leve melhora nas idades mais avançadas. Já λ_3 e λ_4 têm R^2 próximo de zero na maior parte da malha temporal, tornando-se negativo para λ_3 aos 75 e 100 anos e para λ_4 aos 100 anos: nesses casos, a média do conjunto de validação prediz g melhor que a própria PCE. Esse comportamento sustenta a escolha de um valor médio fixo para os dois parâmetros de forma, em vez de um metamodelo dedicado a cada um.

A Tabela 7 traz a mesma métrica para a rede neural global, treinada uma única vez sobre o conjunto agregado de todas as idades.

Tabela 7: Erro quadrático médio (MSE) e coeficiente de determinação R^2 de λ_1 e λ_2 no conjunto de validação da rede neural global.

MSE λ_1	R^2 λ_1	MSE λ_2	R^2 λ_2
0,000164	0,99989	0,00205	0,999454




Figura 7: Valor previsto versus valor real de λ_1 (esquerda) e λ_2 (direita) no conjunto de validação da rede neural global. A linha tracejada vermelha marca a identidade.

A rede neural reproduz λ_1 com qualidade equivalente à da PCE ($R^2 > 0,9998$) e supera a PCE na predição de λ_2 ($R^2 = 0,999454$, contra 0,977–0,989 por idade na PCE), apesar de ser um único modelo treinado sobre todas as idades simultaneamente, sem a informação discreta de qual PCE usar em cada instante. A Figura 7 confirma essa leitura: os pontos se mantêm próximos à identidade em toda a faixa de valores, com dispersão um pouco maior em λ_2 nos valores mais altos. O resultado é compatível com λ_2 variar suavemente com t : a camada temporal aproveita essa suavidade para interpolar entre os instantes discretos da PCE, em vez de ajustar cada idade isoladamente.

5.2.3 Propagação de incerteza: PCE versus rede neural

Esta seção compara diretamente a PCE e a rede neural quanto à propagação de incerteza de g , no mesmo ponto de projeto ($R = 5,394$, $S = 2,305$, pertencente ao conjunto de treinamento) e nas mesmas duas idades, $t = 50$ e $t = 100$ anos, com $\lambda_3 = 0,142157$ e $\lambda_4 = 0,131525$ fixados para os dois modelos. A densidade de referência é estimada por KDE sobre as amostras brutas de g desse ponto, e comparada à GLD reconstruída a partir dos parâmetros emulados por cada modelo, pelas métricas da Seção 4.2.3: divergência KL, estatística KS, distância de Wasserstein, R^2 entre densidades e erros relativos de quantil. Por se tratar de um único ponto de projeto, o resultado não generaliza o comportamento dos dois modelos no espaço (R, S, t) , mas fornece uma estimativa direta de como cada um se comporta nesse ponto específico.




Figura 8: Densidades de referência e emuladas para $R = 5,394$ e $S = 2,305$, nas idades de 50 e 100 anos: PCE (esquerda) e rede neural (direita). A linha cheia representa a KDE das amostras do conjunto de dados e a linha tracejada representa a GLD emulada, com os parâmetros de forma fixados.

Tabela 8: Métricas de propagação de incerteza para a PCE e para a rede neural, no mesmo ponto de projeto, em duas idades.

Métrica	PCE		Rede neural	
	$t = 50$	$t = 100$	$t = 50$	$t = 100$
Divergência KL	0,00374	0,00366	0,00351	0,00318
Estatística KS	0,01840	0,01400	0,01800	0,01960
Distância de Wasserstein	0,00540	0,00701	0,00529	0,00740
R^2 entre densidades	0,99791	0,99753	0,99801	0,99551
Erro relativo em P_5 (%)	-0,47	+10,91	-0,61	-46,78
Erro relativo em P_{50} (%)	-0,16	+0,32	-0,16	-2,05
Erro relativo em P_{95} (%)	+0,18	+1,11	+0,27	-0,18

Aos 50 anos, PCE e rede neural têm desempenho equivalente e igualmente bom: divergência KL de 0,00374 e 0,00351, R^2 acima de 0,997 para ambas, e erros de quantil abaixo de 1% nos três percentis avaliados. As duas curvas praticamente se sobrepõem à KDE de referência na Figura 8.

Aos 100 anos, a divergência KL e o R^2 entre densidades ainda favorecem discretamente a rede neural (0,00318 e 0,99551, contra 0,00366 e 0,99753 da PCE). Aqui o R^2 da PCE é o maior dos dois, o oposto do que ocorre na divergência KL, o que já sinaliza que essas duas métricas agregadas não contam a mesma história dos quantis. O erro relativo em P_5 dispara para os dois modelos, mas de forma assimétrica: +10,91% na PCE contra -46,78% na rede neural. Esse salto não indica necessariamente um colapso do ajuste: aos 100 anos o percentil P_5 do conjunto de referência está próximo de zero (Figura 8, cauda inferior da distribuição à esquerda), de modo que um pequeno desvio absoluto do quantil emulado se traduz em um erro percentual muito maior que nas demais métricas. Ainda assim, a rede neural erra por uma margem consideravelmente maior que a PCE nesse

ponto específico, o que é relevante porque a cauda inferior de g é justamente a região que governa a probabilidade de falha.

Em conjunto, os dois ensaios sugerem que a rede neural iguala ou supera a PCE na qualidade agregada da densidade (KL, R^2 , Wasserstein), mas pode ser menos confiável que a PCE especificamente na cauda inferior em idades mais avançadas. Um único ponto de projeto não permite afirmar se isso é uma característica sistemática do modelo global ou uma particularidade deste ponto e desta idade. **[FALTA: Repetir esta comparação em outros pontos de projeto e idades para verificar se a maior sensibilidade da rede neural na cauda inferior em $t = 100$ é sistemática.]**

5.2.4 Vida útil remanescente

Para este exemplo, adota-se um limiar de intervenção em $g = 0,7$, definido apenas para fins de ilustração do método, sem correspondência com um critério normativo específico. O fim da vida útil é tomado como o primeiro instante em que g cruza esse limiar, e não necessariamente $g = 0$: na prática, uma intervenção de manutenção é programada enquanto ainda resta margem de segurança, não apenas quando o estado limite já foi atingido.




Figura 9: Comportamento de $g(t)$ para $R = 5,0$ e $S = 2,0$ (valores médios das variáveis de entrada): (a) 300 das 50.000 trajetórias simuladas, com a média (vermelho); (b) densidade de g em seis idades entre 0 e 100 anos. O limiar de intervenção $g = 0,7$ é indicado em ambos os painéis (tracejado).

Cada trajetória do painel (a) é comonotônica: um único nível de quantil u é sorteado por trajetória e mantido fixo ao longo do tempo, de modo que $g_i(t) = Q(u_i; \hat{\lambda}(t))$, o que garante trajetórias monotonicamente decrescentes, compatíveis com um processo de degradação. Amostrarmos cada instante de forma independente produziria, em vez disso, trajetórias que oscilam livremente. A dispersão entre trajetórias cresce com o tempo, refletindo o aumento da incerteza acumulada na predição de λ_1 e λ_2 pela camada temporal, e a média cruza o limiar por volta de $t = 91$ anos. O painel (b) mostra a mesma degradação

sob outro ângulo: a densidade de g se desloca gradualmente para a esquerda, e por $t = 100$ anos seu corpo já ultrapassou o limiar.




Figura 10: Distribuição do tempo até o cruzamento do limiar $g = 0,7$, para $R = 5,0$ e $S = 2,0$: (a) a partir de $t = 0$; (b) vida útil remanescente condicionada à sobrevivência em $t = 50$ anos, $RUL = T - t_{\text{insp}}$. Ambas as densidades são truncadas no maior valor alcançável dentro do horizonte simulado de 100 anos.

A distribuição do painel (a) tem média de 91,32 anos, mediana de 92,18 anos, desvio padrão de 7,13 anos e $P_5 = 78,19$ anos, com 16,4% das trajetórias censuradas em $t = 100$ anos. O pico estreito junto a esse limite corresponde a essa censura, não a um comportamento intrínseco da distribuição. Como nenhuma trajetória cruza o limiar antes de $t = 50$ anos (valor obtido por interpolação linear entre os instantes simulados, que não incluem $t = 50$ diretamente), todas as 50.000 sobrevivem até esse instante, e a RUL condicional do painel (b) é a mesma distribuição do painel (a), apenas deslocada em 50 anos: média de 41,32 anos, mediana de 42,18 anos e $P_{95} = 50,00$ anos, o próprio limite do horizonte alcançável a partir desse instante.

5.3 Exemplo 2 — RUL probabilística de viga de concreto armado sob carbonatação

Verificado o arcabouço, aplica-se o emulador ao problema-alvo: a previsão da vida útil remanescente de uma viga de concreto armado sujeita à corrosão induzida por carbonatação, com a função de estado limite da Equação (19) e o modelo de carbonatação da Seção 2.4.

5.3.1 Definição do problema

A viga analisada possui seção retangular com os parâmetros geométricos e mecânicos da Tabela 9 e a caracterização probabilística das variáveis aleatórias da Tabela 10. **[FALTA: revisar/ajustar os valores determinísticos conforme o caso final simulado]**

Tabela 9: Parâmetros determinísticos da viga analisada.

Parâmetro	Símbolo	Valor
Largura da seção	b_w	[FALTA: ex.: 0,14 m]
Altura total	h	[FALTA: ex.: 0,40 m]
Altura útil	$d = 0,90 h$	[•]
Diâmetro nominal das barras	d_{s0}	12,5 mm
Número de barras	n_b	[•]
Resistência característica do aço	f_{yk}	500 MPa
Módulo de elasticidade do aço	E_s	200 GPa
Horizonte de análise	T_f	[FALTA: ex.: 100 anos]

Tabela 10: Variáveis aleatórias do Exemplo 2. [FALTA: confirmar distribuições e parâmetros; sugestões baseadas em jc2001<empty citation>]

Variável	Símbolo	Distribuição	Média	
Resistência do concreto	f_c	Lognormal	[FALTA: 30 MPa]	[FA
Cobrimento nominal	c_{nom}	Normal	[FALTA: 25 mm]	[FA
Coef. de carbonatação	k	Lognormal	[FALTA: $k_{30} = 3,8 \text{ mm}/\sqrt{\text{ano}}$]	[FA
Taxa de corrosão a 20°C	$i_{corr,20}$	Lognormal	[FALTA: 0,431 $\mu\text{A}/\text{cm}^2$]	[FA
Temperatura ambiente	T	Normal	[FALTA: 23,6 °C]	[FA
Momento das ações permanentes	M_{Gk}	Normal	[FALTA: 12,0 kN·m]	[FA
Momento das ações variáveis	M_{Qk}	Gumbel	[FALTA: 8,0 kN·m]	[FA
Incerteza de modelo (resistência)	Z_R	Lognormal	1,00	[FA

5.3.2 Treinamento do emulador

O plano de experimentos foi gerado por LHS com $M = 100$ pontos no espaço das variáveis da Tabela 10, avaliados nos passos de tempo 0, 10, 20, 30, 40, 50, 60, 70, 80, 90, 100, 110, 120, 130, 140, 150 anos, com $N = 1.000$ réplicas das variáveis latentes por ponto. Os parâmetros locais $\hat{\lambda}^{(j,m)}$ foram ajustados via PyGLAM, sendo o parâmetro de testes de 80% dos dados para treinamento e 20% para teste, e a análise exploratória de sensibilidade confirmou a baixa variabilidade de λ_3 e λ_4 observada no Exemplo 1. O regressor temporal foi selecionado por comparação entre Redes Neurais, Gradient Boosting, Floresta aleatória e Árvore de decisão com hiperparâmetros otimizados por validação cruzada 10-dobras; a Tabela 11 resume o desempenho.

Tabela 11: Comparação de regressores para a camada temporal (Exemplo 2).

Regressor	$R^2 (\lambda_1)$	$R^2 (\lambda_2)$	Tempo de treino (s)
Rede neural (MLP)	1.00	1.00	56.2
Floresta aleatória	0.99	0.99	1.3
Gradient Boosting	0.99	0.99	7.4
Árvore de Decisão	0.98	0.97	0.2

5.3.3 Validação em instantes não vistos

O teste crítico da emulação temporal consiste em prever a distribuição de g em anos *deliberadamente excluídos do treinamento* — adotaram-se $t^* = \text{[FALTA: ex.: 35]}$ e $t^* = \text{[FALTA: ex.: 65]}$ anos — e compará-la ao Monte Carlo direto do simulador nesses instantes. A Figura 11 sobrepõe as densidades emuladas e de referência, e a Tabela 12 reporta as métricas da Seção 4.2.3, com destaque para a cauda inferior ($g \leq 0$), região que governa a probabilidade de falha.

[FALTA: figura: PDFs emuladas vs. Monte Carlo nos anos não vistos (2 painéis), com a região $g \leq 0$ destacada]

Figura 11: Validação do emulador temporal em instantes não utilizados no treinamento: PDF emulada vs. Monte Carlo direto. **[FALTA: inserir figura]**

Tabela 12: Métricas de validação do emulador em instantes não vistos (Exemplo 2). **[FALTA: preencher]**

Instante	KS (valor-p)	Wasserstein	$D(p q)$	Erro P_5 (%)	Erro em p_f (%)
$t^* = \text{[•]} \text{ anos}$	[•]	[•]	[•]	[•]	[•]
$t^* = \text{[•]} \text{ anos}$	[•]	[•]	[•]	[•]	[•]

5.3.4 Evolução da confiabilidade e RUL probabilística

A Figura 12 apresenta a evolução de $p_f(t)$ e do índice de confiabilidade $\beta(t)$ ao longo do horizonte de análise, calculados pela Equação (27) a custo desprezível, com pontos de verificação por Monte Carlo direto em **[FALTA: 2–3 anos-âncora]** confirmando a acurácia. Observa-se **[FALTA: descrever: instante de despassivação média, ponto em que β cruza o alvo normativo, taxa de degradação]**.

[FALTA: figura: $\beta(t)$ e $p_f(t)$ emulados (linha contínua) com marcadores de Monte Carlo nos anos-âncora; linha horizontal em $\beta_{\text{alvo}} = 1,5$]

Figura 12: Evolução temporal do índice de confiabilidade e da probabilidade de falha (Exemplo 2). **[FALTA: inserir figura]**

A partir das trajetórias contínuas de $\hat{g}$, obtêm-se a distribuição do tempo até a falha e a distribuição de RUL para o instante de inspeção $t_{\text{insp}} = \text{[FALTA: ex.: 40]}$ anos (Figura 13). As estatísticas-resumo constam da Tabela 13. **[FALTA: repetir a análise para um segundo instante de inspeção (ex.: 20 anos) para mostrar a dependência da RUL em relação à idade da estrutura]**

[FALTA: figura com 3 painéis lado a lado: (a) PDF de g em t_{insp} ; (b) PDF do tempo até a falha; (c) PDF da RUL]

Figura 13: Resultados probabilísticos de RUL para a viga sob carbonatação. **[FALTA: inserir figura]**

Tabela 13: Estatísticas da distribuição de RUL (Exemplo 2, $t_{\text{insp}} = [\bullet]$ anos). **[FALTA: preencher]**

Estatística	Valor (anos)
$E[\text{RUL}]$	$[\bullet]$
Mediana	$[\bullet]$
P_5	$[\bullet]$
$\text{VaR}_{5\%}$	$[\bullet]$
$\text{CVaR}_{5\%}$	$[\bullet]$

5.3.5 Análise de sensibilidade e custo computacional

Os índices de Sobol de primeira ordem e totais, obtidos analiticamente dos coeficientes da PCE (sudret2008), quantificam a contribuição de cada variável de entrada para a variância de λ_1 (locação de g) ao longo do tempo (Figura 14). **[FALTA: descrever os resultados: espera-se dominância do cobrimento e do coeficiente de carbonatação na fase de iniciação, com crescimento da importância de i_{corr} na propagação]**. Por fim, a Tabela 14 consolida o custo computacional: o orçamento total de avaliações do simulador para o treinamento foi de $M \times N \times N_t = [\bullet]$ execuções, contra **[FALTA: valor]** execuções exigidas por Monte Carlo direto para a mesma acurácia em p_f ao longo do horizonte, com tempo de predição *online* de **[FALTA: valor]** segundos por cenário completo de RUL.

[FALTA: figura: índices de Sobol por variável, em barras, para 2–3 instantes (ex.: 20, 50, 80 anos)]

Figura 14: Índices de sensibilidade de Sobol das variáveis de entrada (Exemplo 2). **[FALTA: inserir figura]**

Tabela 14: Custo computacional do Exemplo 2. **[FALTA: preencher]**

	Monte Carlo direto	Emulador
Avaliações do simulador	$[\bullet]$	$[\bullet]$
Tempo total (s)	$[\bullet]$	$[\bullet]$
Tempo de predição <i>online</i> (s)	—	$[\bullet]$
<i>Speed-up</i>	$[\bullet] \times$	

5.4 Exemplo 3 — Cenário com intervenção de manutenção

O terceiro exemplo demonstra a utilidade prática do emulador para o suporte à decisão de manutenção, retomando a viga do Exemplo 2 e introduzindo uma intervenção que recupera a margem de segurança, conforme o modelo da Seção 4.3.3.

5.4.1 Cenários analisados

Consideram-se: (i) o cenário de referência sem manutenção (Exemplo 2); (ii) cenários com intervenção única em $t_{\text{man}} \in \{[\text{FALTA: ex.: 30, 40, 50}]\}$ anos, com eficácia de reparo $\rho = [\text{FALTA: ex.: 0,95}]$ e coeficiente de carbonatação do material de reparo $k_{\text{rep}} = [\text{FALTA: valor/hipótese}]$; e (iii) o cenário com intervenção no instante normativo t_{man}^* da Equação (29), determinado diretamente da curva $\beta(t)$ emulada para $\beta_{\text{alvo}} = 1,5$ (fib2006). Destaca-se que a avaliação de cada cenário adicional exigiu apenas $[\text{FALTA: valor}]$ segundos de pós-processamento do emulador, sem qualquer nova execução do simulador original — precisamente o tipo de varredura de cenários que é intratável via Monte Carlo direto.

5.4.2 Trajetórias e ganho de vida útil

A Figura 15 apresenta a evolução da média e das bandas de credibilidade (quantis P_5 – P_{95}) da margem de segurança para os cenários com e sem manutenção, evidenciando o característico formato dente de serra: a queda progressiva de g até t_{man} , a recuperação parcial promovida pelo reparo e o novo ciclo de degradação no material recomposto.

[FALTA: figura: trajetórias de $g(t)$ (média e banda P_5 – P_{95}) com e sem manutenção, no mesmo eixo; marcar t_{man} e a linha $g = 0$]

Figura 15: Evolução da margem de segurança com e sem intervenção de manutenção (formato dente de serra). **[FALTA: inserir figura]**

A Figura 16 compara as distribuições de RUL com e sem manutenção para o instante de inspeção $t_{\text{insp}} = [\text{FALTA: valor}]$ anos, e a Tabela 15 consolida as estatísticas para todos os cenários, incluindo o ganho probabilístico de vida útil ΔRUL (Eq. 28) e o efeito do instante de intervenção sobre as métricas de risco. **[FALTA: descrever os resultados: espera-se que intervenções mais precoces produzam maior ΔRUL esperado, mas com retornos decrescentes; comentar o deslocamento do $\text{VaR}_{5\%}$, que é a métrica de decisão conservadora]**

[FALTA: figura: PDFs de RUL sobrepostas (sem manutenção vs. com manutenção em t_{man}^*), com $\text{VaR}_{5\%}$ de cada cenário marcado]

Figura 16: Distribuições de RUL com e sem intervenção de manutenção. **[FALTA: inserir figura]**

Tabela 15: Comparação dos cenários de manutenção (Exemplo 3). **[FALTA: preencher]**

Cenário	$\mathbb{E}[\text{RUL}]$ (anos)	$\text{VaR}_{5\%}$ (anos)	$\text{CVaR}_{5\%}$ (anos)	ΔRUL médio (anos)	t até β_{alvo} (anos)
Sem manutenção	[•]	[•]	[•]	—	[•]
$t_{\text{man}} = [\bullet]$	[•]	[•]	[•]	[•]	[•]
$t_{\text{man}} = [\bullet]$	[•]	[•]	[•]	[•]	[•]
$t_{\text{man}} = t_{\text{man}}^* = [\bullet]$	[•]	[•]	[•]	[•]	[•]

5.4.3 Discussão geral

[FALTA: síntese crítica dos três exemplos, cobrindo: (i) acurácia do emulador no problema real vs. benchmark; (ii) limitações observadas — comportamento nas caudas extremas, hipótese de unimodalidade da GLD, validade da interpolação apenas DENTRO do horizonte treinado (não extrapolar além de t_{N_t}); (iii) sensibilidade dos resultados de manutenção às hipóteses de ρ e k_{rep} ; (iv) comparação qualitativa com alternativas (SPCE, GP heteroscedástico, emulação direta de $\beta(t)$) e por que emular a distribuição completa agrega valor para RUL]

6. Conclusões

Este trabalho propôs um emulador estocástico dependente do tempo para a previsão probabilística da vida útil remanescente de estruturas de concreto armado sujeitas à corrosão induzida por carbonatação. O arcabouço aproxima a distribuição condicional completa da função de estado limite $g(\mathbf{X}, t)$ por meio da Distribuição Lambda Generalizada, cujos parâmetros são representados por Expansões em Caos Polinomial das variáveis de entrada e interpolados continuamente no tempo por um modelo de aprendizado de máquina. As principais conclusões são as seguintes:

1. **Acurácia da emulação distribucional.** No problema de referência, o emulador reproduziu a distribuição da margem de segurança com erro relativo inferior a 0,5% até o percentil 99, com discrepâncias confinadas à cauda extrema (cerca de 1,3% no quantil 99,9%), conforme atestado pelos testes de Kolmogorov–Smirnov e pela comparação de quantis. No problema da viga sob carbonatação, **[FALTA: resumir as métricas obtidas no Exemplo 2, em particular o erro em p_f e nos instantes não vistos]**;
2. **Generalização temporal.** A camada de aprendizado de máquina sobre os parâmetros da GLD atuou como interpolador contínuo da distribuição entre os instantes simulados, com R^2 superior a 0,98 para os parâmetros sensíveis e **[FALTA: reportar**

o desempenho nos anos omitidos do treinamento (teste de generalização temporal)], sustentando a alegação de emulação dependente do tempo;

3. **Eficiência computacional.** O emulador reduziu o custo da análise em quase duas ordens de grandeza no problema de referência (48,75 s vs. 0,66 s) e em **[FALTA: valor]** no problema da viga, viabilizando a varredura de cenários de inspeção e manutenção em tempo quase real;
4. **RUL probabilística e suporte à decisão.** A leitura direta da distribuição emulada em termos de tempo até a falha forneceu a distribuição completa da RUL e suas métricas de risco (VaR e CVaR), e o cenário com intervenção de manutenção demonstrou a capacidade do arcabouço de quantificar o ganho probabilístico de vida útil ($\Delta RUL = \text{[FALTA: valor]}$ anos para intervenção no instante normativo $\beta_{alvo} = 1,5$) a custo de pós-processamento desprezível.

Entre as limitações do estudo, destacam-se: a hipótese de unimodalidade da resposta inerente à GLD; a validade da interpolação temporal restrita ao horizonte de treinamento, sem garantia de extrapolação; a dependência dos resultados do Exemplo 3 em relação às hipóteses de eficácia do reparo (ρ) e de desempenho do material de recomposição (k_{rep}); e a adoção de um único mecanismo de degradação, sem interação com cloretos ou fadiga.

Como trabalhos futuros, vislumbram-se: (i) a atualização bayesiana do emulador com dados de inspeção em serviço, permitindo o refinamento da RUL ao longo da vida da estrutura; (ii) a incorporação de variabilidade espacial por campos aleatórios; (iii) a comparação sistemática com emuladores estocásticos alternativos, como as expansões em caos polinomial estocásticas (SPCE) e processos gaussianos heteroscedásticos; (iv) a extensão para otimização completa de manutenção sob critério de custo de ciclo de vida, com custos de inspeção, reparo e falha; e (v) a aplicação do arcabouço a estruturas reais monitoradas, integrando-o a sistemas de gestão de obras de arte especiais.

Conflitos de interesse

Os autores declaram não haver conflitos de interesse.

Contribuição dos autores

Victor Hugo Moreira do Couto Souza: **[FALTA: Conceituação, Metodologia, Software, Redação (rascunho)]**. Wanderlei Malaquias Pereira Junior: **[FALTA: Concepção, Supervisão, Redação (revisão e edição)]**. Marcos Luiz Henrique: **[FALTA: Software, Validação]**. Renata Maria Pensin: **[FALTA: Investigação, Visualização]**. Ketson dos Santos: **[FALTA: Metodologia, Supervisão]**.

Financiamento

[FALTA: citar todas as fontes de financiamento com os respectivos números de processo (ex.: CNPq, CAPES, FAPEG); se não houver, declarar explicitamente]

Disponibilidade de dados

[FALTA: informar onde e sob quais condições os dados e o código (PyGLAM) podem ser acessados — ex.: repositório público com DOI]

Agradecimentos

[FALTA: agradecer pessoas e instituições que auxiliaram na preparação do manuscrito]

Apêndice A. Exemplo de verificação para um passo de tempo

Este apêndice detalha, para um único passo de tempo e uma única simulação, o procedimento de cálculo da margem de segurança $g(t)$ descrito na Seção ??, a fim de tornar transparente a sequência de operações do simulador. A viga considerada segue os parâmetros da Seção 5.3, com cobrimento nominal $c_{\text{nom}} = 25$ mm, diâmetro nominal das barras $d_{s0} = 12,5$ mm e coeficiente de carbonatação $k = 6$ mm/ $\sqrt{\text{ano}}$.

Considere o passo de tempo $t = 40$ anos, com temperatura ambiente $T = 23,56$ °C, taxa de corrosão a 20 °C igual a $i_{\text{corr},20} = 0,431$ $\mu\text{A}/\text{cm}^2$ e início da corrosão em $t_{\text{ini}} = 25$ anos.

A.1 Verificação da carbonatação

$$y_{\text{carb}}(40) = 6\sqrt{40} = 37,95 \text{ mm.} \quad (\text{A1})$$

Como $y_{\text{carb}}(40) > c_{\text{nom}} = 25$ mm, considera-se que já ocorreu o início da corrosão.

A.2 Taxa de corrosão ajustada

Pela Equação (?), com $T > 20$ °C ($K = 0,073$):

$$i_{\text{corr}}(23,56) = 0,431 [1 + 0,073 (23,56 - 20)] = 0,542 \mu\text{A}/\text{cm}^2. \quad (\text{A2})$$

A.3 Perda de diâmetro e área efetiva

Com $t_{\text{corr}} = 40 - 25 = 15$ anos, a Equação (??) fornece

$$d_s(40) = 12,5 - 0,0232 \times 0,542 \times 15 = 12,3114 \text{ mm}, \quad (\text{A3})$$

de modo que a área da barra corroída, pela Equação (??) (por barra), é

$$\frac{\pi}{4} d_s(40)^2 = \frac{\pi}{4} (12,3114)^2 = 119,06 \text{ mm}^2, \quad (\text{A4})$$

ante $A_{s,0} = 122,72 \text{ mm}^2$ da barra íntegra ($d_{s0} = 12,5 \text{ mm}$), uma redução de $3,66 \text{ mm}^2$ por barra.

A.4 Momento resistente degradado e coeficiente de aderência

Recompondo o equilíbrio seccional (Equação ??) com a área corroída, obtém-se $M_{Rd}(40) = 34,82 \text{ kN}\cdot\text{m}$. O coeficiente redutor de aderência, pela Equação (??), é

$$C_f = \frac{5,0}{12,5^{0,54} [(0,542/1000) \cdot 15 \cdot 365]^{0,19}} = 0,873, \quad (\text{A5})$$

resultando, pela Equação (??), em

$$M_{Rd,\text{cor}}(40) = C_f \cdot M_{Rd}(40) = 0,873 \times 34,82 = 30,39 \text{ kN} \cdot \text{m}. \quad (\text{A6})$$

A.5 Margem de segurança

Com os momentos solicitantes $M_{Gk} = 12,0 \text{ kN}\cdot\text{m}$ e $M_{Qk} = 8,0 \text{ kN}\cdot\text{m}$, o momento solicitante total é $M_S = 20,0 \text{ kN}\cdot\text{m}$, e a margem de segurança (Equação 19) torna-se

$$g(40) = M_{Rd,\text{cor}}(40) - M_S = 30,39 - 20,0 = 10,39 \text{ kN} \cdot \text{m}. \quad (\text{A7})$$

O resultado positivo indica que, aos 40 anos, mesmo considerando a corrosão, a seção ainda possui capacidade resistente superior às solicitações atuantes. Este cálculo é repetido para todos os instantes da simulação e para todas as amostras estocásticas, constituindo o simulador cujo custo o emulador da Seção 3 busca contornar.

Apêndice B. Material suplementar

[FALTA: candidatos a material suplementar/apêndice: (i) métricas complementares de validação da PCE nos 10 instantes da Tabela 6; (ii) equações dos três trechos da regressão por partes do CO₂; (iii) hiperparâmetros finais da RNA]