Previsão da vida útil remanescente de estruturas de concreto armado sujeitas à corrosão induzida por carbonatação por meio de emuladores estocásticos

Forecasting the Remaining Useful Life of Reinforced Concrete Structures Subjected to Carbonation-Induced Corrosion Using Stochastic Emulators

Victor Hugo Moreira do Couto Souza

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

Wanderlei Malaquias Pereira Junior (Autor correspondente)

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

University of Minnesota, Minneapolis, MN 55455, Estados Unidos

wanderlei.malaquias.pereira.jr@gmail.com

Marcos Luiz Henrique

Núcleo Interdisciplinar de Ciências Exatas e da Natureza (NICEN/CAA)

Universidade Federal de Pernambuco (UFPE), Caruaru, 55014-900, Pernambuco, Brasil

marcos.henrique@ufpe.br

Renata Maria Pensin

Universidade Federal de Catalão (UFCAT), Catalão, 75701-180, Goiás, Brasil

Ketson dos Santos

CEGE — Department of Civil, Environmental, and Geo-Engineering, University of Minnesota, Minneapolis, MN 55455, Estados Unidos

Resumo

A previsão probabilística da vida remanescente de elementos de concreto armado sob carbonatação pode apoiar o planejamento de inspeções e de manutenção preventiva. Este trabalho apresenta um emulador estocástico dependente do tempo que aproxima a distribuição condicional da margem entre o cobrimento e a profundidade carbonatada por uma Distribuição Lambda Generalizada. Seus parâmetros são representados por Expansões em Caos Polinomial em idades discretas, e uma camada de redes neurais permite consultar a distribuição entre essas idades. O procedimento é verificado em um problema idealizado de resistência e solicitação e aplicado a um elemento de concreto armado com variabilidade de resistência, umidade e cobrimento, sob a trajetória de CO_2 SSP2-4.5. A partir das distribuições emuladas, constroem-se trajetórias por acoplamento quantílico e estimam-se os tempos até a despassivação e até limiares preventivos. A comparação de margens de zero a 12 mm permite avaliar o efeito do critério de intervenção sobre os prazos, considerando a censura no horizonte de 100 anos. **[FALTA: Completar o resumo**

com as métricas de acurácia, custo e vida remanescente dos exemplos de durabilidade após a conclusão das simulações.]

Palavras-chave: vida útil remanescente; carbonatação; emulador estocástico; distribuição lambda generalizada; confiabilidade dependente do tempo; concreto armado.

Keywords: remaining useful life; carbonation; stochastic emulator; generalized lambda distribution; time-dependent reliability; reinforced concrete.

Nomenclatura

Modelos físicos — carbonatação e corrosão

$y(t)$	Profundidade da frente de carbonatação no instante t (mm)
k	Coeficiente de carbonatação (mm/$\sqrt{\text{ano}}$)
CO_2	Concentração volumétrica de CO_2 no ambiente (%)
ad	Teor de adição pozolânica em relação à massa de cimento (%)
k_c, k_{fc}, k_{ad}	Coeficientes do modelo de carbonatação: cimento, resistência e adições
k_{CO_2}, k_{UR}, k_{ce}	Coeficientes do modelo de carbonatação: CO_2, umidade e exposição
c_{nom}	Cobrimento nominal da armadura (mm)
t_{ini}	Instante de iniciação da corrosão (anos)
t_{corr}	Período de propagação, $t_{\text{corr}} = t - t_{\text{ini}}$ (anos)
f_c	Resistência a compressão do concreto (MPa)
UR	Umidade relativa do ar (%)
i_{corr}	Densidade de corrente de corrosão (μA/cm^2)
d_{s0}, $d_s(t)$	Diâmetro inicial e residual das barras (mm)
$A_s(t)$	Area efetiva de armadura no instante t (mm^2)
C_f	Coeficiente redutor de aderência aço–concreto

Resistência e estado limite

$M_{Rd,0}$	Momento resistente da seção íntegra (kN·m)
$M_{Rd,\text{cor}}(t)$	Momento resistente degradado no instante t (kN·m)
M_S	Momento solicitante característico total (kN·m)
$g(\mathbf{X}, t)$	Função de estado limite (margem de segurança)
$\mathbf{X}$	Vetor de variáveis aleatórias de entrada
$T(\mathbf{x})$	Tempo até a falha (anos)

Emulador estocástico

$\mathcal{M}_S$	Simulador estocástico
$Q(u)$	Função quantílica da Distribuição Lambda Generalizada
$\boldsymbol{\lambda} = \{\lambda_1, \ldots, \lambda_4\}$	Parâmetros da GLD (locação, escala, forma)
$\Psi_{\boldsymbol{\alpha}}$	Polinômios ortonormais multivariados da PCE

$a_{i,\boldsymbol{\alpha}}$	Coeficientes da PCE
$\mathcal{M}_{ML}$	Regressor de aprendizado de máquina (camada temporal)
M, N, N_t	Número de pontos do DoE, réplicas e passos de tempo

Confiabilidade, RUL e risco

$p_f(t)$	Probabilidade de falha dependente do tempo
$\beta(t)$	Índice de confiabilidade generalizado
$R(t)$	Função de confiabilidade (probabilidade de sobrevivência)
$\mathrm{RUL}(t_{\mathrm{insp}})$	Vida útil remanescente condicionada a inspeção
VaR_α	*Value-at-Risk* ao nível α
CVaR_α	*Conditional Value-at-Risk* ao nível α

Siglas

RUL	*Remaining Useful Life* (vida útil remanescente)
GLD	Distribuição Lambda Generalizada
GLaM	*Generalized Lambda Model*
PCE	Expansão em Caos Polinomial
ML	Aprendizado de Máquina (*Machine Learning*)
RNA	Rede Neural Artificial
MoM	Método dos Momentos
LHS	Amostragem por Hipercubo Latino
KS / AD	Testes de Kolmogorov–Smirnov / Anderson–Darling

1. Introdução

As estruturas de concreto armado constituem a espinha dorsal dos sistemas de infraestrutura crítica; entretanto, sua durabilidade a longo prazo é fortemente afetada por mecanismos de degradação, dentre os quais se destaca a corrosão das armaduras induzida pela carbonatação. A carbonatação reduz a alcalinidade do concreto, viabilizando o início da corrosão e a perda progressiva de capacidade resistente, o que pode comprometer a segurança, a funcionalidade e o desempenho ao longo do ciclo de vida (**tuutti1982**; **possan2010**). À medida que as redes de infraestrutura envelhecem e os recursos de manutenção se tornam cada vez mais restritos, a capacidade de prever com acurácia a vida útil remanescente (*Remaining Useful Life* – RUL) de estruturas de concreto armado tornou-se um desafio central da engenharia estrutural e da gestão de ativos informada por risco (**ellingwood2005**; **frangopol2011**; **si2011**).

As abordagens tradicionais de previsão de vida útil apoiam-se em modelos físicos de profundidade de carbonatação e em formulações determinísticas de estado limite. Embora tais modelos forneçam valiosa compreensão mecanicista, eles frequentemente não capturam os efeitos combinados da variabilidade dos materiais, da incerteza ambiental, da

deterioração estocástica e do erro epistêmico de modelo (**possan2010**; **melchers2018**). Os avanços recentes em modelagem probabilística de durabilidade têm, portanto, enfatizado a integração entre quantificação de incertezas, processos estocásticos de deterioração e calibração orientada por dados (**jcss2001**; **fib2006**).

Em paralelo, técnicas de aprendizado de máquina (*Machine Learning* – ML) e de metamodelagem têm recebido crescente atenção para a previsão da profundidade de carbonatação, da degradação estrutural e do desempenho ao longo do ciclo de vida de sistemas de concreto armado. Em trabalho anterior deste grupo, modelos de ML foram treinados para reproduzir a profundidade de carbonatação prevista por um modelo paramétrico de referência, evidenciando a forte não linearidade do fenômeno e a superioridade dos regressores não lineares sobre formulações de regressão convencionais (**couto2025**). Contudo, modelos puramente orientados por dados costumam apresentar capacidade limitada de extrapolação, baixa interpretabilidade e sensibilidade à escassez de dados de treinamento, o que restringe sua aplicação direta em avaliações de confiabilidade de sistemas críticos.

No contexto da quantificação de incertezas, metamodelos consolidados como os Processos Gaussianos (GP) (**rasmussen2006**) e as Expansões em Caos Polinomial (PCE) (**xiu2002**; **blatman2011**) são padrão para simuladores *determinísticos*, nos quais uma única avaliação caracteriza a resposta. Esses metamodelos, entretanto, não podem ser aplicados diretamente a *simuladores estocásticos*, nos quais a resposta para um mesmo vetor de entrada é uma variável aleatória cuja distribuição precisa ser caracterizada. Essa é exatamente a natureza do problema de degradação por carbonatação: para uma mesma configuração de projeto, variáveis latentes de material e de ambiente produzem uma distribuição de margens de segurança, e não um valor único. Para esse cenário, foram propostos recentemente os emuladores estocásticos, com destaque para os modelos *Generalized Lambda Models* (GLaM), nos quais a distribuição condicional da resposta é aproximada pela Distribuição Lambda Generalizada (GLD) e seus quatro parâmetros são representados por PCE das variáveis de entrada (**ZhuSudret2020**; **ZhuSudret2021**).

Apesar desses avanços, identifica-se uma lacuna na literatura: os trabalhos existentes sobre confiabilidade dependente do tempo de estruturas sujeitas à carbonatação concentram-se em emular momentos estatísticos, o índice de confiabilidade $\beta(t)$ ou a profundidade média de carbonatação, e o arcabouço GLaM original é formulado para um instante fixo, sem tratamento contínuo da variável tempo. Nenhuma abordagem disponível fornece, de forma simultânea, (i) a distribuição condicional *completa* da função de estado limite $g(t)$, (ii) a interpolação contínua dessa distribuição entre instantes simulados e (iii) a tradução direta dessa informação em uma distribuição probabilística de RUL apta a subsidiar decisões de manutenção.

Para preencher essa lacuna, o presente estudo propõe um emulador estocástico dependente do tempo no qual a resposta do simulador é modelada por uma GLD cujos parâmetros $\boldsymbol{\lambda}$ são funções das variáveis de entrada, representadas por PCE, e a evolução temporal desses parâmetros é aprendida por um modelo de ML que recebe o tempo

como variável de entrada contínua. Uma vez treinado, o emulador fornece instantaneamente a função densidade de probabilidade da margem de segurança $g(\mathbf{X}, t)$ em qualquer instante t do horizonte de análise, da qual se derivam a probabilidade de falha, a distribuição do tempo até a falha, a RUL probabilística e métricas de risco de cauda (VaR e CVaR). A metodologia é aplicada à previsão da vida remanescente de elementos de concreto armado sujeitos à carbonatação, combinando o modelo de avanço da frente de **possan2010**; **possan2016co2<empty citation>** com a margem entre o cobrimento efetivo e a profundidade carbonatada. O evento de referência é a despassivação da armadura, e limiares positivos dessa margem representam critérios de intervenção preventiva. Para verificar o arcabouço metodológico, adota-se uma versão adaptada de um problema de referência de confiabilidade, seguindo a estratégia geral de validação proposta por **pires2024<empty citation>**.

As principais contribuições deste trabalho são: (i) a extensão do arcabouço GLaM para o domínio temporal, por meio de uma camada de aprendizado de máquina que interpola continuamente os parâmetros da GLD entre os instantes simulados; (ii) a integração da deterioração por carbonatação em um arcabouço probabilístico de previsão de RUL que opera sobre a distribuição completa da função de estado limite, e não apenas sobre seus momentos; e (iii) a demonstração de ganhos de eficiência computacional de ordens de grandeza em relação à abordagem convencional de Monte Carlo, viabilizando análises de RUL em tempo quase real, inclusive na comparação de limiares de manutenção preventiva. Os resultados visam a contribuir para a avaliação de ciclo de vida baseada em confiabilidade de infraestruturas de concreto armado e para o suporte a decisões de manutenção informadas por risco.

O restante do artigo está organizado da seguinte forma. A Seção 2 reúne a fundamentação sobre vida útil de estruturas de concreto armado: os mecanismos de degradação, a fenomenologia da carbonatação, os modelos de previsão da profundidade carbonatada e o conceito de vida útil remanescente com suas métricas de risco. A Seção 3 apresenta o núcleo metodológico do emulador — o simulador estocástico, a Distribuição Lambda Generalizada, seu acoplamento com a Expansão em Caos Polinomial e a camada de aprendizado de máquina que o torna contínuo no tempo. A Seção 4 detalha a metodologia propriamente dita: a função de estado limite de despassivação, a parametrização adotada, os cenários de exposição, o procedimento de construção do emulador e a obtenção da RUL a partir da distribuição emulada. A Seção 5 apresenta os exemplos numéricos, iniciando pela verificação em um problema de referência e avançando para a previsão de RUL de elementos de concreto armado sob carbonatação. A Seção 6 resume as conclusões.

2. Vida útil de estruturas de concreto armado

2.1 Degradação, vida útil e o modelo de Tuutti

Estruturas de concreto armado em serviço estão permanentemente expostas a agentes físicos e químicos que reduzem progressivamente seu desempenho. A durabilidade não é, portanto, uma propriedade intrínseca do material, mas a resposta de uma estrutura específica, em um ambiente específico, ao longo de um período determinado (**fib2006**). Essa dependência conjunta de material, ambiente e tempo é o que torna a previsão de vida útil um problema naturalmente probabilístico.

Entre os mecanismos de deterioração do concreto armado destacam-se a corrosão de armaduras induzida por íons cloreto, característica de ambientes marinhos e de estruturas sujeitas a sais de degelo; a corrosão induzida por carbonatação, predominante em ambientes urbanos e atmosféricos; o ataque por sulfatos; a reação álcali-agregado; a lixiviação da matriz cimentícia; e os ciclos de gelo-degelo. Dentre todos, a corrosão das armaduras é reconhecida como a principal causa de deterioração precoce de estruturas de concreto armado (**tuutti1982**; **melchers2018**).

Os dois mecanismos de corrosão mais relevantes diferem quanto à natureza do ataque, conforme detalhado na Seção 2.2: os cloretos rompem a camada passiva de forma localizada, enquanto a carbonatação a destrói de maneira generalizada. A carbonatação é o mecanismo dominante em ambientes urbanos atmosféricos afastados da orla marítima, condição que descreve grande parte do parque construído brasileiro no interior do país e que justifica o recorte adotado neste trabalho.

No que se refere à vida útil, é usual distinguir a *vida útil de projeto*, período para o qual a estrutura é concebida e que fundamenta a escolha do cobrimento e da classe de agressividade ambiental (**nbr6118**); a *vida útil de serviço*, efetivamente observada em campo; e a *vida útil remanescente*, isto é, o período que resta, a partir de um instante de inspeção, até que um estado limite pertinente seja atingido. É esta última que interessa à gestão de ativos existentes e que constitui o objeto deste trabalho.

O arcabouço conceitual consagrado para descrever a evolução da corrosão é o modelo de **tuutti1982<empty citation>**, que decompõe a vida útil em duas fases sucessivas:

$$t_{\text{total}} = t_{\text{ini}} + t_{\text{prop}}, \tag{1}$$

em que t_{ini} é o período de *iniciação*, durante o qual a frente agressiva avança pelo cobrimento sem que haja perda de capacidade estrutural, e t_{prop} é o período de *propagação*, iniciado com a despassivação da armadura, no qual ocorrem a perda de seção do aço, a fissuração por expansão dos produtos de corrosão e o eventual destacamento do cobrimento.

Este trabalho concentra-se na **fase de iniciação**. O estado limite considerado é, portanto, a *despassivação* da armadura — o instante em que a frente carbonatada alcança o

nível do aço — e não a ruína estrutural. Trata-se de um estado limite de serviço de durabilidade, para o qual as recomendações do **fib2006<empty citation>** indicam índices de confiabilidade alvo da ordem de $\beta_{\text{alvo}} \approx 1{,}3$, substancialmente inferiores aos adotados para estados limites últimos, justamente porque sua violação não implica colapso, mas o encerramento do período protegido e o início da janela em que a intervenção de manutenção passa a ser pertinente. Para o limiar nulo, a vida remanescente refere-se ao tempo até a despassivação. Os exemplos também consideram limiares positivos, associados ao prazo até uma intervenção preventiva, conforme a definição da Seção 2.5.

2.2 Carbonatação: fenomenologia

A corrosão desencadeada pela carbonatação difere substancialmente de outros mecanismos agressivos por sua natureza química global, governada pela redução progressiva da alcalinidade da matriz cimentícia. Enquanto agentes como os íons cloreto perfuram a camada passiva de forma localizada (corrosão por *pites*), a carbonatação avança como uma frente ácida que reduz o pH do concreto a níveis inferiores a 9, promovendo a despassivação generalizada de toda a superfície da armadura afetada. Essa perda de proteção em larga escala resulta em corrosão uniforme, caracterizada pela formação volumosa de óxidos expansivos ao longo da barra, o que gera tensões de tração no concreto e culmina em fissuração intensa e destacamento do cobrimento, mesmo antes da perda crítica de seção transversal do aço (**tuutti1982**).

O processo inicia-se com a difusão do dióxido de carbono atmosférico (CO_2) através da rede de poros do concreto. O CO_2 reage com a umidade dos poros e com os produtos de hidratação do cimento, predominantemente o hidróxido de cálcio ($Ca(OH)_2$), levando à formação de carbonato de cálcio ($CaCO_3$), conforme a Equação (2):

$$Ca(OH)_2 + CO_2 \rightarrow CaCO_3 + H_2O \tag{2}$$

Em condições normais, o concreto mantém um ambiente altamente alcalino (pH entre 12,6 e 13,5), que sustenta uma película passiva estável de óxidos sobre a superfície do aço, conferindo proteção efetiva contra a corrosão. O avanço progressivo da frente de carbonatação, contudo, reduz o pH a valores inferiores a 9, despassivando a armadura e tornando o aço suscetível à corrosão generalizada na presença de oxigênio e umidade. O processo de corrosão é tipicamente dividido em duas fases: *iniciação*, durante a qual a armadura permanece passivada enquanto a frente avança em direção a ela, e *propagação*, na qual a película protetora é destruída e a corrosão ativa se desenvolve (**tuutti1982**).

A velocidade e a profundidade da carbonatação são influenciadas por diversos fatores ambientais e de material, tais como: a concentração de CO_2 (níveis mais elevados aceleram a reação); a umidade relativa do ar (a carbonatação é mais intensa em faixas intermediárias, tipicamente 50%–70%); a qualidade do concreto (relação água/cimento, tipo de cimento e porosidade determinam a facilidade de ingresso do CO_2); e a espessura

do cobrimento, que atua como barreira física (**possan2010**; **possan2016co2**).

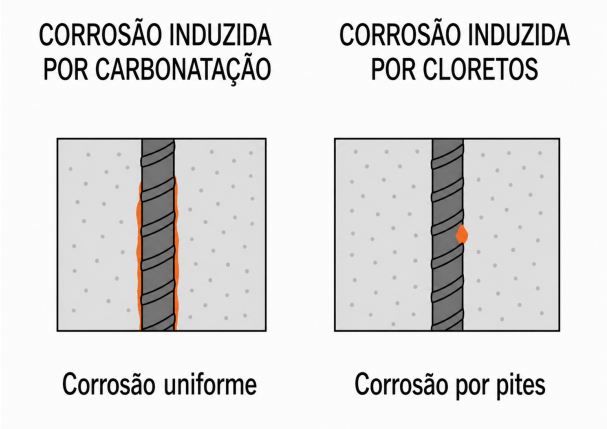


Figura 1: Diferenças entre os mecanismos de corrosão localizada (cloretos) e generalizada (carbonatação).

2.3 Exposição ambiental: concentração atmosférica de CO_2

Como descrito na subseção anterior, o CO_2 atmosférico é o agente que desencadeia a carbonatação, e sua concentração governa diretamente o fluxo difusivo para o interior do concreto. Diferentemente das demais condições ambientais, trata-se de uma grandeza que não é estacionária ao longo da vida útil de uma estrutura: a concentração de fundo cresceu de forma sustentada ao longo do século XX e sua trajetória futura depende do cenário de emissões considerado. Uma previsão de vida útil em horizonte secular precisa, portanto, tratar o CO_2 como uma condição de exposição variável no tempo, e não como uma constante. Para representar sua evolução, empregam-se as concentrações médias globais anuais do CMIP6, publicadas por **meinshausen2017<empty citation>** para o período histórico e por **meinshausen2020<empty citation>** para os cenários SSP (*Shared Socioeconomic Pathways*). A grandeza utilizada é a concentração de CO_2 no ar, em partes por milhão (ppm), e não a taxa de emissão, o consumo de carbono ou uma concentração de CO_2 equivalente.

A série implementada abrange 1900–2100. Até 2014, adota-se um histórico comum aos cenários. A partir de 2015, utilizam-se as trajetórias anuais publicadas para SSP1-2.6, SSP2-4.5 e SSP5-8.5. Os dados foram extraídos das colunas referentes a CO_2, unidade ppm e região global (*World*) do suplemento de **meinshausen2020<empty citation>**; o mesmo suplemento disponibiliza a série histórica de **meinshausen2017<empty citation>**. As séries são utilizadas sem ajuste de regressão ou correção posterior. As abas SSP incorporam observações em 2015–2016, conforme a descrição da base, e as trajetórias subsequentes são mantidas na versão publicada em 2020. Assim, os valores de cenário em anos já transcorridos não são apresentados como medições atualizadas.

Os três cenários representam, respectivamente, trajetórias de emissões baixas, intermediárias e muito altas. Sua seleção permite examinar condições ambientais contras-

tantes sem atribuir probabilidades de ocorrência. O SSP2-4.5 é a referência de comparação adotada por padrão; essa escolha não implica classificá-lo como o futuro mais provável. Na nomenclatura SSPx-y, o primeiro índice identifica a trajetória socioeconômica e o segundo indica o nível aproximado de forçamento radiativo em 2100, em W/m^2 (**ipcc2021scenarios**). Os resultados de durabilidade devem, portanto, ser interpretados como condicionais ao cenário de exposição escolhido.

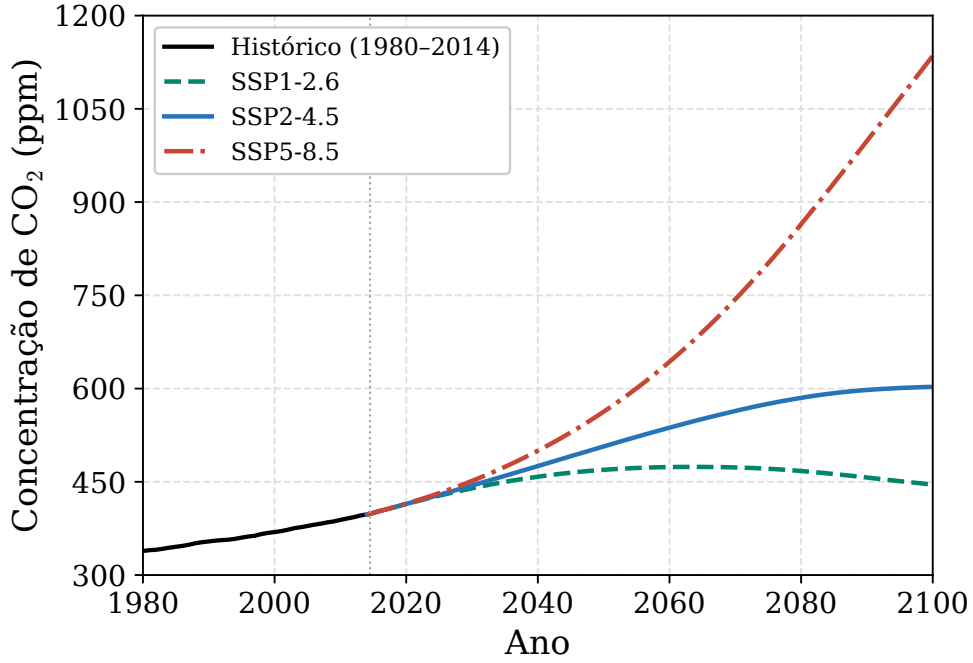


Figura 2: Concentração atmosférica média global anual de CO_2 entre 1980 e 2100: histórico comum até 2014 e trajetórias SSP1-2.6, SSP2-4.5 e SSP5-8.5 a partir de 2015. A linha vertical indica a transição entre as séries. As linhas unem os valores anuais publicados e não representam bandas de confiança. Elaboração própria com dados de **meinshausen2017**; **meinshausen2020<empty citation>**.

A Figura 2 evidencia a divergência entre as trajetórias. No SSP1-2.6, a concentração atinge aproximadamente 474 ppm em 2063 e posteriormente diminui; no SSP2-4.5, o crescimento desacelera; no SSP5-8.5, o aumento é mais acentuado. A Tabela 1 apresenta valores selecionados para os horizontes de interesse. Esses valores descrevem o CO_2 atmosférico; uma eventual redução da concentração não significa reversão da carbonatação já ocorrida.

Tabela 1: Concentrações médias globais anuais de CO_2 nos cenários adotados (ppm), extraídas do suplemento de **meinshausen2020<empty citation>**.

Cenário	2050	2080	2100
SSP1-2.6	469,3	467,4	445,6
SSP2-4.5	506,9	585,1	602,8
SSP5-8.5	562,8	864,4	1135,2

2.4 Modelos de previsão da profundidade de carbonatação

A despassivação por carbonatação ocorre quando a frente carbonatada avança pelo concreto de cobrimento e atinge o nível da armadura, ou seja, quando $y(t) \geq c_{\text{nom}}$, sendo c_{nom} o cobrimento nominal. Para prever o avanço dessa frente ao longo do tempo, existem diversos modelos matemáticos na literatura, que variam desde formulações empíricas simples até abordagens analíticas e mecanísticas mais complexas.

Na sua forma mais geral e clássica, frequentemente utilizada em análises de confiabilidade, o avanço da frente de carbonatação reduz-se à lei da difusão baseada na raiz do tempo:

$$y(t) = k\,\sqrt{t}, \tag{3}$$

na qual t é o tempo de exposição e k ($\text{mm}/\sqrt{\text{ano}}$) é o coeficiente de carbonatação. Em modelos simplificados como este, o coeficiente k condensa todo o efeito conjunto do material e do ambiente de exposição, podendo ser obtido, por exemplo, por regressão de perfis medidos como $k = y/\sqrt{t}$. A contrapartida dessa simplicidade é que k não permite discriminar a contribuição individual de cada fator de projeto ou de ambiente, o que o torna pouco útil quando o objetivo é justamente propagar incertezas de material e de exposição, como neste trabalho.

Formulação adotada. Para contornar essa limitação, adotou-se o modelo semiempírico de **possan2010**; **possan2016co2<empty citation>**, calibrado a partir de resultados de ensaios naturais e acelerados de concretos brasileiros. O modelo explicita a influência da resistência à compressão, do tipo de cimento, do teor de adições pozolânicas, da concentração atmosférica de CO_2, da umidade relativa e da proteção à chuva, conforme a Equação (4):

$$y(t) = k_c \cdot \left(\frac{20}{f_c}\right)^{k_{fc}} \cdot \left(\frac{t}{20}\right)^{\frac{1}{2}} \cdot \exp\left[\frac{k_{ad}\cdot ad^{\frac{3}{2}}}{40+f_c} + \frac{k_{CO_2}\cdot CO_2^{\frac{1}{2}}}{60+f_c} - \frac{k_{UR}\cdot (UR-0{,}58)^2}{100+f_c}\right] \cdot k_{ce} \tag{4}$$

em que $y(t)$ é a profundidade de carbonatação (mm) na idade t (anos), f_c é a resistência à compressão do concreto (MPa), ad é o teor de adição pozolânica em relação à massa de cimento (%), CO_2 é a concentração volumétrica de dióxido de carbono no ambiente (%) e UR é a umidade relativa média do ar, expressa como fração decimal. Os seis coeficientes de calibração são: k_c, associado ao tipo de cimento; k_{fc}, à resistência à compressão; k_{ad}, às adições pozolânicas; k_{CO_2}, à concentração de CO_2; k_{UR}, à umidade relativa; e k_{ce}, à condição de exposição da estrutura quanto à proteção à chuva. Os cinco primeiros dependem do tipo de cimento e o último da condição de exposição, com os valores reunidos na Tabela 2.

Tabela 2: Coeficientes do modelo de carbonatação em função (a) do tipo de cimento e (b) da condição de exposição da estrutura (**possan2010**, **possan2010**).

(a) Tipo de cimento					
	Características do concreto			Condições ambientais	
Tipo de cimento	Cimento k_c	f_c k_{fc}	Adição k_{ad}	CO_2 k_{CO_2}	UR k_{UR}
CP I	19,80	1,70	0,24	18,00	1300
CP II E	22,48	1,50	0,32	15,50	1300
CP II F	21,68	1,50	0,24	18,00	1100
CP II Z	23,66	1,50	0,32	15,50	1300
CP III	30,50	1,70	0,32	15,50	1300
CP IV	33,27	1,70	0,32	15,50	1000
CP V-ARI	19,80	1,70	0,24	18,00	1300
(b) Condição de exposição					
Proteção à chuva					k_{ce}
Ambiente interno, protegido da chuva					1,30
Ambiente externo, protegido da chuva					1,00
Ambiente externo, desprotegido da chuva					0,65

Leitura física dos termos. A estrutura multiplicativa da Equação (4) admite interpretação direta, o que facilita tanto a verificação do modelo quanto a leitura posterior dos índices de sensibilidade:

- **Termo de resistência**, $(20/f_c)^{k_{fc}}$. Normaliza a resposta em relação a um concreto de referência de 20 MPa. Resistências mais elevadas decorrem de relações água/cimento menores, que produzem matriz mais densa e menor difusividade efetiva do CO_2, reduzindo a profundidade carbonatada. O expoente k_{fc}, entre 1,50 e 1,70, mede a intensidade dessa redução.

- **Termo temporal**, $(t/20)^{1/2}$. Preserva a lei da raiz do tempo da Equação (3), ancorada em uma idade de referência de 20 anos.

- **Termo de adições**, $+\,k_{ad}\,ad^{3/2}/(40+f_c)$. O sinal positivo indica aprofundamento da frente: as adições pozolânicas consomem hidróxido de cálcio na reação pozolânica e reduzem a reserva alcalina disponível para fixar o CO_2. Esse efeito é contrário ao do refinamento da estrutura de poros que as mesmas adições promovem, o qual já é capturado indiretamente pela resistência f_c.

- **Termo de CO_2**, $+\,k_{CO_2}\sqrt{CO_2}/(60+f_c)$. Representa o gradiente de concentração que governa o fluxo difusivo do gás para o interior do concreto; quanto maior a concentração ambiente, mais rápida a penetração.

- **Termo de umidade**, $-\,k_{UR}(UR-0{,}58)^2/(100+f_c)$. É uma parábola com vértice em $UR = 0{,}58$, ou seja, a expressão matemática do comportamento em sino característico

da carbonatação: em concreto seco falta água nos poros para dissolver o CO_2 e viabilizar a reação de carbonatação; em concreto saturado, os poros preenchidos reduzem o coeficiente de difusão do CO_2 em várias ordens de grandeza. A taxa máxima ocorre, portanto, em umidades intermediárias, em torno de 58%.

- **Fator de exposição**, k_{ce}. Os ciclos de molhagem saturam a rede de poros e retardam o avanço da frente, razão pela qual o ambiente externo desprotegido da chuva ($k_{ce} = 0{,}65$) carbonata menos que o ambiente interno protegido ($k_{ce} = 1{,}30$).

Cabe observar que os três termos do expoente são atenuados por denominadores crescentes com f_c ($40+f_c$, $60+f_c$ e $100+f_c$), de modo que concretos mais resistentes são menos sensíveis tanto às adições quanto às condições ambientais — comportamento coerente com a menor conectividade da rede porosa.

Uma consequência útil da normalização adotada é que, para $t = 20$ anos, $f_c = 20$ MPa, $ad = 0$, $UR = 0{,}58$ e concentração de CO_2 desprezível, a Equação (4) reduz-se a $y = k_c \cdot k_{ce}$. O coeficiente k_c é, portanto, diretamente interpretável como a profundidade de carbonatação, em milímetros, de um concreto de 20 MPa aos 20 anos na condição de referência, o que torna a Tabela 2 imediatamente legível: um CP IV ($k_c = 33{,}27$) carbonata cerca de 68% mais que um CP V-ARI ($k_c = 19{,}80$) nas mesmas condições, refletindo a menor reserva alcalina dos cimentos com elevado teor de adições.

Domínio de validade. O modelo foi calibrado para concretos convencionais brasileiros a partir de ensaios naturais e acelerados, e sua aplicação deve respeitar a faixa de variáveis empregada nessa calibração. O domínio nominal de amostragem adotado neste trabalho é $f_c \in [20; 50]$ MPa, $UR \in [20; 80]\%$ e $t \leq 100$ anos, com a concentração de CO_2 dada pelas trajetórias da Seção 2.3. Esse domínio numérico deve ser distinguido do domínio de calibração: além das faixas nominais, as variáveis latentes podem produzir resistências e cobrimentos fora dos intervalos de amostragem das entradas. **[FALTA: confirmar o limite superior de f_c contra a fonte primária: a descrição do modelo em possan2010<empty citation> menciona a faixa de 20 a 40 MPa, enquanto as simulações deste trabalho alcançam 50 MPa — se a faixa de calibração for mesmo 20–40 MPa, ou se reduz o envelope, ou se declara e justifica explicitamente a extrapolação]**

2.5 Vida útil remanescente

Definido o mecanismo de degradação e o modelo que descreve o avanço da frente carbonatada, resta estabelecer a grandeza de interesse para a gestão da estrutura. Para cada realização $\mathbf{x}$ das variáveis de entrada, o tempo até o esgotamento da vida útil é o primeiro instante em que a margem de segurança atinge um limiar de intervenção $g_{\lim}$:

$$T(\mathbf{x};\, g_{\lim}) = \inf\{\, t \geq 0 \,:\, g(\mathbf{x}, t) \leq g_{\lim} \,\}\,. \tag{5}$$

O caso $g_{\lim} = 0$ recupera o tempo até a violação do estado limite propriamente dita. Adotar $g_{\lim} > 0$, contudo, é o que corresponde à prática de gestão: não se aguarda que a frente carbonatada alcance a armadura para então intervir, mas antecipa-se a intervenção enquanto ainda resta uma margem de cobrimento não atacado. O limiar é, portanto, uma *variável de decisão* do gestor, e não uma propriedade da estrutura — elevá-lo significa intervir mais cedo e com mais folga; reduzi-lo a zero significa operar o ativo até o limite. Manter $g_{\lim}$ explícito na formulação permite que uma mesma análise produza uma família de distribuições de vida remanescente, uma por política, que é precisamente a entrada de um problema de otimização de manutenção.

Dado um instante de inspeção t_{insp} no qual se constata que a estrutura ainda não violou o estado limite, a *vida útil remanescente* (*Remaining Useful Life* — RUL) é a variável aleatória condicionada

$$\mathrm{RUL}(t_{\text{insp}};\, g_{\lim}) = (\, T - t_{\text{insp}} \,|\, T > t_{\text{insp}}) \,. \tag{6}$$

A RUL é a grandeza central da literatura de prognóstico e gestão da saúde de sistemas (**si2011**) e da gestão de infraestruturas informada por risco (**frangopol2011**; **vannoortwijk2009**). Sua natureza é intrinsecamente probabilística: como as propriedades do material, a geometria executada e as condições de exposição são incertas, T é uma variável aleatória e a RUL é uma distribuição, não um número.

Essa distinção é mais do que formal. A prática corrente reporta a vida útil residual por um valor único — tipicamente a média ou o valor obtido com parâmetros nominais —, mas nenhuma decisão de manutenção é tomada sobre a média. Decide-se sobre quantis inferiores: o gestor precisa saber qual é a vida remanescente que será superada com alta confiança, e não qual é a vida remanescente típica. Duas estruturas com a mesma $\mathbb{E}[\mathrm{RUL}]$ podem exigir intervenções em momentos muito distintos se as dispersões, e sobretudo as caudas inferiores, forem diferentes.

Por essa razão, além da distribuição completa, empregam-se métricas de risco de cauda consagradas em análise de decisão sob incerteza (**rockafellar2000**). O *Value-at-Risk* ao nível α é o quantil inferior da distribuição de RUL,

$$\mathrm{VaR}_{\alpha} = \inf \{\, r \,:\, F_{\mathrm{RUL}}(r) \geq \alpha \,\} \,, \tag{7}$$

e representa a vida remanescente que será superada com confiança $(1-\alpha)$. O *Conditional Value-at-Risk* é o valor esperado da RUL condicionado aos cenários abaixo desse limiar,

$$\mathrm{CVaR}_{\alpha} = \mathbb{E}\,[\,\mathrm{RUL} \,|\, \mathrm{RUL} \leq \mathrm{VaR}_{\alpha}\,] \,, \tag{8}$$

contabilizando explicitamente a severidade da cauda e fornecendo uma medida mais conservadora que o próprio VaR.

Complementarmente, a confiabilidade dependente do tempo é descrita pela probabilidade de falha instantânea $p_f(t) = \mathbb{P}[g(\mathbf{X}, t) \leq 0]$ e pelo índice de confiabilidade

generalizado $\beta(t) = -\Phi^{-1}[p_f(t)]$, em que Φ é a função de distribuição normal padrão (**melchers2018**). Para processos de degradação monotônica, como o avanço da frente de carbonatação, a função de confiabilidade satisfaz $R(t) \approx 1 - p_f(t)$, uma vez que as trajetórias que cruzam o limiar não retornam ao domínio seguro (**ellingwood2005**).

Cabe observar, por fim, que a maior parte dos trabalhos de confiabilidade dependente do tempo aplicados à carbonatação reporta a evolução de $\beta(t)$ ou da profundidade média carbonatada. A distribuição de T — e, por consequência, a de RUL e suas métricas de cauda — raramente é obtida de forma direta, pois exigiria caracterizar a distribuição *completa* de g em cada instante do horizonte de análise. É precisamente essa lacuna que o emulador estocástico apresentado na Seção 3 se propõe a preencher.

3. Emuladores estocásticos e aprendizado de máquina

O elevado custo computacional de modelos de alta fidelidade frequentemente inviabiliza simulações diretas de Monte Carlo, exigindo o uso de metamodelos, também chamados de emuladores. Embora Processos Gaussianos (GP) (**rasmussen2006**) e Expansões em Caos Polinomial (PCE) (**xiu2002**) sejam padrão para sistemas determinísticos, eles não podem ser aplicados diretamente a simuladores estocásticos, nos quais uma única avaliação é insuficiente para caracterizar a distribuição da resposta.

3.1 Simuladores estocásticos

Matematicamente, um simulador estocástico $\mathcal{M}_S$ pode ser visto como um mapeamento que incorpora variáveis determinísticas e aleatoriedade intrínseca. Para um dado vetor de parâmetros de entrada $\mathbf{x}$ no domínio $\mathcal{D}_X$, a resposta não é um valor determinístico único, mas uma variável aleatória $Y_{\mathbf{x}}$. Essa relação é formalmente expressa como:

$$\mathcal{M}_S : \mathcal{D}_X \times \Omega \to \mathbb{R}, \qquad (\mathbf{x}, \omega) \mapsto \mathcal{M}_S(\mathbf{x}, \omega), \tag{9}$$

em que $\mathbf{x}$ representa o conjunto de parâmetros de entrada controlados (e.g., geometria, propriedades dos materiais) e ω denota um evento aleatório do espaço de probabilidade Ω. Essa variável latente ω introduz a estocasticidade no sistema. Consequentemente, para uma entrada fixa $\mathbf{x}$, o simulador produz uma distribuição de resultados possíveis, e não uma solução única. No problema em estudo, $\mathcal{M}_S(\mathbf{x}, \omega) = g(\mathbf{x}, t; \omega)$ é a função de estado limite definida na Equação (19), e as variáveis latentes correspondem às incertezas de modelo e às flutuações não explicitamente parametrizadas.

3.2 Distribuição Lambda Generalizada

No contexto da avaliação de durabilidade do concreto armado, o processo de carbonatação é influenciado por diversas fontes de incerteza, que vão da heterogeneidade do material às flutuações ambientais. Para capturar esses comportamentos probabilísticos complexos

sem o custo computacional de simulações exaustivas, este estudo emprega a Distribuição Lambda Generalizada (GLD) como núcleo do emulador estocástico. A GLD é uma família de distribuições de quatro parâmetros, altamente flexível, projetada para aproximar uma ampla gama de distribuições paramétricas (**KarianDudewicz2000**; **ZhuSudret2021**).

A GLD é definida por sua *função quantílica* $Q(u)$, que é a inversa da função de distribuição acumulada (CDF), i.e., $Q(u) = F^{-1}(u)$. Essa abordagem é particularmente vantajosa para a emulação estocástica, pois facilita o método de amostragem por transformada inversa. Neste estudo, considera-se a família Freimer–Kollia–Mudholkar–Lin (FKML) (**Freimer1988**), definida como:

$$Q(u) = \lambda_1 + \frac{1}{\lambda_2}\left(\frac{u^{\lambda_3} - 1}{\lambda_3} - \frac{(1-u)^{\lambda_4} - 1}{\lambda_4}\right) \tag{10}$$

em que $u \in [0, 1]$ representa a probabilidade acumulada. A distribuição é governada por quatro parâmetros: λ_1 é o parâmetro de *locação*, λ_2 é o parâmetro de *escala* (com a exigência $\lambda_2 > 0$) e λ_3, λ_4 são os parâmetros de *forma*.

3.3 Estimação de parâmetros via método dos momentos

Para calibrar o emulador GLD, os quatro parâmetros $\boldsymbol{\lambda} = \{\lambda_1, \ldots, \lambda_4\}$ devem ser estimados a partir de um conjunto de avaliações do modelo (**karian2010handbook**; **corlu2016**). Neste estudo, emprega-se o *Método dos Momentos* (MoM) (**lakhany2000**), que consiste em igualar os momentos teóricos da GLD aos momentos empíricos calculados do conjunto amostral $\mathcal{Y} = \{y^{(1)}, \ldots, y^{(N)}\}$. Os quatro primeiros momentos centrais — média μ, variância σ^2, assimetria δ e curtose κ — relacionam-se analiticamente aos parâmetros λ da seguinte forma:

$$\mu = \lambda_1 - \frac{1}{\lambda_2}\left(\frac{1}{\lambda_3 + 1} - \frac{1}{\lambda_4 + 1}\right) \tag{11}$$

$$\sigma^2 = \frac{v_2 - v_1^2}{\lambda_2^2} \tag{12}$$

$$\delta = \frac{v_3 - 3v_1v_2 + 2v_1^3}{(v_2 - v_1^2)^{3/2}} \tag{13}$$

$$\kappa = \frac{v_4 - 4v_1v_3 + 6v_1^2v_2 - 3v_1^4}{(v_2 - v_1^2)^2} \tag{14}$$

Nessas expressões, v_k denota uma função não linear que depende apenas de λ_3 e λ_4, dada pela Equação (15), em que $B(\cdot, \cdot)$ representa a função Beta:

$$v_k = \sum_{j=0}^{k} \frac{(-1)^j}{\lambda_3^{k-j}\lambda_4^j}\binom{k}{j} B(\lambda_3(k-j) + 1,\ \lambda_4 j + 1) \tag{15}$$

A calibração dos parâmetros da GLD é formulada como um problema inverso, cujo objetivo é minimizar a discrepância entre os momentos analíticos (Equações 11–14) e os

momentos empíricos derivados do simulador estocástico. Para resolver esse sistema não linear, emprega-se o algoritmo de otimização Broyden–Fletcher–Goldfarb–Shanno (BFGS) (**nocedal2006**), um método quase-Newton particularmente adequado a esse tipo de estimação devido ao tratamento eficiente de gradientes e às boas propriedades de convergência em espaços multidimensionais. O procedimento numérico foi implementado no PyGLAM, biblioteca Python desenvolvida pelos autores especificamente para a emulação de simuladores estocásticos com Distribuições Lambda Generalizadas.

Cabe registrar que o arcabouço GLaM original (**ZhuSudret2021**) emprega máxima verossimilhança condicional combinada a mínimos quadrados generalizados para a estimação dos parâmetros, dispensando réplicas no plano de experimentos. A opção pelo MoM com réplicas adotada neste trabalho justifica-se (i) pela robustez e simplicidade de implementação, (ii) pelo baixo custo de cada avaliação dos modelos mecânicos aqui considerados, que torna as réplicas viáveis, e (iii) pelo controle direto da qualidade do ajuste local em cada ponto do plano de experimentos, requisito importante para a camada temporal descrita na Seção 4.2.

A acurácia desse ajuste — que condiciona a de todo o arcabouço, por ser ele que converte cada conjunto de réplicas do simulador em um vetor $\boldsymbol{\lambda}$ — é verificada de forma isolada na Seção 5.1, por meio do ajuste a distribuições de referência com solução analítica conhecida.

3.4 Acoplamento com a Expansão em Caos Polinomial

Seguindo a metodologia proposta por **ZhuSudret2021<empty citation>** e desenvolvimentos posteriores em metamodelagem estocástica, a GLD é acoplada à Expansão em Caos Polinomial (PCE) para a construção de um emulador global. Nesse arcabouço, a resposta estocástica do simulador para qualquer entrada $\mathbf{X}$ é modelada por uma GLD cujos parâmetros $\boldsymbol{\lambda}$ são, eles próprios, funções das variáveis de entrada.

Dado um conjunto de parâmetros de entrada $\mathbf{X}$ governado por uma função densidade de probabilidade conjunta $f_{\mathbf{X}}(\mathbf{x})$, cada componente do vetor de parâmetros λ_i é aproximada por uma PCE truncada:

$$\lambda_i(\mathbf{X}) \approx \sum_{\boldsymbol{\alpha}\in\mathcal{A}} a_{i,\boldsymbol{\alpha}}\Psi_{\boldsymbol{\alpha}}(\mathbf{X}), \quad i = \{1,2,3,4\} \tag{16}$$

em que $\Psi_{\boldsymbol{\alpha}}(\mathbf{X})$ são polinômios ortonormais multivariados específicos das distribuições de entrada (**xiu2002**), $a_{i,\boldsymbol{\alpha}}$ são os coeficientes a determinar e $\mathcal{A}$ é o conjunto de multi-índices que define o esquema de truncamento (e.g., base de grau total) (**blatman2011**). Uma vez estimados os coeficientes, o emulador PCE–GLD fornece instantaneamente a distribuição de probabilidade completa (via parâmetros λ) para qualquer nova entrada $\mathbf{X}^*$, sem exigir novas execuções do simulador estocástico original. O procedimento concreto de construção do emulador — plano de experimentos, réplicas estocásticas e extensão temporal — é detalhado na Seção 4.2.

3.5 Aprendizado de máquina como camada temporal

O emulador PCE–GLD descrito nas subseções anteriores fornece, para cada ponto do plano de experimentos e para cada instante simulado, um vetor de parâmetros $\boldsymbol{\lambda}$ que caracteriza a distribuição condicional da margem de segurança. Para que esse emulador opere de forma *contínua* no tempo — e não apenas nos instantes efetivamente simulados —, é necessária uma camada de regressão capaz de aprender o mapeamento entre as variáveis de entrada, o tempo e os parâmetros da distribuição. Esta subseção apresenta os fundamentos de aprendizado de máquina empregados nessa camada, com ênfase nas redes neurais artificiais.

3.5.1 Regressão supervisionada de múltiplas saídas

$$\mathbf{w}^{*} = \arg\min_{\mathbf{w}} \; \frac{1}{K} \sum_{k=1}^{K} \mathcal{L}\Big(\boldsymbol{\lambda}^{(k)},\, \mathcal{M}_{ML}(\mathbf{z}^{(k)}; \mathbf{w})\Big) + \Omega(\mathbf{w}), \tag{17}$$

em que $\Omega(\mathbf{w})$ é um termo de regularização que penaliza a complexidade do modelo e mitiga o sobreajuste. Diferentemente da regressão determinística usual, aqui a variável-alvo não é a resposta física em si, mas os *parâmetros de uma distribuição de probabilidade*; a acurácia da camada de ML traduz-se, portanto, diretamente na qualidade da distribuição emulada e, consequentemente, na estimativa de probabilidade de falha e de RUL.

Diversos regressores podem representar esse mapeamento, entre eles florestas aleatórias, regressão por vetores de suporte e redes neurais artificiais. Nos exemplos deste trabalho adota-se uma rede do tipo perceptron multicamadas para cada um dos dois parâmetros preditos, com arquitetura mantida entre o problema de referência e o de durabilidade. Essa definição constitui a configuração do experimento, sem uma comparação de desempenho entre famílias de regressores.

3.5.2 Redes neurais artificiais

Inspiradas na biologia do cérebro humano, as redes neurais funcionam através de unidades básicas de processamento conhecidas como neurônios artificiais. Assim como os dendritos e sinapses biológicas recebem e modulam sinais elétricos, o modelo computacional recebe dados numéricos de entrada e aplica "pesos"matemáticos para determinar a importância relativa de cada variável. O verdadeiro poder dessa tecnologia reside em sua capacidade inata de generalização; após processar milhares de exemplos, a rede ajusta seus parâmetros e adquire a habilidade de prever respostas estruturais para cenários físicos inéditos com notável resiliência.

Para realizar esse mapeamento complexo, a arquitetura padrão organiza os neurônios em camadas hierárquicas, movimentando a informação unidirecionalmente da camada de entrada até a previsão final na camada de saída. A estrutura básica de uma rede neural é composta por um grande número de nós interconectados distribuídos nessas camadas, que se diferenciam fundamentalmente em três tipos: a camada de entrada (que capta as

variáveis iniciais do projeto), as camadas ocultas (que realizam o processamento denso e a extração de padrões profundos) e a camada de saída (que emite a resposta final do modelo). O mecanismo de funcionamento da rede neural baseia-se na propagação contínua do sinal numérico através dessas conexões. O processamento matemático ocorre em duas etapas essenciais dentro de cada nó: primeiro, o neurônio realiza uma soma linear das entradas ponderadas pelos pesos, adicionando um valor de viés. Em seguida, o resultado passa por uma função de ativação não linear (como o ReLU), o que permite ao modelo emancipar-se das regressões simples e simular comportamentos não lineares de materiais, como a plasticidade do aço ou a fissuração do concreto. Adicionalmente, os tipos de camadas de saída dependem diretamente da aplicação estrutural desejada: em problemas de regressão a camada de saída opera geralmente com ativações lineares.

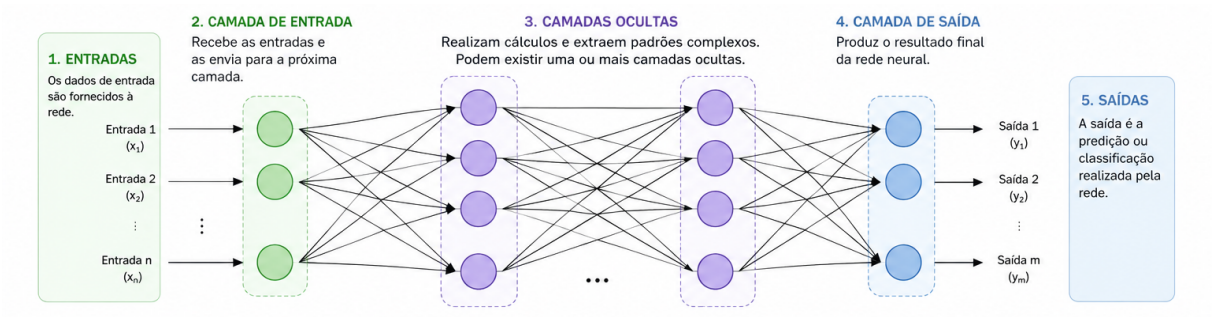


Figura 3: Diagrama de funcionamento de uma rede neural

O "conhecimento"da rede neural é construído durante um processo chamado de treinamento supervisionado. No início, como os pesos internos são aleatórios, as previsões do modelo são bastante imprecisas, gerando a necessidade de medir a divergência em relação ao resultado real por meio de uma função de perda. O algoritmo então utiliza um método de retropropagação para avaliar as falhas e ajustar iterativamente os pesos de cada conexão. Com a exposição contínua aos dados de treino, o erro matemático diminui progressivamente e a rede converge para um estado de estabilidade, atingindo a precisão necessária para o uso na engenharia em tempo real.

As redes neurais artificiais são aproximadores universais de funções, capazes de representar mapeamentos não lineares arbitrariamente complexos desde que dotadas de capacidade suficiente. Uma rede do tipo perceptron de múltiplas camadas (*Multilayer Perceptron* — MLP) organiza-se em uma camada de entrada, uma ou mais camadas ocultas e uma camada de saída. Cada neurônio de uma camada ℓ computa uma combinação afim das ativações da camada anterior, seguida da aplicação de uma função de ativação não linear $\phi(\cdot)$:

$$\mathbf{a}^{(\ell)} = \phi\Big(\mathbf{W}^{(\ell)}\mathbf{a}^{(\ell-1)} + \mathbf{b}^{(\ell)}\Big), \qquad \mathbf{a}^{(0)} = \mathbf{z}, \tag{18}$$

em que $\mathbf{W}^{(\ell)}$ e $\mathbf{b}^{(\ell)}$ são, respectivamente, a matriz de pesos e o vetor de vieses da camada ℓ, agrupados no conjunto de parâmetros $\mathbf{w} = \{\mathbf{W}^{(\ell)}, \mathbf{b}^{(\ell)}\}_\ell$. Funções de ativação usuais nas camadas ocultas incluem a unidade linear retificada (ReLU), $\phi(s) = \max(0, s)$, e a

tangente hiperbólica, $\phi(s) = \tanh(s)$; a camada de saída, no caso de regressão, emprega tipicamente ativação linear. A saída da rede, $\mathbf{a}^{(L)}$, fornece a estimativa dos parâmetros $\hat{\boldsymbol{\lambda}}$.

O treinamento consiste na minimização da perda da Equação (17), tipicamente o erro quadrático médio, por meio de *retropropagação* do gradiente combinada a um otimizador de gradiente estocástico (e.g., Adam). Para evitar o sobreajuste, empregam-se estratégias de regularização como parada antecipada (*early stopping*), penalização ℓ_2 dos pesos e, quando pertinente, *dropout*. A partição dos dados em subconjuntos de treinamento, validação e teste, aliada a validação cruzada, sustenta a estimativa honesta do erro de generalização.

Uma particularidade do presente problema é a condição $\lambda_2 > 0$ necessária à validade da GLD. Na implementação utilizada, os alvos são previstos diretamente, sem transformação logarítmica nem ativação positiva na saída. A base temporal de durabilidade exclui alvos com $\lambda_2 \leq 0$, mas isso não garante a positividade de novas predições. Nos diagnósticos distribucionais, predições inválidas são identificadas e retornam métricas ausentes; sua ocorrência e localização devem ser reportadas. Os parâmetros de forma são mantidos nos valores fixos informados em cada exemplo.

No arcabouço proposto, cada RNA recebe o vetor $\mathbf{z} = (\mathbf{x}, t)$ e prediz um dos parâmetros λ_1 ou λ_2. São utilizadas duas camadas ocultas de 64 neurônios, implementadas com `MLPRegressor` da biblioteca `scikit-learn`, padronização das entradas e parada antecipada. O procedimento de construção dos alvos e a partição dos dados são detalhados nas Seções 4.2.2 e 5.3.

4. Metodologia

Esta seção reúne os modelos físicos que definem o simulador estocástico, a formulação da função de estado limite dependente do tempo, o procedimento de construção do emulador (incluindo a camada temporal de aprendizado de máquina) e a ponte entre a distribuição emulada e as grandezas de gestão de ativos (probabilidade de falha, tempo até a falha, RUL e métricas de risco).

4.1 Simulador estocástico

A fundamentação sobre o mecanismo de degradação e o modelo de previsão da profundidade carbonatada foi apresentada na Seção 2. Esta subseção define como esse modelo é organizado em um simulador estocástico: qual é a função de estado limite, como as variáveis são separadas entre entradas controladas e fontes latentes de aleatoriedade, e quais parametrizações foram adotadas.

4.1.1 Função de estado limite de despassivação

Conforme estabelecido na Seção 2.1, o estado limite adotado é a despassivação da armadura, atingida quando a frente carbonatada alcança o nível do aço. A margem de segurança no instante t é, portanto, a distância remanescente entre a face da armadura e a frente de carbonatação:

$$g(\mathbf{X}, t) = c(\mathbf{X}) - y(\mathbf{X}, t), \tag{19}$$

em que c é o cobrimento efetivo da armadura (mm) e y é a profundidade de carbonatação (mm) dada pela Equação (4). A interpretação física é direta:

$$\begin{cases} g(\mathbf{X}, t) > 0, & \text{armadura passivada (período de iniciação),} \\ g(\mathbf{X}, t) \leq 0, & \text{despassivação (fim do período de iniciação).} \end{cases} \tag{20}$$

Trata-se de um estado limite de serviço de durabilidade: sua violação não corresponde à ruína da peça, mas ao encerramento da fase protegida e ao início da janela em que a corrosão pode se desenvolver. As Equações (5) e (6) fornecem o tempo até a despassivação quando o limiar é zero; para limiares positivos, fornecem o prazo até o critério preventivo especificado.

Variáveis de projeto e variáveis latentes. A estrutura da Equação (19) admite a separação exigida por um simulador estocástico (Seção 3.1). O vetor $\mathbf{X} = \{f_c,\, UR,\, c_{\text{nom}}\}$ reúne as *variáveis de projeto*, que caracterizam a peça e o ambiente e distinguem um elemento de outro. Sobre elas atua um conjunto de *variáveis latentes* $\boldsymbol{\omega}$, multiplicativas, que representam a dispersão interna ao próprio elemento — heterogeneidade do material, variabilidade executiva do posicionamento da armadura e dispersão das condições de umidade:

$$f_c^* = f_c\,\omega_{f_c}, \qquad UR^* = UR\,\omega_{UR}, \qquad c = c_{\text{nom}}\,\omega_c. \tag{21}$$

Essa separação confere ao problema a estrutura de simulador estocástico: para um mesmo vetor de projeto $\mathbf{x}$ e um mesmo instante t, a resposta g é uma variável aleatória cuja distribuição condicional precisa ser caracterizada. É essa distribuição que o emulador da Seção 4.2 aproxima. As distribuições latentes e suas dispersões são explicitadas a seguir. A configuração adotada não inclui um multiplicador independente de erro do modelo de carbonatação nem representa correlação espacial ao longo do elemento.

Determinada a trajetória de g para cada realização, a repetição do procedimento para todos os instantes e todas as amostras permitiria, em princípio, obter as curvas de confiabilidade e a distribuição do tempo até a despassivação por simulação direta de Monte Carlo. O custo dessa estratégia quando se deseja varrer projetos, cenários de exposição e instantes de inspeção é justamente o que motiva o emulador proposto.

4.1.2 Parametrização adotada

Nos Exemplos 2 e 3 adota-se cimento CP II F e ambiente externo protegido da chuva, o que fixa os coeficientes $k_c = 21{,}68$, $k_{fc} = 1{,}50$, $k_{ad} = 0{,}24$, $k_{CO_2} = 18{,}00$, $k_{UR} = 1100$ e $k_{ce} = 1{,}00$ da Tabela 2. O teor de adição pozolânica é mantido em $ad = 0\%$. No modelo, esse parâmetro expressa a massa de adição pozolânica em relação à massa de cimento (**possan2016co2**). O fíler calcário associado ao CP II F não é contabilizado como adição pozolânica; adotar zero representa a hipótese de ausência de adição pozolânica suplementar no concreto do exemplo. O tipo de cimento continua representado pelos coeficientes próprios do CP II F.

Os multiplicadores ω_{f_c} e ω_c são lognormais independentes, com média unitária e coeficiente de variação $v = 0{,}15$. Seus parâmetros no espaço logarítmico são

$$\sigma_{\ln\omega} = \sqrt{\ln(1+v^2)}, \qquad \mu_{\ln\omega} = -\frac{1}{2}\ln(1+v^2). \tag{22}$$

Essa parametrização preserva a média nominal e garante resistência e cobrimento positivos. Para a umidade, amostra-se uma Normal de média 1 e desvio padrão 0,15, condicionada ao intervalo $0 < \omega_{UR} < 1/UR$, com UR expresso como fração. Assim, $0 < UR^* < 1$. A média e o coeficiente de variação após a truncagem dependem da umidade nominal; os valores 1 e 0,15 são os parâmetros da Normal anterior ao condicionamento.

A independência dos três multiplicadores e a dispersão comum adotada constituem hipóteses do experimento numérico. O valor de 15% não é apresentado como estimativa obtida de uma estrutura real ou como prescrição normativa. Sua influência sobre os resultados deve ser distinguida do erro introduzido pelo emulador.

Por fim, ressalta-se que a Equação (4) é avaliada neste trabalho em sua forma fechada, e não por meio de um metamodelo de aprendizado de máquina ajustado a ela. Essa opção garante que o emulador estocástico proposto na Seção 4.2 seja construído e validado contra o próprio modelo mecanístico de referência, sem a interposição de uma aproximação intermediária.

4.1.3 Trajetória de CO_2 e idade da estrutura

As trajetórias de concentração atmosférica adotadas foram apresentadas na Seção 2.3. Descreve-se aqui como elas são associadas à idade da estrutura e convertidas na entrada do modelo de carbonatação.

Para associar a exposição ambiental à idade da estrutura, distingue-se o ano-calendário a do tempo de exposição t:

$$a = a_0 + t, \qquad 0 \le t \le T, \qquad a_0 + T \le 2100, \tag{23}$$

em que a_0 é o ano de início da exposição, tomado como o ano de construção, e T é o horizonte de análise. Dessa forma, 100 anos correspondem a 1980–2080 para uma

construção de 1980 e a 2000–2100 para uma construção de 2000. O horizonte de análise não é uma vida útil previamente assegurada; o atendimento ao critério de desempenho é avaliado ao longo desse intervalo.

Denotando por $C_s(a)$ a concentração em ppm para o cenário s, a entrada utilizada na Equação (4), expressa em porcentagem, é

$$CO_{2,s}(t)\,[\%] = \frac{C_s(a_0 + t)}{10^4}. \tag{24}$$

Para anos inteiros, empregam-se diretamente os valores tabulados; para anos fracionários, realiza-se interpolação linear entre os dois anos adjacentes. Não se admite extrapolação fora de 1900–2100. O limite de disponibilidade da série ambiental não amplia o domínio de validade do modelo de carbonatação.

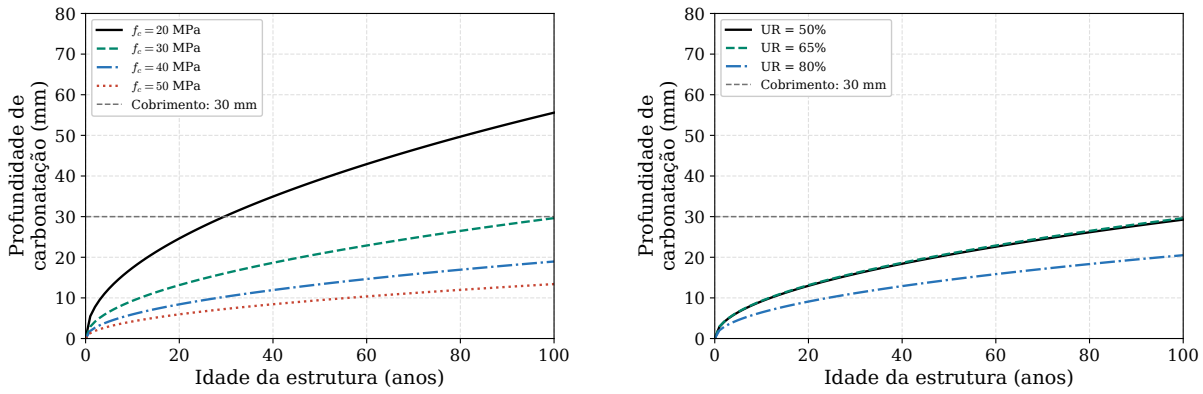
Adota-se a média global como uma hipótese de concentração atmosférica de fundo. Não são representadas diferenças locais associadas a tráfego, ventilação ou ocupação. Além disso, variar apenas o CO_2, mantendo as demais hipóteses ambientais, caracteriza uma análise de sensibilidade à concentração atmosférica, e não uma simulação conjunta de todos os efeitos das mudanças climáticas. As incertezas dos materiais e da exposição consideradas no simulador são avaliadas condicionalmente a cada trajetória de CO_2; a dispersão entre cenários não é tratada como intervalo probabilístico.

Perfis paramétricos de referência. As Figuras 4A e 4B ilustram a resposta da Equação (4) para uma estrutura construída em 2000 e analisada até 2100, sob SSP2-4.5, cimento CP II F, exposição externa protegida e $ad = 10\%$. Na primeira figura varia-se f_c com $UR = 65\%$; na segunda varia-se UR com $f_c = 30$ MPa. A linha em 30 mm corresponde ao cobrimento escolhido para essa ilustração, sem pretensão de representar todas as classes de exposição. Esses perfis ilustrativos mantêm $ad = 10\%$ e início em 2000; o caso de durabilidade dos Exemplos 2 e 3 utiliza $ad = 0\%$ e início em 1980, conforme suas definições.

Nesses perfis, a expressão de carbonatação é avaliada com a idade e a concentração correspondentes a cada ano, aplicando-se o máximo acumulado para impedir a redução da profundidade. Essa é uma aproximação temporal da aplicação do modelo, não uma integração explícita do histórico de difusão e reação. A interpretação dos resultados está sujeita a essa limitação; a adoção de cenários publicados de CO_2 não constitui, por si só, validação dessa aproximação.

4.2 Construção do emulador dependente do tempo

Definidos o simulador estocástico (Seção 4.1.1) e o núcleo estatístico do emulador (Seção 3), descreve-se aqui o procedimento concreto de construção do emulador PCE–GLD e sua extensão ao domínio temporal.



(A) Variação de f_c com $UR = 65\%$.

(B) Variação de UR com $f_c = 30$ MPa.

Figura 4: Perfis paramétricos de carbonatação para 100 anos de exposição (2000–2100), sob SSP2-4.5. O eixo horizontal representa a idade da estrutura. Perfis calculados pela Equação (4) com as hipóteses indicadas no texto.

4.2.1 Plano de experimentos e ajuste local

O treinamento do emulador PCE–GLD segue os passos:

1. **Plano de experimentos:** um conjunto de M pontos amostrais $\{\mathbf{x}^{(1)}, \ldots, \mathbf{x}^{(M)}\}$ é gerado por amostragem aleatória independente das distribuições de entrada. Um segundo conjunto independente é reservado para validação. As distribuições e os tamanhos de ambos os conjuntos são especificados em cada exemplo.

2. **Avaliações estocásticas:** para cada ponto $\mathbf{x}^{(j)}$, o simulador estocástico original é executado N vezes, gerando um conjunto amostral local da resposta, $\mathcal{Y}^{(j)}$.

3. **Ajuste local da GLD:** o método dos momentos, implementado no PyGLAM com 15 inicializações do ajuste, é utilizado para estimar os parâmetros locais ótimos $\hat{\boldsymbol{\lambda}}^{(j)}$ para cada $\mathcal{Y}^{(j)}$.

4. **Estimação dos coeficientes da PCE:** a partir dos pares $\{\mathbf{x}^{(j)}, \hat{\boldsymbol{\lambda}}^{(j)}\}_{j=1}^{M}$, os coeficientes $a_{i,\boldsymbol{\alpha}}$ da Equação (16) são calculados para cada λ_i.

4.2.2 Emulação dependente do tempo

O processo de carbonatação é inerentemente dependente do tempo, exigindo que a evolução da distribuição da margem de segurança seja capturada ao longo de toda a vida em serviço da estrutura. Para tanto, o arcabouço PCE–GLD é estendido para incluir o tempo t como variável de entrada contínua. Nesse esquema de emulação temporal, os parâmetros $\boldsymbol{\lambda}$ da GLD são avaliados em passos de tempo discretos, e um metamodelo de aprendizado de máquina (Seção 3.5) é subsequentemente treinado para mapear o espaço conjunto de variáveis físicas $\mathbf{X}$ e tempo t nos parâmetros da distribuição.

Primeiro, as PCEs são ajustadas aos parâmetros locais da GLD em N_t idades discretas. Em seguida, cada PCE é consultada em M_{ML} novas entradas, formando uma base mais

densa para o aprendizado temporal. Denotando por $\hat{\boldsymbol{\lambda}}_{\mathrm{PCE}}(\mathbf{x}, t_m)$ a saída da PCE da idade t_m, a base temporal é

$$\mathcal{D}_{\mathrm{ML}} = \left\{ \left((\mathbf{x}^{(j,m)}, t_m), \hat{\boldsymbol{\lambda}}_{\mathrm{PCE}}(\mathbf{x}^{(j,m)}, t_m) \right) \right\}_{j=1,\ldots,M_{\mathrm{ML}};\ m=1,\ldots,N_t} . \tag{25}$$

Essa etapa usa as predições das PCEs como alvos e dispensa novas avaliações físicas. Consequentemente, sua validação mede a reprodução das PCEs; a avaliação do emulador completo requer comparação adicional com as respostas do simulador.

Empregam-se dois regressores escalares, descritos na Seção 3.5.2, para aprender os parâmetros de locação e escala inversa:

$$\hat{\lambda}_i(\mathbf{X}, t) = \mathcal{M}_i(\mathbf{X}, t; \mathbf{w}_i), \qquad i \in \{1, 2\}. \tag{26}$$

Os parâmetros de forma λ_3 e λ_4 são fixados nos valores especificados em cada exemplo. Ao incluir o tempo como entrada, os regressores permitem consultar a distribuição entre as idades simuladas. A positividade de λ_2 e a qualidade da interpolação precisam ser verificadas nas consultas, pois as redes utilizadas não impõem essas propriedades por construção.

4.2.3 Métricas de validação do emulador

A similaridade estatística entre os dados de referência (*ground truth*, obtidos por simulação direta) e as amostras geradas pelo emulador é avaliada por um conjunto complementar de métricas, com a identificação do conjunto utilizado em cada comparação. As métricas dos parâmetros são calculadas em conjuntos reservados para validação; as comparações distribucionais locais dos exemplos usam também pontos de treinamento e, nesse caso, constituem diagnósticos do ajuste. A verificação em idades não usadas no treinamento é uma avaliação adicional:

Distâncias entre distribuições. A estatística de Kolmogorov–Smirnov (KS) (**massey1951**) quantifica a máxima diferença entre as funções de distribuição acumuladas empíricas. A distância de Wasserstein complementa essa leitura ao medir diferenças na escala da resposta. Nos exemplos, essas grandezas são utilizadas como diagnósticos de discrepância, sem concluir aderência apenas a partir de um valor-p.

Comparação de quantis. Os erros nos quantis P_5, P_{50} e P_{95} permitem distinguir desvios na cauda inferior, no centro e na cauda superior. Quando o quantil de referência se aproxima de zero, o erro relativo deve ser acompanhado do erro absoluto, evitando atribuir uma grande discrepância física ao efeito de um denominador pequeno.

Divergência de Kullback–Leibler. Para duas densidades $p(x)$ (referência) e $q(x)$ (emulador), a entropia relativa (**kullback1951**; **cover2006**)

$$D(p \,\|\, q) = \int p(x)\, \log \frac{p(x)}{q(x)}\, dx \tag{27}$$

é não negativa e anula-se se, e somente se, $p = q$. Embora não seja simétrica nem satisfaça a desigualdade triangular, é frequentemente útil interpretá-la como uma medida de "distância" entre distribuições, fornecendo um escalar global de qualidade do emulador. Nos diagnósticos contra amostras brutas, a implementação estima as densidades por kernels gaussianos em uma grade comum de 400 pontos e regulariza valores de densidade próximos de zero. A KL assim obtida é uma aproximação numérica sobre essa grade, distinta de uma integração analítica sobre todo o suporte. A verificação isolada do PyGLAM identifica sua própria referência e direção de cálculo.

4.3 Da distribuição emulada à vida útil remanescente

As grandezas de interesse para a gestão de ativos — probabilidade de falha dependente do tempo, distribuição do tempo até a despassivação, vida útil remanescente e métricas de risco — foram definidas na Seção 2.5. Esta subseção descreve como cada uma delas é obtida a partir da distribuição condicional emulada, e não por simulação direta.

4.3.1 Probabilidade de falha por inversão da função quantílica

Dado que o emulador fornece, para qualquer instante t, os parâmetros $\hat{\boldsymbol{\lambda}}(\mathbf{X}, t)$ da GLD que aproxima a distribuição de g, a probabilidade de falha instantânea é obtida diretamente da função quantílica, sem necessidade de amostragem:

$$p_f(t) = \mathbb{P}\,[\, g(\mathbf{X}, t) \leq 0\,] = F_{g(t)}(0) = Q_t^{-1}(0), \tag{28}$$

em que $F_{g(t)}$ é a CDF da margem de segurança no instante t e Q_t a correspondente função quantílica emulada. Como a GLD é definida por sua função quantílica (Equação (10)) e não admite CDF em forma fechada, a inversão é realizada numericamente por bisseção em $u \in [0, 1]$, procurando-se u^* tal que $Q(u^*; \hat{\boldsymbol{\lambda}}) = 0$; o valor u^* é a própria probabilidade de falha. Cada avaliação custa algumas dezenas de iterações escalares, contra as milhares de execuções do simulador que a estimativa equivalente por Monte Carlo exigiria. O índice de confiabilidade generalizado associado é $\beta(t) = -\Phi^{-1}[p_f(t)]$, conforme a Seção 2.5.

No simulador físico, a profundidade carbonatada é não decrescente, pela aplicação do máximo acumulado, e o cobrimento de cada realização permanece constante. Nessas condições, uma trajetória que cruza o zero não retorna ao domínio seguro e a probabilidade de primeira passagem até t coincide com $p_f(t)$. Essa propriedade do simulador não é imposta automaticamente às predições da camada temporal. A equivalência deve, portanto, ser verificada para as trajetórias emuladas antes de interpretar $1 - p_f(t)$ como sobrevivência até t.

4.3.2 Distribuição de RUL e métricas de risco

Nos exemplos de RUL, fixa-se um ponto de projeto $\mathbf{x}$ e constroem-se trajetórias a partir das distribuições condicionais emuladas. Para cada realização, sorteia-se um nível $u_i \sim \mathcal{U}(0,1)$, mantido ao longo do tempo:

$$\hat{g}_i(t) = Q\Big(u_i; \hat{\boldsymbol{\lambda}}(\mathbf{x}, t)\Big)\,. \tag{29}$$

Esse acoplamento comonotônico preserva a ordenação das realizações entre as idades. Ele é uma hipótese de dependência temporal, adicional à aproximação das distribuições marginais. Manter u_i fixo não assegura, por si só, que $\hat{g}_i(t)$ decresça: isso depende da evolução dos quantis emulados.

O tempo até um limiar é localizado pelo primeiro cruzamento descendente, com interpolação linear entre as idades adjacentes. Para um instante de inspeção t_{insp}, a distribuição de RUL é obtida condicionando os tempos à não ocorrência do evento até essa idade e subtraindo t_{insp}, conforme a Equação (6). O condicionamento pela margem $g(t_{\text{insp}}) > g_{\text{lim}}$ é equivalente ao condicionamento pela sobrevivência quando as trajetórias são não crescentes; caso haja retornos, deve-se considerar o histórico do primeiro cruzamento.

Trajetórias sem cruzamento no horizonte são censuradas à direita. Representando o horizonte por $t_{\max}$ e o tempo até o evento por T, o valor armazenado é $\min(T, t_{\max})$. Sua média estima uma vida média restrita ao horizonte. Estatísticas calculadas apenas sobre os cruzamentos observados, por sua vez, descrevem a população condicionada a $T < t_{\max}$. Essa distinção acompanha a apresentação dos resultados, inclusive quando se interpretam os quantis inferiores e as métricas de risco das Equações (7) e (8).

4.3.3 Políticas de manutenção por limiar preventivo

A política preventiva é definida pelo valor de margem que aciona uma intervenção. Para cada realização,

$$T_i(g_{\text{lim}}) = \inf\left\{t \geq 0 : \hat{g}_i(t) \leq g_{\text{lim}}\right\}. \tag{30}$$

Para o estado limite de carbonatação, $g_{\text{lim}} = 0$ corresponde à despassivação; um valor positivo reserva uma espessura de cobrimento ainda não carbonatado no instante de intervenção. Uma trajetória já abaixo do limiar em $t = 0$ tem $T_i = 0$; uma trajetória sem cruzamento até $t_{\max}$ permanece censurada.

A variação do limiar utiliza as mesmas trajetórias do emulador, alterando apenas o critério de cruzamento. O Exemplo 3 aplica esse procedimento para comparar os prazos associados a margens preventivas diferentes. O custo adicional é o do pós-processamento das trajetórias. A avaliação do efeito físico de um reparo sobre a degradação posterior e a otimização de custos de manutenção constituem extensões que exigem modelos e dados específicos.

5. Resultados e discussão

Os exemplos numéricos examinam três questões complementares: a capacidade de representar uma distribuição de resposta que evolui no tempo, a aplicação dessa representação à durabilidade do concreto armado e o efeito de uma política preventiva sobre o tempo disponível para intervir. Após a verificação isolada do ajuste da GLD, o Exemplo 1 utiliza um problema idealizado de resistência e solicitação, cuja simplicidade permite comparar o emulador com a simulação direta. O Exemplo 2 considera a margem entre o cobrimento e a profundidade carbonatada, incorporando a variabilidade do material, do cobrimento e da umidade relativa. O Exemplo 3 retoma o mesmo elemento e compara limiares de intervenção, interpretados como diferentes margens de cobrimento ainda não carbonatado.

Essa sequência permite examinar separadamente o erro de aproximação estatística, as particularidades da resposta de carbonatação e a interpretação dos resultados para manutenção. Nos dois últimos exemplos, o evento físico de referência é a despassivação da armadura; um limiar positivo antecipa a intervenção em relação a esse evento. Os Exemplos 1 e 2 são apresentados com os resultados numéricos da execução atual dos notebooks. **[FALTA: O Exemplo 3 depende de uma nova rodada de geração do conjunto de RUL com limiares adicionais, ainda em execução; a Seção 5.4 mantém a configuração planejada e as tabelas a preencher.]**

5.1 Verificação da biblioteca PyGLAM

A biblioteca *PyGLAM*, desenvolvida pelos autores em linguagem Python, implementa o ajuste, a amostragem e a avaliação da Distribuição Lambda Generalizada na parametrização FKML (**Freimer1988**). Por ser o núcleo estatístico de todo o arcabouço — é ela que converte cada conjunto de réplicas do simulador em um vetor $\boldsymbol{\lambda}$ —, sua acurácia condiciona a de todos os resultados subsequentes. Esta subseção verifica essa acurácia de forma isolada, antes que o emulador seja exercitado nos Exemplos 5.2 e 5.3.

5.1.1 Procedimento

Quatro distribuições-alvo foram escolhidas por exercitarem geometrias distintas: a **Normal** (simétrica, suporte ilimitado), a de **Gumbel** (assimétrica à direita, cauda exponencial), a **Uniforme** (suporte compacto, sem moda) e a **Lognormal** (assimétrica à direita, cauda mais pesada). Para cada alvo, amostras de tamanho $N \in \{50;\ 200;\ 1.000;\ 5.000\}$ foram geradas e ajustadas pelo método dos momentos com 15 reinícios de otimização. Cada célula $(\text{distribuição}, N)$ foi repetida 20 vezes com amostras independentes, e os valores reportados são as médias dessas repetições — precaução necessária porque, em $N = 50$, um ajuste isolado é dominado por ruído amostral.

As métricas são calculadas contra a distribuição-alvo *analítica*, e não contra a amostra, de modo a medir a qualidade da aproximação da família GLD e não o ajuste ao ruído. A estatística de Kolmogorov–Smirnov é tomada como $\sup_x |F_{\text{GLD}}(x) - F_{\text{alvo}}(x)|$, os erros

de quantil são normalizados pela amplitude P_5–P_{95} do alvo, e a divergência de Kullback–Leibler (Equação (27)) é avaliada na direção $D(q\|p)$, da GLD ajustada em relação ao alvo. Essa escolha de direção não é arbitrária: com $\lambda_3, \lambda_4 > 0$ a GLD-FKML possui suporte *compacto*, ao passo que Normal, Gumbel e Lognormal não, de modo que $D(p\|q)$ diverge por construção.

5.1.2 Resultados

A Figura 5 apresenta os ajustes para $N = 1.000$ e a Tabela 3 consolida as métricas.

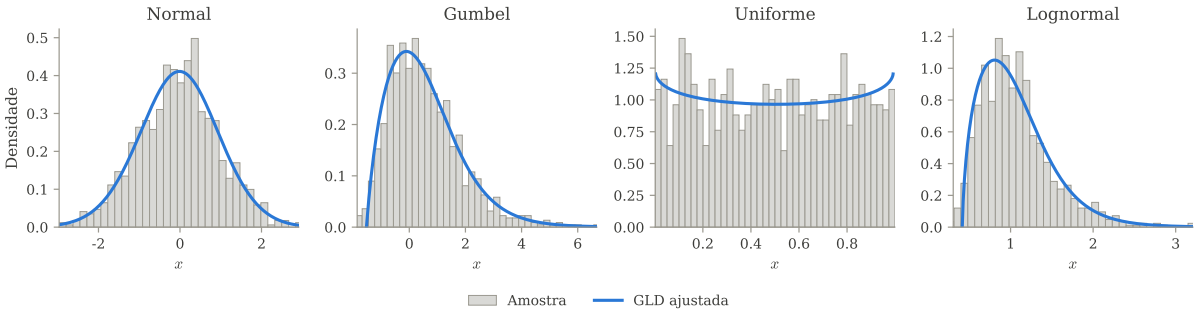


Figura 5: Ajuste da GLD, pelo método dos momentos implementado no PyGLAM, a quatro distribuições-alvo ($N = 1.000$). O histograma corresponde à amostra e a linha contínua à densidade da GLD ajustada.

Tabela 3: Métricas de qualidade do ajuste da GLD às distribuições-alvo, em média sobre 20 repetições independentes por célula. Erros de quantil normalizados pela amplitude P_5–P_{95}.

Distribuição	N	**KS**	$D(q\|p)$	**Wasserstein**	P_5 (%)	P_{50} (%)	P_{95} (%)
Normal	50	0,0659	0,0488	0,0877	5,55	3,37	7,18
	200	0,0366	0,0108	0,0512	3,59	2,04	2,27
	1.000	0,0158	0,0021	0,0228	1,43	0,74	1,34
	5.000	0,0059	0,0003	0,0129	0,46	0,28	0,53
Gumbel	50	0,0818	0,1047	0,1333	5,01	3,88	9,92
	200	0,0476	0,0623	0,0947	2,46	1,57	4,94
	1.000	0,0460	0,0941	0,0883	1,50	1,14	4,84
	5.000	0,0436	0,0963	0,0823	1,23	0,93	3,24
Uniforme	50	0,0720	0,0341	0,0208	3,48	5,73	2,92
	200	0,0324	0,0006	0,0099	1,16	2,41	1,39
	1.000	0,0175	0,0026	0,0051	0,82	1,12	0,65
	5.000	0,0066	0,0013	0,0029	0,21	0,48	0,21
Lognormal	50	0,0940	0,1238	0,0543	4,07	4,17	13,73
	200	0,0738	0,1584	0,0423	2,74	2,56	6,36
	1.000	0,0303	0,0481	0,0191	1,14	0,85	2,53
	5.000	0,0149	0,0149	0,0117	0,57	0,37	1,10

A leitura quantitativa desses resultados é dada pela taxa com que a distância KS decai com o tamanho amostral, obtida por regressão linear em escala logarítmica. O erro

de um ajuste por momentos decompõe-se em duas parcelas: uma *amostral*, decorrente da estimação dos quatro primeiros momentos a partir de uma amostra finita, que decai com a taxa teórica $N^{-1/2}$; e outra *estrutural*, decorrente de a família GLD não conter exatamente a distribuição-alvo, que independe de N. A inclinação medida discrimina as duas.

Para a Normal e a Uniforme obtiveram-se inclinações de $-0{,}52$ e $-0{,}50$, com $R^2 = 0{,}99$ em ambos os casos — estatisticamente indistinguíveis da taxa teórica $-1/2$. O erro observado é, portanto, integralmente de natureza amostral, sem parcela estrutural detectável: a GLD representa essas duas distribuições com a precisão que os dados permitirem. Em termos absolutos, em $N = 5.000$ a distância KS cai a 0,0059 e 0,0066, respectivamente, com erros de quantil abaixo de 0,55% em toda a faixa P_5–P_{95}. A Lognormal apresenta inclinação de $-0{,}42$, ligeiramente inferior, o que sinaliza uma pequena parcela não amostral, mas ainda converge de forma sustentada, alcançando 1,10% no P_{95}. Esses três casos confirmam a capacidade da GLD de representar simultaneamente distribuições simétricas, assimétricas e de suporte compacto com um único conjunto de quatro parâmetros.

5.1.3 O limite estrutural da família GLD

O comportamento da distribuição de Gumbel merece destaque, e a Figura 6 o evidencia. Enquanto as demais distribuições decaem com inclinações entre $-0{,}42$ e $-0{,}52$, a curva da Gumbel estabiliza em torno de KS $\approx 0{,}044$ a partir de $N = 200$: sua inclinação medida é de apenas $-0{,}12$, e o baixo coeficiente de determinação da regressão ($R^2 = 0{,}68$) confirma que o decaimento sequer segue uma lei de potência. Trata-se, portanto, de um patamar *estrutural*, e não amostral: aumentar a amostra não reduz a discrepância porque a família GLD, com os parâmetros de forma ajustados, não representa exatamente a cauda exponencial da Gumbel.

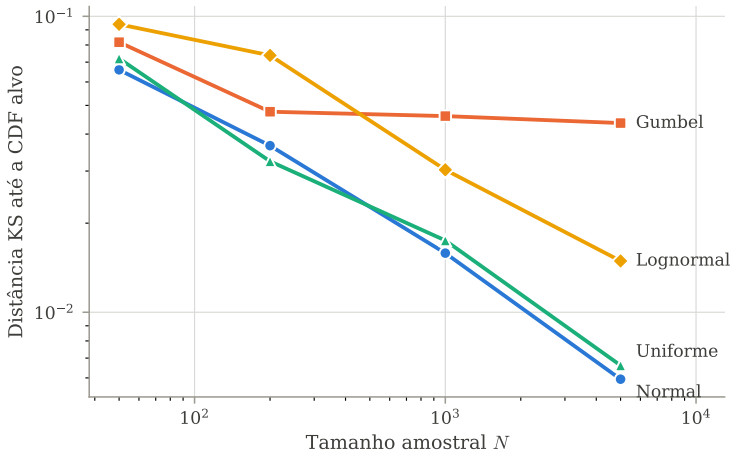


Figura 6: Convergência da distância de Kolmogorov–Smirnov entre a GLD ajustada e a distribuição-alvo, em função do tamanho amostral. Eixos em escala logarítmica; cada ponto é a média de 20 repetições independentes.

A mesma leitura explica o comportamento do teste clássico de aderência. Nas 20

repetições, o teste KS de duas amostras não rejeitou a hipótese nula em nenhum caso para a Normal e para a Uniforme, em qualquer tamanho amostral. Para a Gumbel e a Lognormal, contudo, a taxa de rejeição a 5% cresceu de 0% em $N = 50$ para 30% em $N = 5.000$. O aparente paradoxo — ajustes que melhoram enquanto o teste rejeita mais — é apenas o ganho de potência do teste: com amostras maiores, ele passa a detectar uma discrepância residual que permanece pequena em magnitude. No Exemplo 5.2, a comparação das distribuições é apresentada por métricas de distância e erros de quantis, sem uma decisão de teste de hipótese.

A origem desse limite é geométrica. Com $\lambda_3, \lambda_4 > 0$, a GLD-FKML tem suporte compacto, de modo que uma distribuição-alvo de suporte ilimitado é necessariamente aproximada por uma de caudas truncadas. Para a Gumbel ajustada em $N = 5.000$, por exemplo, obteve-se $\lambda_3 = 1{,}67$ e $\lambda_4 = 2{,}25$, com suporte $[-1{,}86;\ 34{,}42]$; já a Lognormal produziu $\lambda_4 = -0{,}04$, valor negativo que mantém a cauda direita ilimitada e explica sua convergência mais favorável. Essa constatação é relevante para a interpretação dos resultados de confiabilidade: a aproximação da GLD é excelente no corpo da distribuição e nos quantis usualmente empregados em decisões de manutenção, mas a acurácia na cauda extrema deve ser verificada caso a caso, e não presumida.

5.2 Exemplo 1: verificação em problema de referência

O problema de referência permite avaliar a representação da distribuição de resposta antes da aplicação ao concreto armado. Adota-se uma adaptação do exemplo de **pires2024<empty citation>** na qual a margem de segurança depende da resistência R, da solicitação S e das incertezas de modelo Z_1 e Z_2:

$$g(R, S, t) = k_{\text{fator}}(t)\frac{R}{Z_1} - SZ_2. \tag{31}$$

A redução da resistência segue a expressão

$$k_{\text{fator}}(t) = \begin{cases} 1 + (k_{\text{final}} - 1)\dfrac{t}{T_f}, & 0 \le t < T_f, \\ k_{\text{final}}, & t \ge T_f, \end{cases} \qquad t \text{ em anos}, \tag{32}$$

com $k_{\text{final}} = 0{,}5$ e $T_f = 100$ anos, de modo que a capacidade cai linearmente até metade do valor íntegro ao final do horizonte. Essa magnitude é compatível com uma deterioração severa, ainda que a lei de decaimento permaneça idealizada. A retenção do valor terminal para $t \ge T_f$ é uma salvaguarda: sem ela, a extrapolação linear cruzaria zero em $t = T_f/(1 - k_{\text{final}})$ e inverteria o sinal da resistência, produzindo distribuições de resposta degeneradas, sem interpretação física e não representáveis por uma GLD válida. As variáveis de entrada estão descritas na Tabela 4. Esse exemplo representa uma perda idealizada de capacidade e serve à verificação do método. Sua lei de degradação não descreve os mecanismos de carbonatação ou corrosão do concreto armado.

Tabela 4: Variáveis do problema de referência.

Variável	Símbolo	Distribuição	Média	Desvio padrão
Resistência	R	Normal	5,00	0,80
Solicitação	S	Normal	2,00	0,60
Incerteza de modelo da resistência	Z_1	Lognormal	1,00	0,028
Incerteza de modelo da solicitação	Z_2	Lognormal	1,00	0,096

5.2.1 Configuração das simulações, representação da GLD e ganho computacional

A configuração atual utiliza 2.000 pontos de projeto para treinamento e 500 para validação, com 2.500 realizações de g geradas para cada par (R, S) a partir das variáveis latentes. Os quatro parâmetros da GLD são ajustados às amostras pelo PyGLAM, e os metamodelos PCE são construídos separadamente em cada uma das 5 idades igualmente espaçadas entre 0 e 100 anos. A qualidade desse ajuste, por parâmetro, é discutida na Seção 5.2.2, junto com o desempenho da camada temporal de aprendizado de máquina.

A distinção entre os dois níveis de amostragem é central para esse ensaio. A variação de (R, S) testa a capacidade de generalização no espaço de entradas, enquanto a repetição de (Z_1, Z_2) para um par fixo determina a distribuição condicional que se deseja emular. As idades $\{0, 25, 50, 75, 100\}$ anos cobrem o início, os pontos intermediários e o final da degradação prescrita. Emprega-se uma PCE de grau total máximo cinco, ajustada por mínimos quadrados; sua qualidade é avaliada nos pontos de validação, sem pressupor que o grau escolhido seja ótimo. A lei linear de perda de resistência torna mais simples identificar discrepâncias introduzidas pelo ajuste da GLD e pela representação temporal, antes de introduzir a resposta não linear da carbonatação.

O ganho computacional foi avaliado pela razão entre o tempo do procedimento de referência e o tempo de predição do emulador PCE para o mesmo conjunto de 2.000 pontos de projeto, em cada uma das cinco idades:

$$S_{\text{comp}}(t) = \frac{T_{\text{ref}}(t)}{T_{\text{PCE}}(t)}. \tag{33}$$

O tempo T_{ref} soma a geração das amostras latentes, a avaliação do modelo numérico, a organização dos dados e o ajuste local da GLD. O tempo T_{PCE} corresponde à predição dos parâmetros para o lote de entradas, com o metamodelo já treinado e carregado. Portanto, a razão mede o ganho na obtenção dos parâmetros da distribuição em relação ao procedimento completo de referência, e não uma comparação com o tempo isolado de avaliação da função g.

Tabela 5: Tempos por lote de pontos de projeto e ganho computacional nas cinco idades avaliadas.

Tempo (anos)	Referência (s)	Emulador PCE (s)	Ganho (vezes)
0,00	936,209381	0,002231	419.549
25,00	954,884701	0,001499	637.069
50,00	905,878127	0,001637	553.220
75,00	870,398033	0,001492	583.323
100,00	798,989566	0,001436	556.504
Mediana	905,878127	0,001499	556.504

A última linha apresenta a mediana de cada coluna, estatística menos sensível ao valor mais baixo registrado em $t = 0$. A mediana do ganho é a mediana das cinco razões registradas, calculada antes do arredondamento; não é a razão entre os tempos medianos.

O procedimento de referência demandou, na mediana, 905,88 s por idade, enquanto a predição pela PCE levou aproximadamente 1,50 ms. A mediana dos ganhos foi de $5{,}57 \times 10^5$ vezes, com valores entre $4{,}20 \times 10^5$ e $6{,}37 \times 10^5$.

Esses resultados mostram a redução do custo de consulta após a construção da PCE, o que favorece a avaliação repetida de cenários. O treinamento da PCE e o pós-processamento para amostragem, confiabilidade ou RUL não estão incluídos no tempo de predição. Além disso, o registro disponível contém uma cronometragem de predição por idade, sem repetições para estimar sua variabilidade. O ganho obtido caracteriza esse ensaio e não deve ser transferido diretamente para o modelo de durabilidade do concreto.

5.2.2 Camada temporal de aprendizado de máquina

A camada temporal utiliza as entradas (R, S, t) para prever os parâmetros λ_1 e λ_2 de forma contínua no tempo, dispensando o uso de uma PCE independente para cada instante. Os parâmetros de forma λ_3 e λ_4 não são preditos por essa camada, nem pela PCE nas reconstruções distribucionais deste exemplo: como mostra a Tabela 6, esses dois parâmetros controlam principalmente as caudas da GLD, variam pouco entre pontos de projeto e ao longo do tempo, e a PCE não os representa com precisão. Adotam-se, portanto, seus valores médios no conjunto de treinamento, $\lambda_3 = 0{,}142157$ e $\lambda_4 = 0{,}131525$, nas comparações distribucionais do Exemplo 1. O Exemplo 2 adota seus próprios valores de forma.

Tabela 6: Erro quadrático médio (MSE) e coeficiente de determinação R^2 dos quatro parâmetros da GLD no conjunto de validação da PCE, por idade.

	MSE				R^2			
Tempo (anos)	λ_1	λ_2	λ_3	λ_4	λ_1	λ_2	λ_3	λ_4
0,00	0,000032	0,036096	0,000452	0,000413	0,999969	0,979504	0,002202	0,100693
25,00	0,000032	0,051272	0,000454	0,000469	0,999965	0,976717	0,065788	0,002610
50,00	0,000026	0,049197	0,000438	0,000383	0,999967	0,984233	0,015658	0,079338
75,00	0,000025	0,056486	0,000400	0,000399	0,999962	0,986619	−0,001781	0,060296
100,00	0,000022	0,063286	0,000419	0,000420	0,999960	0,989090	−0,018763	−0,008939

A predição de λ_1 tem R^2 acima de 0,9999 em todas as idades, com MSE da ordem de 10^{-5}, cerca de três ordens de grandeza menor que o de λ_2. Para λ_2, o R^2 fica entre 0,977 e 0,989, com leve melhora nas idades mais avançadas. Já λ_3 e λ_4 têm R^2 próximo de zero na maior parte da malha temporal, tornando-se negativo para λ_3 aos 75 e 100 anos e para λ_4 aos 100 anos: nesses casos, a média dos valores de referência do parâmetro no conjunto de validação produz menor erro quadrático que a predição desse parâmetro pela PCE. Esse comportamento sustenta a escolha de um valor médio fixo para os dois parâmetros de forma, em vez de um metamodelo dedicado a cada um.

A Tabela 7 traz as métricas da camada neural global, composta por uma rede para cada parâmetro. Seus alvos são obtidos por 5.000 novas consultas à PCE em cada idade, totalizando 25.000 pares. Assim, as métricas desta tabela medem a reprodução das saídas da PCE pela camada temporal; a comparação com as amostras brutas do simulador é apresentada a seguir.

Tabela 7: Erro quadrático médio (MSE) e coeficiente de determinação R^2 de λ_1 e λ_2 no conjunto de validação da rede neural global.

MSE λ_1	R^2 λ_1	MSE λ_2	R^2 λ_2
0,000164	0,99989	0,00205	0,999454

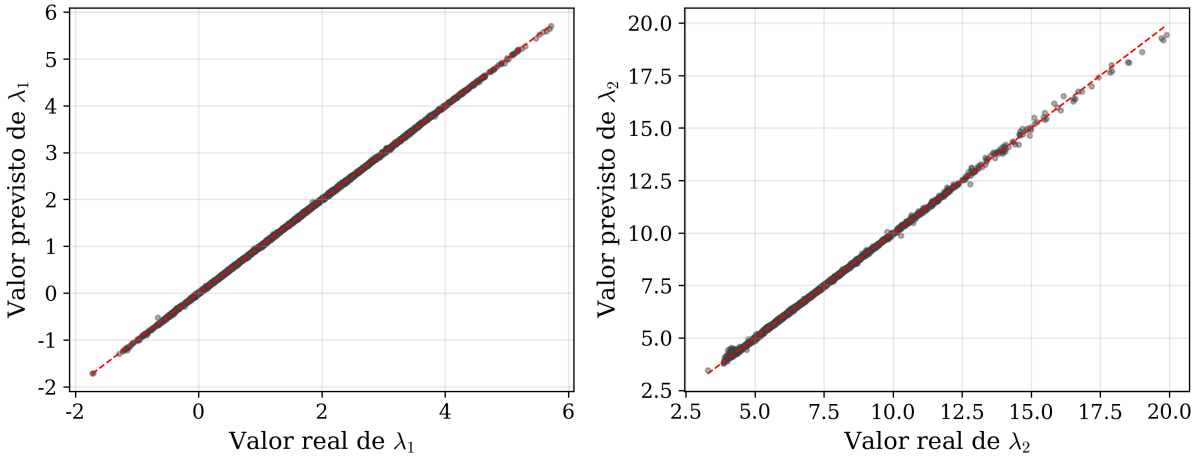


Figura 7: Valor previsto versus valor real de λ_1 (esquerda) e λ_2 (direita) no conjunto de validação da rede neural global. A linha tracejada vermelha marca a identidade.

A camada neural reproduz os alvos gerados pela PCE com $R^2 > 0{,}9998$ para λ_1 e $R^2 = 0{,}999454$ para λ_2. Como as Tabelas 6 e 7 utilizam referências diferentes, esses valores não demonstram superioridade da rede em relação à PCE na aproximação do simulador físico. A Figura 7 confirma essa leitura: os pontos se mantêm próximos à identidade em toda a faixa de valores, com dispersão um pouco maior em λ_2 nos valores mais altos. O resultado é compatível com λ_2 variar suavemente com t: a camada temporal aproveita essa suavidade para interpolar entre os instantes discretos da PCE, em vez de ajustar cada idade isoladamente.

5.2.3 Propagação de incerteza: PCE versus rede neural

Esta seção compara diretamente a PCE e a rede neural quanto à propagação de incerteza de g, no mesmo ponto de projeto ($R = 5{,}394$, $S = 2{,}305$, pertencente ao conjunto de treinamento) e nas mesmas duas idades, $t = 50$ e $t = 100$ anos, com $\lambda_3 = 0{,}142157$ e $\lambda_4 = 0{,}131525$ fixados para os dois modelos. A densidade de referência é estimada por KDE sobre as amostras brutas de g desse ponto, e comparada à GLD reconstruída a partir dos parâmetros emulados por cada modelo, pelas métricas da Seção 4.2.3: divergência KL, estatística KS, distância de Wasserstein, R^2 entre densidades e erros relativos de quantil. Por se tratar de um único ponto de projeto, o resultado não generaliza o comportamento dos dois modelos no espaço (R, S, t), mas fornece uma estimativa direta de como cada um se comporta nesse ponto específico.

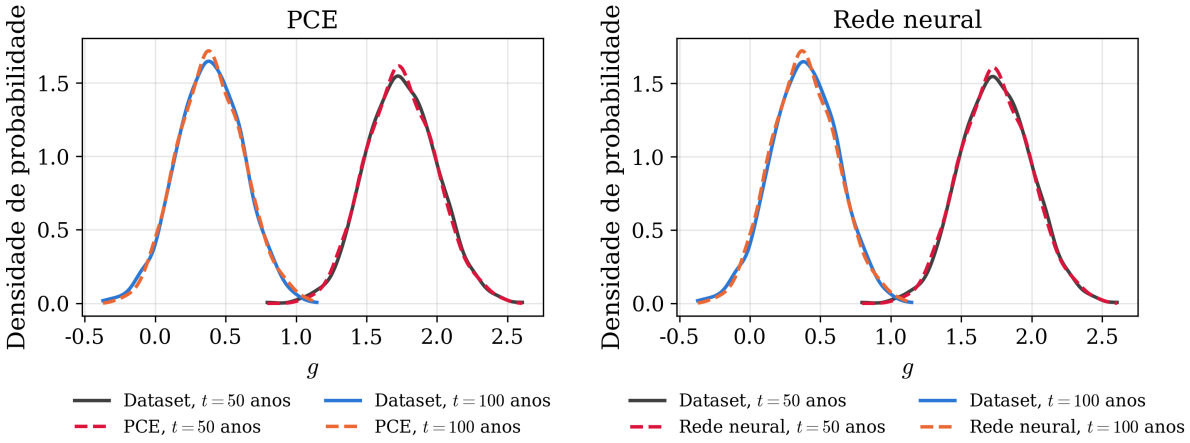


Figura 8: Densidades de referência e emuladas para $R = 5{,}394$ e $S = 2{,}305$, nas idades de 50 e 100 anos: PCE (esquerda) e rede neural (direita). A linha cheia representa a KDE das amostras do conjunto de dados e a linha tracejada representa a GLD emulada, com os parâmetros de forma fixados.

Tabela 8: Métricas de propagação de incerteza para a PCE e para a rede neural, no mesmo ponto de projeto, em duas idades.

	PCE		Rede neural	
Métrica	$t = 50$	$t = 100$	$t = 50$	$t = 100$
Divergência KL	0,00374	0,00366	0,00351	0,00318
Estatística KS	0,01840	0,01400	0,01800	0,01960
Distância de Wasserstein	0,00540	0,00701	0,00529	0,00740
R^2 entre densidades	0,99791	0,99753	0,99801	0,99551
Erro relativo em P_5 (%)	−0,47	+10,91	−0,61	−46,78
Erro relativo em P_{50} (%)	−0,16	+0,32	−0,16	−2,05
Erro relativo em P_{95} (%)	+0,18	+1,11	+0,27	−0,18

Aos 50 anos, PCE e rede neural têm desempenho equivalente e igualmente bom: divergência KL de 0,00374 e 0,00351, R^2 acima de 0,997 para ambas, e erros de quantil

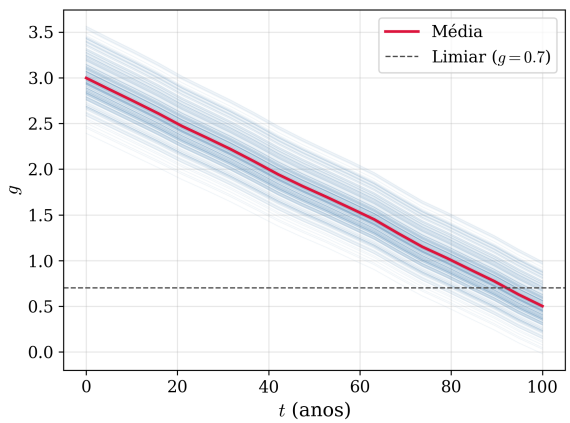
abaixo de 1% nos três percentis avaliados. As duas curvas praticamente se sobrepõem à KDE de referência na Figura 8.

Aos 100 anos, a divergência KL favorece discretamente a rede neural, enquanto o R^2 entre densidades favorece a PCE (0,00318 e 0,99551, contra 0,00366 e 0,99753 da PCE). Aqui o R^2 da PCE é o maior dos dois, o oposto do que ocorre na divergência KL, o que já sinaliza que essas duas métricas agregadas não contam a mesma história dos quantis. O erro relativo em P_5 dispara para os dois modelos, mas de forma assimétrica: +10,91% na PCE contra −46,78% na rede neural. Esse salto não indica necessariamente um colapso do ajuste: aos 100 anos o percentil P_5 do conjunto de referência está próximo de zero (Figura 8, cauda inferior da distribuição à esquerda), de modo que um pequeno desvio absoluto do quantil emulado se traduz em um erro percentual muito maior que nas demais métricas. Ainda assim, a rede neural erra por uma margem consideravelmente maior que a PCE nesse ponto específico, o que é relevante porque a cauda inferior de g é justamente a região que governa a probabilidade de falha.

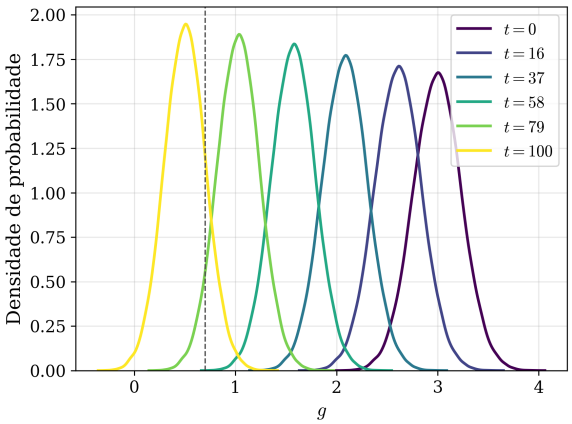
Em conjunto, os dois ensaios mostram desempenhos globais próximos, com diferenças de ordenação entre as métricas e maior erro relativo da rede neural na cauda inferior aos 100 anos. Um único ponto de projeto não permite afirmar se isso é uma característica sistemática do modelo global ou uma particularidade deste ponto e desta idade. **[FALTA: Repetir esta comparação em outros pontos de projeto e idades para verificar se a maior sensibilidade da rede neural na cauda inferior em $t = 100$ é sistemática.]**

5.2.4 Vida útil remanescente

Para este exemplo, adota-se um limiar de intervenção em $g = 0{,}7$, definido apenas para fins de ilustração do método, sem correspondência com um critério normativo específico. O fim da vida útil é tomado como o primeiro instante em que g cruza esse limiar, e não necessariamente $g = 0$: na prática, uma intervenção de manutenção é programada enquanto ainda resta margem de segurança, não apenas quando o estado limite já foi atingido.



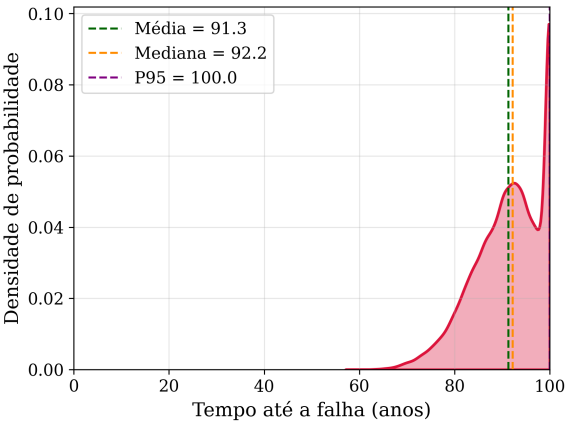
(A) Trajetórias de $g(t)$.



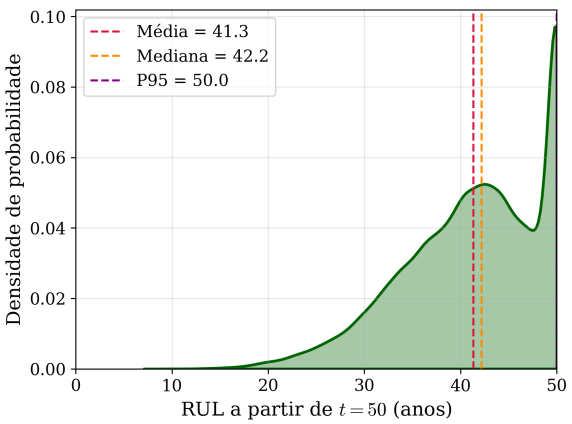
(B) Densidade de g em seis idades.

Figura 9: Comportamento de $g(t)$ para $R = 5{,}0$ e $S = 2{,}0$ (valores médios das variáveis de entrada): (a) 300 das 50.000 trajetórias simuladas, com a média (vermelho); (b) densidade de g em seis idades entre 0 e 100 anos. O limiar de intervenção $g = 0{,}7$ é indicado em ambos os painéis (tracejado).

Cada trajetória do painel (a) é comonotônica: um único nível de quantil u é sorteado por trajetória e mantido fixo ao longo do tempo, de modo que $g_i(t) = Q\big(u_i; \hat{\boldsymbol{\lambda}}(t)\big)$, o que preserva a ordenação das realizações entre as idades. A monotonicidade no tempo depende da evolução dos quantis emulados e deve ser verificada separadamente. Amostrar cada instante de forma independente produziria, em vez disso, trajetórias que oscilam livremente. A dispersão entre trajetórias cresce com o tempo, conforme a evolução da dispersão condicional representada pelos parâmetros da GLD, e a média cruza o limiar por volta de $t = 91$ anos. O painel (b) mostra a mesma degradação sob outro ângulo: a densidade de g se desloca gradualmente para a esquerda, e por $t = 100$ anos seu corpo já ultrapassou o limiar.



(A) Tempo até o cruzamento, a partir de $t = 0$.



(B) RUL condicionada à sobrevivência em $t = 50$ anos.

Figura 10: Distribuição do tempo até o cruzamento do limiar $g = 0{,}7$, para $R = 5{,}0$ e $S = 2{,}0$: (a) a partir de $t = 0$; (b) vida útil remanescente condicionada à sobrevivência em $t = 50$ anos, RUL $= T - t_{\text{insp}}$. Ambas as densidades são truncadas no maior valor alcançável dentro do horizonte simulado de 100 anos.

Os tempos armazenados, limitados ao horizonte de 100 anos, apresentam média restrita de 91,32 anos, mediana de 92,18 anos, desvio padrão de 7,13 anos e $P_5 = 78{,}19$ anos, com 16,4% das trajetórias censuradas em $t = 100$ anos. O pico estreito junto a esse limite corresponde a essa censura, não a um comportamento intrínseco da distribuição. Como nenhuma trajetória cruza o limiar antes de $t = 50$ anos (valor obtido por interpolação linear entre os instantes simulados, que não incluem $t = 50$ diretamente), todas as 50.000 sobrevivem até esse instante, e a RUL condicional do painel (b) é a mesma distribuição do painel (a), apenas deslocada em 50 anos: média restrita de 41,32 anos e mediana de 42,18 anos. O percentil empírico $P_{95} = 50{,}00$ anos recai no limite do horizonte: a simulação não determina o percentil 95 da RUL completa.

5.3 Exemplo 2: distribuição da margem de durabilidade e vida remanescente sob carbonatação

O segundo exemplo investiga se o emulador consegue representar a evolução da distribuição de $g = c - y(t)$ quando a degradação decorre do modelo de carbonatação da Seção 2.4. O caso corresponde a um elemento de concreto armado idealizado, com início da exposição em 1980, cimento CP II F, ambiente externo protegido da chuva e concentração atmosférica de CO_2 segundo SSP2-4.5. A análise compreende as idades de zero a 100 anos, correspondentes a 1980–2080. Essas definições caracterizam um estudo numérico; não se atribuem os parâmetros a uma estrutura inspecionada.

5.3.1 Escolha das entradas e do ponto de análise

O domínio de construção do emulador está apresentado na Tabela 9. As três entradas são amostradas de distribuições uniformes independentes. Aqui, essas distribuições definem a cobertura do espaço de estudo: cada ponto representa uma combinação nominal de concreto, ambiente e cobrimento. A dispersão da resposta para um elemento com entradas fixadas é introduzida separadamente pelas variáveis latentes da Seção 4.1.2.

Tabela 9: Domínio das entradas e ponto fixado para a análise de vida remanescente do Exemplo 2. A umidade é apresentada em porcentagem e convertida em fração na equação de carbonatação.

Entrada	Símbolo	Domínio de amostragem	Ponto fixado
Resistência à compressão	f_c	$\mathcal{U}(20, 50)$ MPa	25 MPa
Umidade relativa	UR	$\mathcal{U}(20, 80)\%$	55%
Cobrimento nominal	c_{nom}	$\mathcal{U}(15, 60)$ mm	25 mm

As entradas exercem papéis distintos na função de estado limite. O cobrimento desloca diretamente a margem de segurança, pois representa a distância que a frente carbonatada precisa percorrer para alcançar a armadura. A resistência à compressão modifica a profundidade prevista pelo modelo, e a umidade relativa atua de forma não monotônica: o

termo quadrático da Equação (4) atinge seu máximo em $UR = 58\%$. Assim, a faixa de umidade abrange ambos os lados desse máximo e exige que o emulador represente respostas diferentes para ambientes mais secos e mais úmidos. Esses intervalos constituem o domínio numérico escolhido; a sua adoção não equivale à validação experimental do modelo em toda a faixa, conforme discutido na Seção 2.4.

Para a análise temporal detalhada, fixa-se $(f_c, UR, c_{\text{nom}}) = (25\,\text{MPa}, 55\%, 25\,\text{mm})$. A resistência e o cobrimento situam-se na parte inferior dos respectivos intervalos, enquanto a umidade está próxima daquela que maximiza a profundidade no modelo. Essa combinação permite examinar uma condição favorável ao avanço da carbonatação e acompanhar a aproximação de g aos limiares de interesse. A ocorrência e o instante de cruzamento permanecem resultados da análise probabilística. Os valores escolhidos não constituem uma especificação normativa de projeto.

A escolha de 1980 estabelece uma origem temporal para avaliar um elemento que envelhece sob uma trajetória ambiental variável. O cenário SSP2-4.5 é mantido fixo para que a análise se concentre na variabilidade das entradas e na aproximação pelo emulador; não lhe é atribuída probabilidade de ocorrência. O horizonte de 100 anos permanece dentro da série ambiental disponível. Na parametrização do cimento, adota-se $ad = 0\%$, representando a hipótese de ausência de adição pozolânica suplementar, conforme a Seção 4.1.2.

5.3.2 Variabilidade condicional e construção do conjunto de dados

Para cada combinação nominal são geradas 2.500 réplicas independentes dos multiplicadores de resistência, umidade e cobrimento. Os multiplicadores da resistência e do cobrimento são lognormais com média unitária e coeficiente de variação de 15%; o da umidade é obtido de uma Normal de média unitária e desvio padrão 0,15, truncada para manter a umidade efetiva entre zero e 100%. As distribuições positivas evitam valores negativos de resistência e cobrimento. A truncagem da umidade respeita seu intervalo físico sem acumular artificialmente observações exatamente nos limites. Como a truncagem altera os momentos, o coeficiente de variação efetivo da umidade não é exatamente 15% em todos os pontos de projeto.

O valor comum de 15% define a intensidade de dispersão adotada no experimento. Ele permite estudar a propagação de uma variabilidade não desprezível, mas não é tratado como uma calibração conjunta das três grandezas para uma obra real. A influência dessa hipótese sobre a vida remanescente deve ser considerada na interpretação dos resultados; sua eventual aplicação a um ativo específico requer caracterização própria dos materiais, do cobrimento e da exposição.

São amostrados 2.000 pontos de treinamento e 500 pontos de validação, mantidos nas cinco idades $\{0, 25, 50, 75, 100\}$ anos. A reutilização das mesmas entradas permite acompanhar a evolução da distribuição em cada ponto. As réplicas latentes são geradas novamente em cada idade; portanto, o conjunto de treinamento caracteriza distribuições

condicionais e não fornece, por si só, trajetórias individuais acompanhadas ao longo do tempo. O planejamento corresponde a 25 milhões de respostas escalares de g para treinamento e 6,25 milhões para validação, totalizando 12.500 ajustes locais de GLD pelo método dos momentos, com 15 inicializações do procedimento de ajuste.

Convém distinguir a malha do simulador físico da malha de treinamento. O simulador avalia a expressão de carbonatação em uma malha auxiliar de dez anos, aplica o máximo acumulado da profundidade e interpola linearmente para obter a resposta na idade consultada. As cinco idades de treinamento selecionam as distribuições a serem aproximadas pela PCE. Essa organização reduz o número de ajustes distribucionais ao longo do tempo, mas introduz uma discretização que precisa ser considerada na avaliação da precisão temporal.

5.3.3 PCE e camada temporal

Em cada idade ajusta-se uma PCE de grau total máximo três por mínimos quadrados aos quatro parâmetros locais da GLD. Para três entradas, essa escolha resulta em 20 termos por parâmetro, incluindo a constante, estimados com 2.000 pontos de treinamento. A relação entre o número de pontos e o número de termos produz um ajuste sobredeterminado. O grau três constitui a configuração inicial do estudo; sua suficiência deve ser avaliada pelos erros nos pontos de validação, sobretudo em regiões de maior curvatura da resposta em função da umidade.

A camada temporal recebe $(f_c, UR, c_{\text{nom}}, t)$ e é treinada a partir de 5.000 novas consultas a cada PCE, totalizando até 25.000 pares de entrada e saída. Esses alvos são predições das PCEs. A geração dessa base mais densa permite treinar a rede sem repetir as simulações físicas e os ajustes locais da GLD. Antes do treinamento são excluídas as linhas com $\lambda_2 \leq 0$ e as linhas com alvos ausentes. A quantidade descartada deve acompanhar as métricas, pois a exclusão pode reduzir a cobertura do domínio.

São utilizadas duas redes do tipo perceptron multicamadas, uma para λ_1 e outra para λ_2, cada qual com duas camadas ocultas de 64 neurônios. As entradas são padronizadas a partir do subconjunto de treinamento. Adotam-se uma partição aleatória de 80% para treinamento e 20% para validação, no máximo 500 iterações e parada antecipada com tolerância de 15 iterações sem melhoria; a semente da partição e das redes é 42. A mesma arquitetura do problema de referência permite comparar a aplicação do procedimento aos dois exemplos sem introduzir uma seleção adicional de regressores.

Na reconstrução das distribuições adotam-se $\lambda_3 = 0{,}198312$ e $\lambda_4 = 0{,}130039$, médias dos ajustes locais no conjunto de treinamento na execução com $ad = 0\%$ e variabilidade latente de 15%. Das 25.000 linhas geradas para a base temporal, nenhuma foi descartada pelo critério $\lambda_2 \leq 0$ ou por alvo ausente, de modo que a rede foi treinada sobre a totalidade das consultas às PCEs, com 20.000 linhas para treinamento e 5.000 para validação.

A Tabela 10 apresenta o MSE e o R^2 dos quatro parâmetros da PCE nos 500 pontos de validação, por idade. Como no Exemplo 1, λ_1 é o parâmetro mais bem representado,

com R^2 acima de 0,997 em todas as idades; λ_2 mantém R^2 entre 0,884 e 0,983. Os parâmetros de forma λ_3 e λ_4 têm R^2 próximo de zero ou negativo em quase todas as idades — chegando a $-1{,}28$ para λ_4 aos 25 anos —, o que reforça a opção por fixá-los em seus valores médios em vez de emulá-los pela PCE.

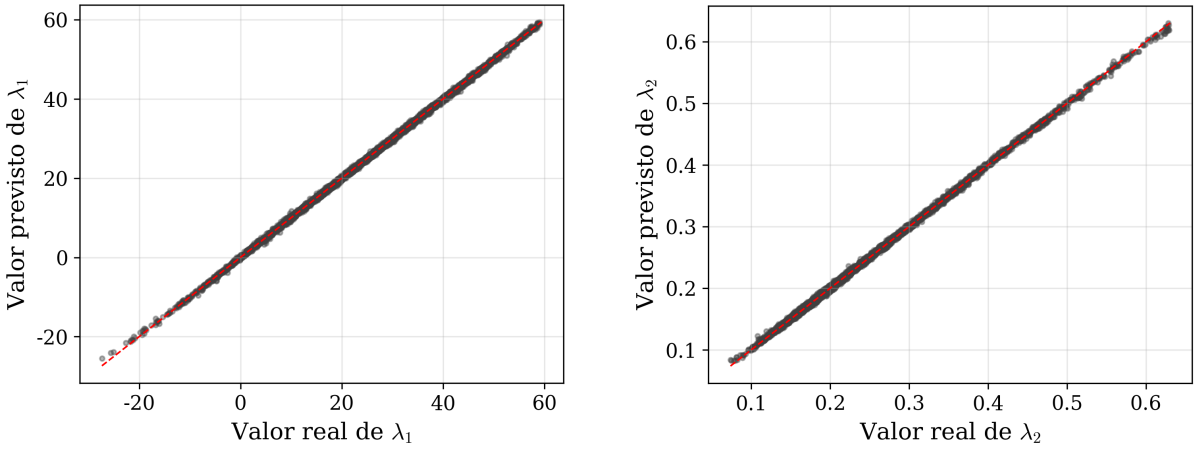
Tabela 10: Erro quadrático médio (MSE) e coeficiente de determinação R^2 dos quatro parâmetros da GLD no conjunto de validação da PCE, por idade, no Exemplo 2.

	MSE				R^2			
Tempo (anos)	λ_1	λ_2	λ_3	λ_4	λ_1	λ_2	λ_3	λ_4
0,00	0,244947	0,000388	0,201466	0,445823	0,998568	0,976155	0,005321	0,005749
25,00	0,131674	0,000143	0,001815	0,002885	0,999299	0,982971	0,457648	−1,280777
50,00	0,327814	0,000195	0,125826	0,081558	0,998430	0,970964	−0,078117	−0,039379
75,00	0,458894	0,000710	0,437726	0,370454	0,998003	0,884269	−0,039640	−0,011561
100,00	0,623390	0,000295	0,303531	0,148885	0,997524	0,946618	−0,044526	−0,000625

A Tabela 11 traz as métricas da camada neural global na partição de validação da base gerada pelas PCEs. A escala de λ_1 neste exemplo (profundidade em milímetros, tipicamente entre 0 e 50 mm) é maior que a do Exemplo 1, o que explica o MSE absoluto mais alto sem indicar pior ajuste relativo: o R^2 de 0,999542 para λ_1 e 0,999354 para λ_2 é comparável ao obtido no problema de referência.

Tabela 11: Erro quadrático médio (MSE) e coeficiente de determinação R^2 de λ_1 e λ_2 no conjunto de validação da rede neural global do Exemplo 2.

MSE λ_1	R^2 λ_1	MSE λ_2	R^2 λ_2
0,110126	0,999542	0,000006	0,999354



(A) λ_1 **(B)** λ_2

Figura 11: Valor previsto versus valor real de λ_1 e λ_2 no conjunto de validação da rede neural global do Exemplo 2. A linha tracejada vermelha marca a identidade.

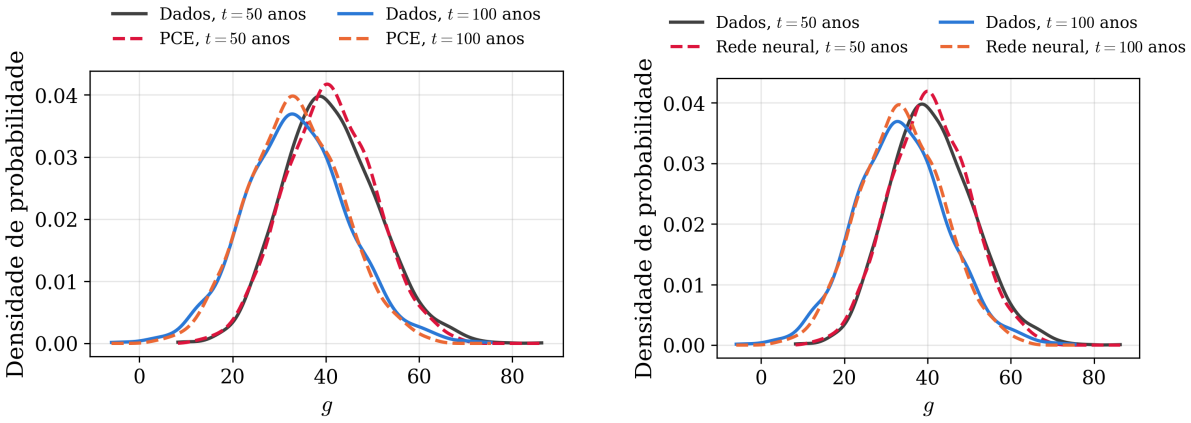
5.3.4 Comparação das distribuições e critérios de validação

A avaliação distingue três níveis. No primeiro, os parâmetros previstos pela PCE são comparados aos ajustes locais nos 500 pontos de validação em cada idade. No segundo, as redes são avaliadas na partição reservada da base gerada pelas PCEs. No terceiro, a distribuição reconstruída pelo emulador é comparada às amostras brutas de g produzidas pelo simulador. Essa distinção é necessária porque um elevado R^2 da rede em relação às saídas da PCE mede a reprodução do metamodelo intermediário e pode coexistir com erro em relação à simulação física.

Os diagnósticos distribucionais configurados utilizam o primeiro ponto do conjunto de treinamento — $f_c = 30{,}805$ MPa, $UR = 52{,}540\%$, $c_{\text{nom}} = 59{,}511$ mm — nas idades de 50 e 100 anos, tanto para a PCE quanto para a rede. A comparação nas mesmas entradas facilita identificar o efeito da camada temporal, enquanto as duas idades permitem observar uma etapa intermediária e o final do horizonte. A referência é constituída pelas 2.500 amostras brutas de g desse ponto, e as métricas incluem KS, Wasserstein, divergência KL estimada por densidades suavizadas, R^2 entre densidades e erros nos quantis P_5, P_{50} e P_{95}. Esses diagnósticos são verificações locais em idades de treinamento. A validação em idades intermediárias requer simulações diretas adicionais e não é realizada nesta execução.

Tabela 12: Comparação distribucional do Exemplo 2 no ponto de projeto $f_c = 30{,}805$ MPa, $UR = 52{,}540\%$, $c_{\text{nom}} = 59{,}511$ mm.

	PCE		Rede neural	
Métrica	50 anos	100 anos	50 anos	100 anos
KS	0,0232	0,0284	0,0300	0,0232
Wasserstein (mm)	0,4353	0,6952	0,5227	0,6933
KL estimada	0,01826	0,03487	0,02111	0,03245
R^2 entre densidades	0,99252	0,99232	0,99356	0,99204
Erro relativo em P_5 (%)	−2,47	+6,35	−3,22	+7,83
Erro relativo em P_{50} (%)	+0,76	−0,30	+0,10	+0,56
Erro relativo em P_{95} (%)	−2,17	−3,62	−2,76	−2,97



(A) PCE **(B)** Rede neural

Figura 12: Densidades de referência (amostras brutas de g) e reconstruída pelo emulador, no ponto $f_c = 30{,}805$ MPa, $UR = 52{,}540\%$, $c_{\text{nom}} = 59{,}511$ mm, nas idades de 50 e 100 anos: PCE (esquerda) e rede neural (direita).

Na Tabela 12, PCE e rede neural têm desempenho equivalente aos 50 anos, com R^2 acima de 0,992 e erros de quantil abaixo de 3% para ambas. Aos 100 anos, o comportamento reproduz o observado no Exemplo 5.2: o erro relativo em P_5 cresce para os dois modelos — +6,35% na PCE e +7,83% na rede neural —, enquanto P_{50} e P_{95} permanecem abaixo de 4%. Ao contrário do problema de referência, aqui a rede neural não se distancia muito mais da PCE nessa cauda: a diferença entre os dois erros em P_5 aos 100 anos é de apenas 1,5 pontos percentuais, contra dezenas de pontos no Exemplo 1. A Figura 12 mostra que, nas duas idades, a densidade reconstruída acompanha de perto a KDE das amostras brutas, com a maior discrepância concentrada na cauda inferior — exatamente a região que determina a proximidade da despassivação. Como no Exemplo 1, a concordância no centro da distribuição não garante, isoladamente, a precisão da probabilidade de atingir um limiar preventivo baixo. A validação da interpolação temporal em idades não usadas no treinamento — por exemplo, 40 ou 90 anos — exigiria simulações diretas adicionais, não realizadas nesta execução.

5.3.5 Trajetórias e vida remanescente no ponto fixado

No ponto da Tabela 9, a rede é consultada em 20 idades igualmente espaçadas entre zero e 100 anos, com intervalo aproximado de 5,26 anos. São geradas 50.000 trajetórias por acoplamento quantílico: cada trajetória mantém o mesmo nível uniforme u_i ao avaliar $g_i(t) = Q(u_i; \hat{\boldsymbol{\lambda}}(t))$. As 50.000 amostras reduzem a variabilidade do pós-processamento da GLD; não aumentam a informação física disponível para treinar o emulador. Para a visualização das trajetórias são utilizadas apenas 300 delas.

O acoplamento preserva a posição relativa de cada realização entre as distribuições, estabelecendo uma hipótese explícita de dependência temporal. A monotonicidade física da profundidade no simulador não garante que todas as curvas quantílicas da rede sejam monotônicas. Por isso, a interpretação em termos de primeira passagem exige verificar

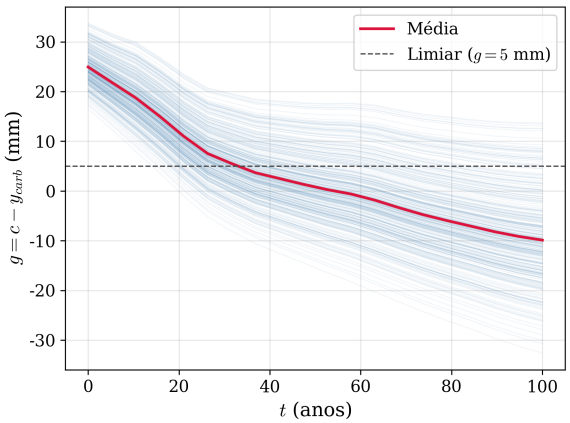
a evolução das trajetórias emuladas. Consultar 20 idades, em vez das cinco usadas no treinamento, permite localizar o cruzamento com maior resolução, mas a precisão desse refinamento depende da interpolação aprendida.

A configuração principal considera $g_{\text{lim}} = 5$ mm. Nesse caso, o tempo calculado representa o prazo até que restem 5 mm de cobrimento não carbonatado. O instante de cruzamento é estimado por interpolação linear entre as duas idades adjacentes que o delimitam. O caso $g_{\text{lim}} = 0$, incluído no Exemplo 3, fornece a referência correspondente à despassivação. Assim, a interpretação da vida remanescente sempre deve ser acompanhada do limiar que define o evento.

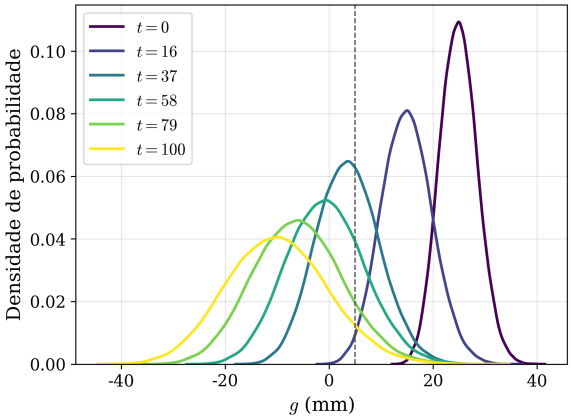
A avaliação condicional adota $t_{\text{insp}} = 25$ anos, correspondente a 2005, para representar a análise de um elemento após parte de sua exposição. Consideram-se as trajetórias que ainda não atingiram o limiar nessa idade, e a vida remanescente é medida a partir dela, conforme a Equação (6). Como 25 anos não pertence à malha de 20 idades do pós-processamento, a margem nesse instante também é obtida por interpolação. Esse condicionamento usa apenas a informação de que o limiar ainda não foi alcançado; uma atualização baseada em medições de carbonatação exigiria incorporar dados de inspeção.

As trajetórias que não atingem o limiar até 100 anos são censuradas à direita. O horizonte disponível a partir de $t_{\text{insp}} = 25$ anos é, portanto, de 75 anos. Uma concentração de valores nesse limite nos gráficos resulta da convenção numérica de encerrar a observação, e não da identificação de uma vida útil exatamente igual a 75 anos. A média calculada mantendo esses valores é uma média restrita ao horizonte, enquanto os quantis que recaem na região censurada não são determinados pela simulação.

Ao longo das 20 idades consultadas nesse ponto, λ_2 permanece positivo, decrescendo de 0,393 em $t = 0$ a 0,146 em $t = 100$ anos, o que garante uma GLD válida em toda a trajetória. Em $t = 0$ nenhuma das 50.000 realizações está abaixo do limiar de 5 mm — a média de g nessa idade é 24,95 mm, com $P(g \leq 5) = 0$ —, de modo que todo cruzamento observado corresponde a uma primeira passagem genuína, sem trajetórias que já iniciem abaixo do limiar.



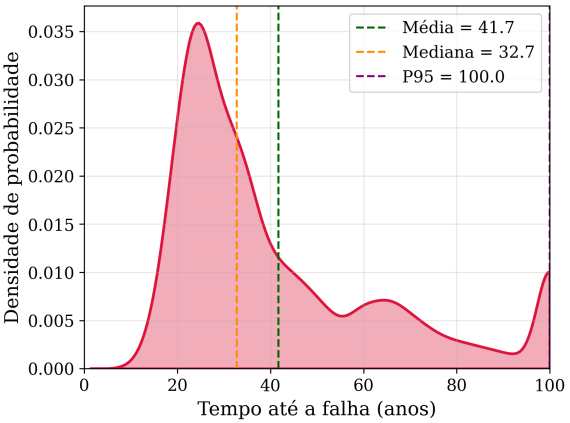
(A) Trajetórias de $g(t)$.



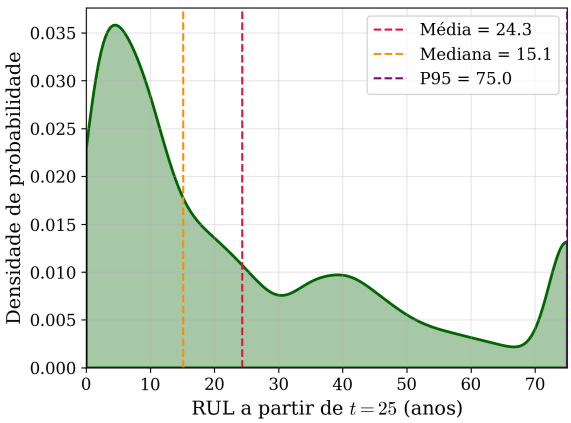
(B) Densidade de g em seis idades.

Figura 13: Comportamento de $g(t)$ no ponto $f_c = 25$ MPa, $UR = 55\%$, $c_{\text{nom}} = 25$ mm: (a) 300 das 50.000 trajetórias emuladas pela rede, com a média (vermelho); (b) densidade de g em seis idades entre 0 e 100 anos. O limiar de intervenção $g = 5$ mm é indicado em ambos os painéis (tracejado).

A dispersão entre trajetórias cresce com o tempo, e a média cruza o limiar de 5 mm por volta de $t = 33$ anos (Figura 13a). Do total de 50.000 trajetórias, 3.279 (6,56%) não atingem o limiar dentro do horizonte de 100 anos e são censuradas à direita. Entre as 46.721 que cruzam, o tempo até o limiar tem média de 41,70 anos, mediana de 32,74 anos, desvio padrão de 23,52 anos e $P_5 = 18{,}46$ anos; o P_{95} empírico da amostra completa recai no limite do horizonte (100 anos), refletindo a fração censurada.



(A) Tempo até o cruzamento, a partir de $t = 0$.



(B) RUL condicionada à sobrevivência em $t = 25$ anos.

Figura 14: Distribuição do tempo até o cruzamento do limiar $g = 5$ mm, no ponto $f_c = 25$ MPa, $UR = 55\%$, $c_{\text{nom}} = 25$ mm: (a) a partir de $t = 0$; (b) vida útil remanescente condicionada à sobrevivência em $t_{\text{insp}} = 25$ anos. Ambas as densidades são truncadas no maior valor alcançável dentro do horizonte simulado de 100 anos.

Em $t_{\text{insp}} = 25$ anos, 36.509 das 50.000 trajetórias (73,02%) ainda não atingiram o limiar; as demais 13.491 (26,98%) já o haviam cruzado antes dessa idade e ficam fora do condicionamento. Para as sobreviventes, a RUL medida a partir de $t = 25$ anos

(Figura 14b) tem média de 24,32 anos, mediana de 15,15 anos e $P_{95} = 75{,}00$ anos — novamente no limite do horizonte disponível a partir dessa idade ($100 - 25 = 75$ anos), de modo que o percentil 95 da RUL condicional completa não é determinado pela simulação. A diferença entre a média (24,32 anos) e a mediana (15,15 anos) reflete a assimetria à direita introduzida pela censura: a cauda longa de trajetórias que só cruzam o limiar perto do fim do horizonte, ou nunca o cruzam, eleva a média sem deslocar igualmente a mediana.

5.3.6 Custo computacional

A avaliação de custo segue a definição da Equação (33): em cada idade, compara-se o tempo de geração das réplicas, organização dos dados e ajuste local da GLD com o tempo de predição da PCE no mesmo lote de 2.000 entradas. Essa razão caracteriza o custo de obtenção dos parâmetros distribucionais. O treinamento das PCEs e das redes, a amostragem das trajetórias e o cálculo dos cruzamentos são etapas distintas e devem ser reportadas separadamente quando se avaliar o custo total.

Tabela 13: Tempos por lote de pontos de projeto e ganho computacional nas cinco idades avaliadas, no Exemplo 2.

Tempo (anos)	Referência (s)	Emulador PCE (s)	Ganho (vezes)
0,00	362,077174	0,006031	60.039
25,00	366,391805	0,005807	63.092
50,00	358,595040	0,005823	61.582
75,00	357,628061	0,002588	138.163
100,00	358,440037	0,002412	148.633
Mediana	358,595040	0,005807	63.092

A última linha apresenta a mediana de cada coluna, calculada como no Exemplo 1: a mediana do ganho é a mediana das cinco razões, não a razão entre os tempos medianos.

O procedimento de referência — que inclui a geração das réplicas latentes, a avaliação do modelo de carbonatação e o ajuste local da GLD — demandou, na mediana, 358,60 s por idade, contra aproximadamente 5,81 ms da predição pela PCE já treinada. A mediana dos ganhos foi de $6{,}31 \times 10^4$ vezes, com valores entre $6{,}00 \times 10^4$ (t=0) e $1{,}49 \times 10^5$ (t=100). Esse ganho é uma ordem de grandeza menor que o do Exemplo 1 ($5{,}57 \times 10^5$), coerente com o registro disponível conter apenas uma cronometragem por idade, sem repetições, e não deve ser interpretado como uma medida mais precisa da eficiência da PCE em si.

Chama atenção a diferença entre os tempos de predição da PCE em $t = 0$, 25 e 50 anos (entre 5,8 e 6,0 ms) e em $t = 75$ e 100 anos (entre 2,4 e 2,6 ms), aproximadamente 2,3 vezes menores. Como a arquitetura da PCE — grau total três, 20 termos por parâmetro — é a mesma em todas as idades, essa diferença é atribuída a variações no ambiente de execução durante a cronometragem (por exemplo, estado do cache ou de outros processos), e não a uma diferença estrutural do modelo entre idades; a ausência de repetições impede

quantificar essa variabilidade. Ainda assim, mesmo no cenário mais conservador ($t = 0$), a consulta ao emulador é cerca de 6×10^4 vezes mais rápida que o procedimento de referência, o que favorece decisivamente a avaliação repetida de cenários — por exemplo, a varredura de limiares do Exemplo 5.4 ou análises de sensibilidade que exijam milhares de consultas — frente ao custo de construir o emulador uma única vez. O treinamento das PCEs e da camada temporal, bem como a amostragem das 50.000 trajetórias e o cálculo dos cruzamentos da Seção anterior, não estão incluídos nesta comparação e representam um custo fixo, pago uma vez, que se dilui à medida que o emulador é reutilizado.

5.4 Exemplo 3: efeito do limiar de manutenção preventiva

O terceiro exemplo utiliza o elemento e as trajetórias do Exemplo 2 para examinar como o critério de intervenção modifica a distribuição do tempo disponível para manutenção. Mantêm-se o ponto de projeto, o cenário ambiental e as variáveis latentes, variando-se apenas g_{lim}. Essa escolha permite associar as diferenças entre os prazos à política adotada.

5.4.1 Definição e justificativa dos limiares

São considerados $g_{\text{lim}} \in \{0, 2, 5, 8, 12\}$ mm, conforme a configuração da análise de RUL. O limiar nulo corresponde à despassivação e estabelece a referência física da comparação. Os valores positivos representam margens preventivas crescentes: quanto maior o limiar, menor o avanço da frente carbonatada admitido antes da intervenção. O valor de 5 mm mantém a configuração principal do Exemplo 2, enquanto os demais permitem observar o efeito de reduzir ou ampliar essa margem. Esses valores são parâmetros de um estudo de políticas e não limites prescritos por norma.

Para uma mesma realização com cobrimento efetivo c_i, o limiar equivale a admitir uma profundidade $y_{\text{lim},i} = c_i - g_{\text{lim}}$. A Tabela 14 apresenta essa relação para o cobrimento nominal de 25 mm; nas simulações, a variabilidade de c_i é preservada. A apresentação em milímetros mantém uma ligação direta com a grandeza física que poderia ser avaliada em uma inspeção.

Tabela 14: Interpretação dos limiares de intervenção para o cobrimento nominal de 25 mm.

g_{lim} (mm)	$c_{\text{nom}} - g_{\text{lim}}$ (mm)	Interpretação
0	25	Referência de despassivação
2	23	Margem preventiva de 2 mm
5	20	Política principal do Exemplo 2
8	17	Margem preventiva de 8 mm
12	13	Margem preventiva de 12 mm

Para cada trajetória calcula-se o primeiro cruzamento de cada limiar, conforme a Seção 4.3.3. A reutilização das mesmas realizações permite uma comparação pareada das

políticas e dispensa novas consultas ao modelo físico. Para trajetórias inicialmente acima dos limiares, o tempo de cruzamento de um limiar maior é menor ou igual ao de um limiar menor. Essa ordenação fornece uma verificação de coerência do pós-processamento. Se uma trajetória já se encontra abaixo de um limiar no início da observação, o evento deve ser identificado como já ocorrido.

5.4.2 Comparação dos prazos e tratamento da censura

A comparação inclui a proporção de trajetórias que atingem cada limiar durante o horizonte, a proporção censurada e as estatísticas do tempo até o cruzamento. A Tabela 15 segue o resumo configurado no notebook: média, P_5 e mediana são calculados apenas entre as trajetórias cujo cruzamento é identificado antes do final do horizonte.

Tabela 15: Tempo até os limiares preventivos, contado a partir do início da exposição. As estatísticas de tempo referem-se apenas aos cruzamentos observados antes de 100 anos. Valores a preencher após a execução.

Limiar (mm)	Cruzamentos (%)	Censura (%)	Média (anos)	P_5 (anos)	Mediana (anos)
0	[•]	[•]	[•]	[•]	[•]
2	[•]	[•]	[•]	[•]	[•]
5	[•]	[•]	[•]	[•]	[•]
8	[•]	[•]	[•]	[•]	[•]
12	[•]	[•]	[•]	[•]	[•]

As densidades geradas na varredura são normalizadas sobre os cruzamentos observados. Por isso, devem ser interpretadas junto com a fração censurada: duas políticas podem apresentar densidades semelhantes e proporções diferentes de trajetórias que chegam ao limiar durante os 100 anos. Uma fração censurada elevada limita o que se pode concluir sobre a média e os quantis da distribuição completa.

Também é necessário distinguir a ordenação dos tempos individuais da comparação de médias condicionadas. Ao mudar o limiar, muda o subconjunto de trajetórias que cruza antes de 100 anos. Assim, as médias calculadas apenas sobre esses subconjuntos não precisam manter a mesma ordenação dos tempos de uma trajetória individual. O percentil P_5 da Tabela 15 caracteriza a cauda inferior dos cruzamentos observados; sua interpretação como quantil da população completa dependeria do tratamento da censura.

[FALTA: Inserir as distribuições do tempo até cada limiar e preencher a Tabela 15. Discutir a antecipação da intervenção, a mudança na proporção de cruzamentos e a amplitude dos prazos, considerando os subconjuntos usados em cada estatística.]

5.4.3 Interpretação para a manutenção e limites do exemplo

A comparação permite expressar uma política preventiva em termos de prazo e dispersão: ao reservar uma margem maior de cobrimento não carbonatado, antecipa-se o instante de intervenção para uma mesma trajetória. O emulador fornece uma forma de examinar essa relação para diferentes limiares, com o custo adicional concentrado no cálculo dos cruzamentos. Essa informação pode apoiar o planejamento de inspeções e a avaliação de antecedência disponível para uma ação.

O resultado deste exemplo é o tempo até o critério de intervenção. A quantificação do prolongamento da vida útil após um reparo exigiria definir a ação executada, a recuperação proporcionada e a evolução posterior do material. Da mesma forma, a escolha de um limiar ótimo dependeria de custos, consequências e restrições de manutenção. Tais extensões requerem informações adicionais às utilizadas nesta comparação.

Em conjunto, os exemplos permitem discutir se a aproximação da distribuição de g preserva as informações necessárias para avaliar prazos associados a eventos distintos. A análise final deve relacionar os erros distribucionais às caudas relevantes para cada limiar, à hipótese de dependência temporal, à resolução das malhas e à fração censurada. **[FALTA: Consolidar essa discussão com os resultados concluídos dos Exemplos 2 e 3, sem transferir automaticamente a acurácia ou o ganho computacional do problema de referência para a aplicação de durabilidade.]**

6. Conclusões

Este trabalho apresenta um procedimento de emulação distribucional dependente do tempo para a análise da margem de durabilidade de elementos de concreto armado sob carbonatação. O encadeamento entre GLD, PCE e redes neurais permite representar distribuições condicionais e consultar sua evolução temporal. O estado limite de referência é a despassivação, e a comparação de limiares positivos expressa políticas de intervenção preventiva.

No problema de referência, as comparações locais em 50 e 100 anos apresentam divergências KL estimadas inferiores a 0,004 para PCE e rede neural. A análise dos quantis evidencia, contudo, que uma pequena discrepância global pode coexistir com erro relativo elevado no quantil inferior quando este se aproxima de zero. A mediana do ganho de tempo na obtenção dos parâmetros por consulta à PCE é de aproximadamente $5{,}57 \times 10^5$, em relação ao procedimento que inclui amostragem, organização dos dados e ajuste local da GLD. Esse valor caracteriza a consulta ao modelo já treinado, com os limites de cronometragem descritos no Exemplo 1.

[FALTA: Concluir a avaliação da aplicação de durabilidade com os resultados dos Exemplos 2 e 3: acurácia da PCE e das redes, comportamento das caudas, verificação temporal, fração censurada, tempos até os limiares e custo computacional. Os resultados do problema de referência não substituem essa

avaliação.]

A interpretação da vida remanescente depende das hipóteses de variabilidade latente, da fixação dos parâmetros de forma da GLD e do acoplamento temporal das trajetórias. Também é limitada pelo domínio de aplicação do modelo de carbonatação, pela resolução temporal e pela censura ao final do horizonte. A comparação de limiares descreve o prazo até uma ação preventiva; a avaliação de ganho de vida após reparo requer um modelo da intervenção e da degradação posterior.

Como continuidade, propõem-se a caracterização das incertezas com dados de inspeção, a verificação do emulador em novos pontos e idades, a avaliação da dependência temporal e a incorporação de modelos de reparo e custos. Essas etapas permitem avançar da comparação de políticas para a seleção de ações de manutenção em um ativo específico.

Conflitos de interesse

Os autores declaram não haver conflitos de interesse.

Contribuição dos autores

Victor Hugo Moreira do Couto Souza: **[FALTA: Conceituação, Metodologia, Software, Redação (rascunho)]**. **Wanderlei Malaquias Pereira Junior**: **[FALTA: Concepção, Supervisão, Redação (revisão e edição)]**. **Marcos Luiz Henrique**: **[FALTA: Software, Validação]**. **Renata Maria Pensin**: **[FALTA: Investigação, Visualização]**. **Ketson dos Santos**: **[FALTA: Metodologia, Supervisão]**.

Financiamento

[FALTA: citar todas as fontes de financiamento com os respectivos números de processo (ex.: CNPq, CAPES, FAPEG); se não houver, declarar explicitamente]

Disponibilidade de dados

[FALTA: informar onde e sob quais condições os dados e o código (PyGLAM) podem ser acessados — ex.: repositório público com DOI]

Agradecimentos

[FALTA: agradecer pessoas e instituições que auxiliaram na preparação do manuscrito]

Apêndice A. Verificação da margem de durabilidade em uma idade

Este apêndice explicita a sequência de cálculo de uma resposta do Exemplo 2. Considera-se o ponto nominal $f_c = 25$ MPa, $UR = 55\%$ e $c_{\text{nom}} = 25$ mm, com início da exposição em 1980, cimento CP II F, exposição externa protegida, $ad = 0\%$ e cenário SSP2-4.5. Para uma realização latente i, calculam-se

$$f^*_{c,i} = 25\,\omega_{f_c,i}, \qquad UR^*_i = 0{,}55\,\omega_{UR,i}, \qquad c_i = 25\,\omega_{c,i}. \tag{A1}$$

A umidade é expressa como fração no modelo, enquanto f_c e c permanecem em MPa e mm. Para cada idade da malha auxiliar de dez anos, obtém-se a concentração no ano-calendário correspondente e avalia-se a Equação (4). O máximo acumulado dessas profundidades define $\tilde{y}_i(t)$ nos pontos da malha.

Para uma consulta aos 25 anos, correspondente a 2005, o simulador interpola entre as profundidades acumuladas aos 20 e 30 anos:

$$y_i(25) = \tilde{y}_i(20) + \frac{25-20}{30-20}\left[\tilde{y}_i(30) - \tilde{y}_i(20)\right], \qquad g_i(25) = c_i - y_i(25). \tag{A2}$$

O resultado é uma margem em milímetros. Um valor $g_i(25) \leq 0$ identifica que a frente alcançou a armadura. Para a política principal, $g_i(25) \leq 5$ mm identifica que o critério preventivo já foi atingido nessa idade, dada a monotonicidade do simulador.

Repetindo esse procedimento para as 2.500 réplicas de um mesmo ponto, obtém-se a amostra condicional de g à qual a GLD é ajustada. A repetição para os pontos de treinamento e de validação produz os conjuntos usados na construção das PCEs. Este cálculo pertence à geração dos dados de referência; a etapa posterior de vida remanescente utiliza as distribuições previstas pelas redes.

Apêndice B. Material suplementar

[FALTA: Incorporar os diagnósticos complementares das cinco idades de treinamento, a identificação dos pontos usados nas comparações distribucionais, os descartes da base temporal e os resultados de verificação da resolução e da monotonicidade das trajetórias.]